Transformações

Transforme seus dados em informação

James Sampaio, PhD

Transformações

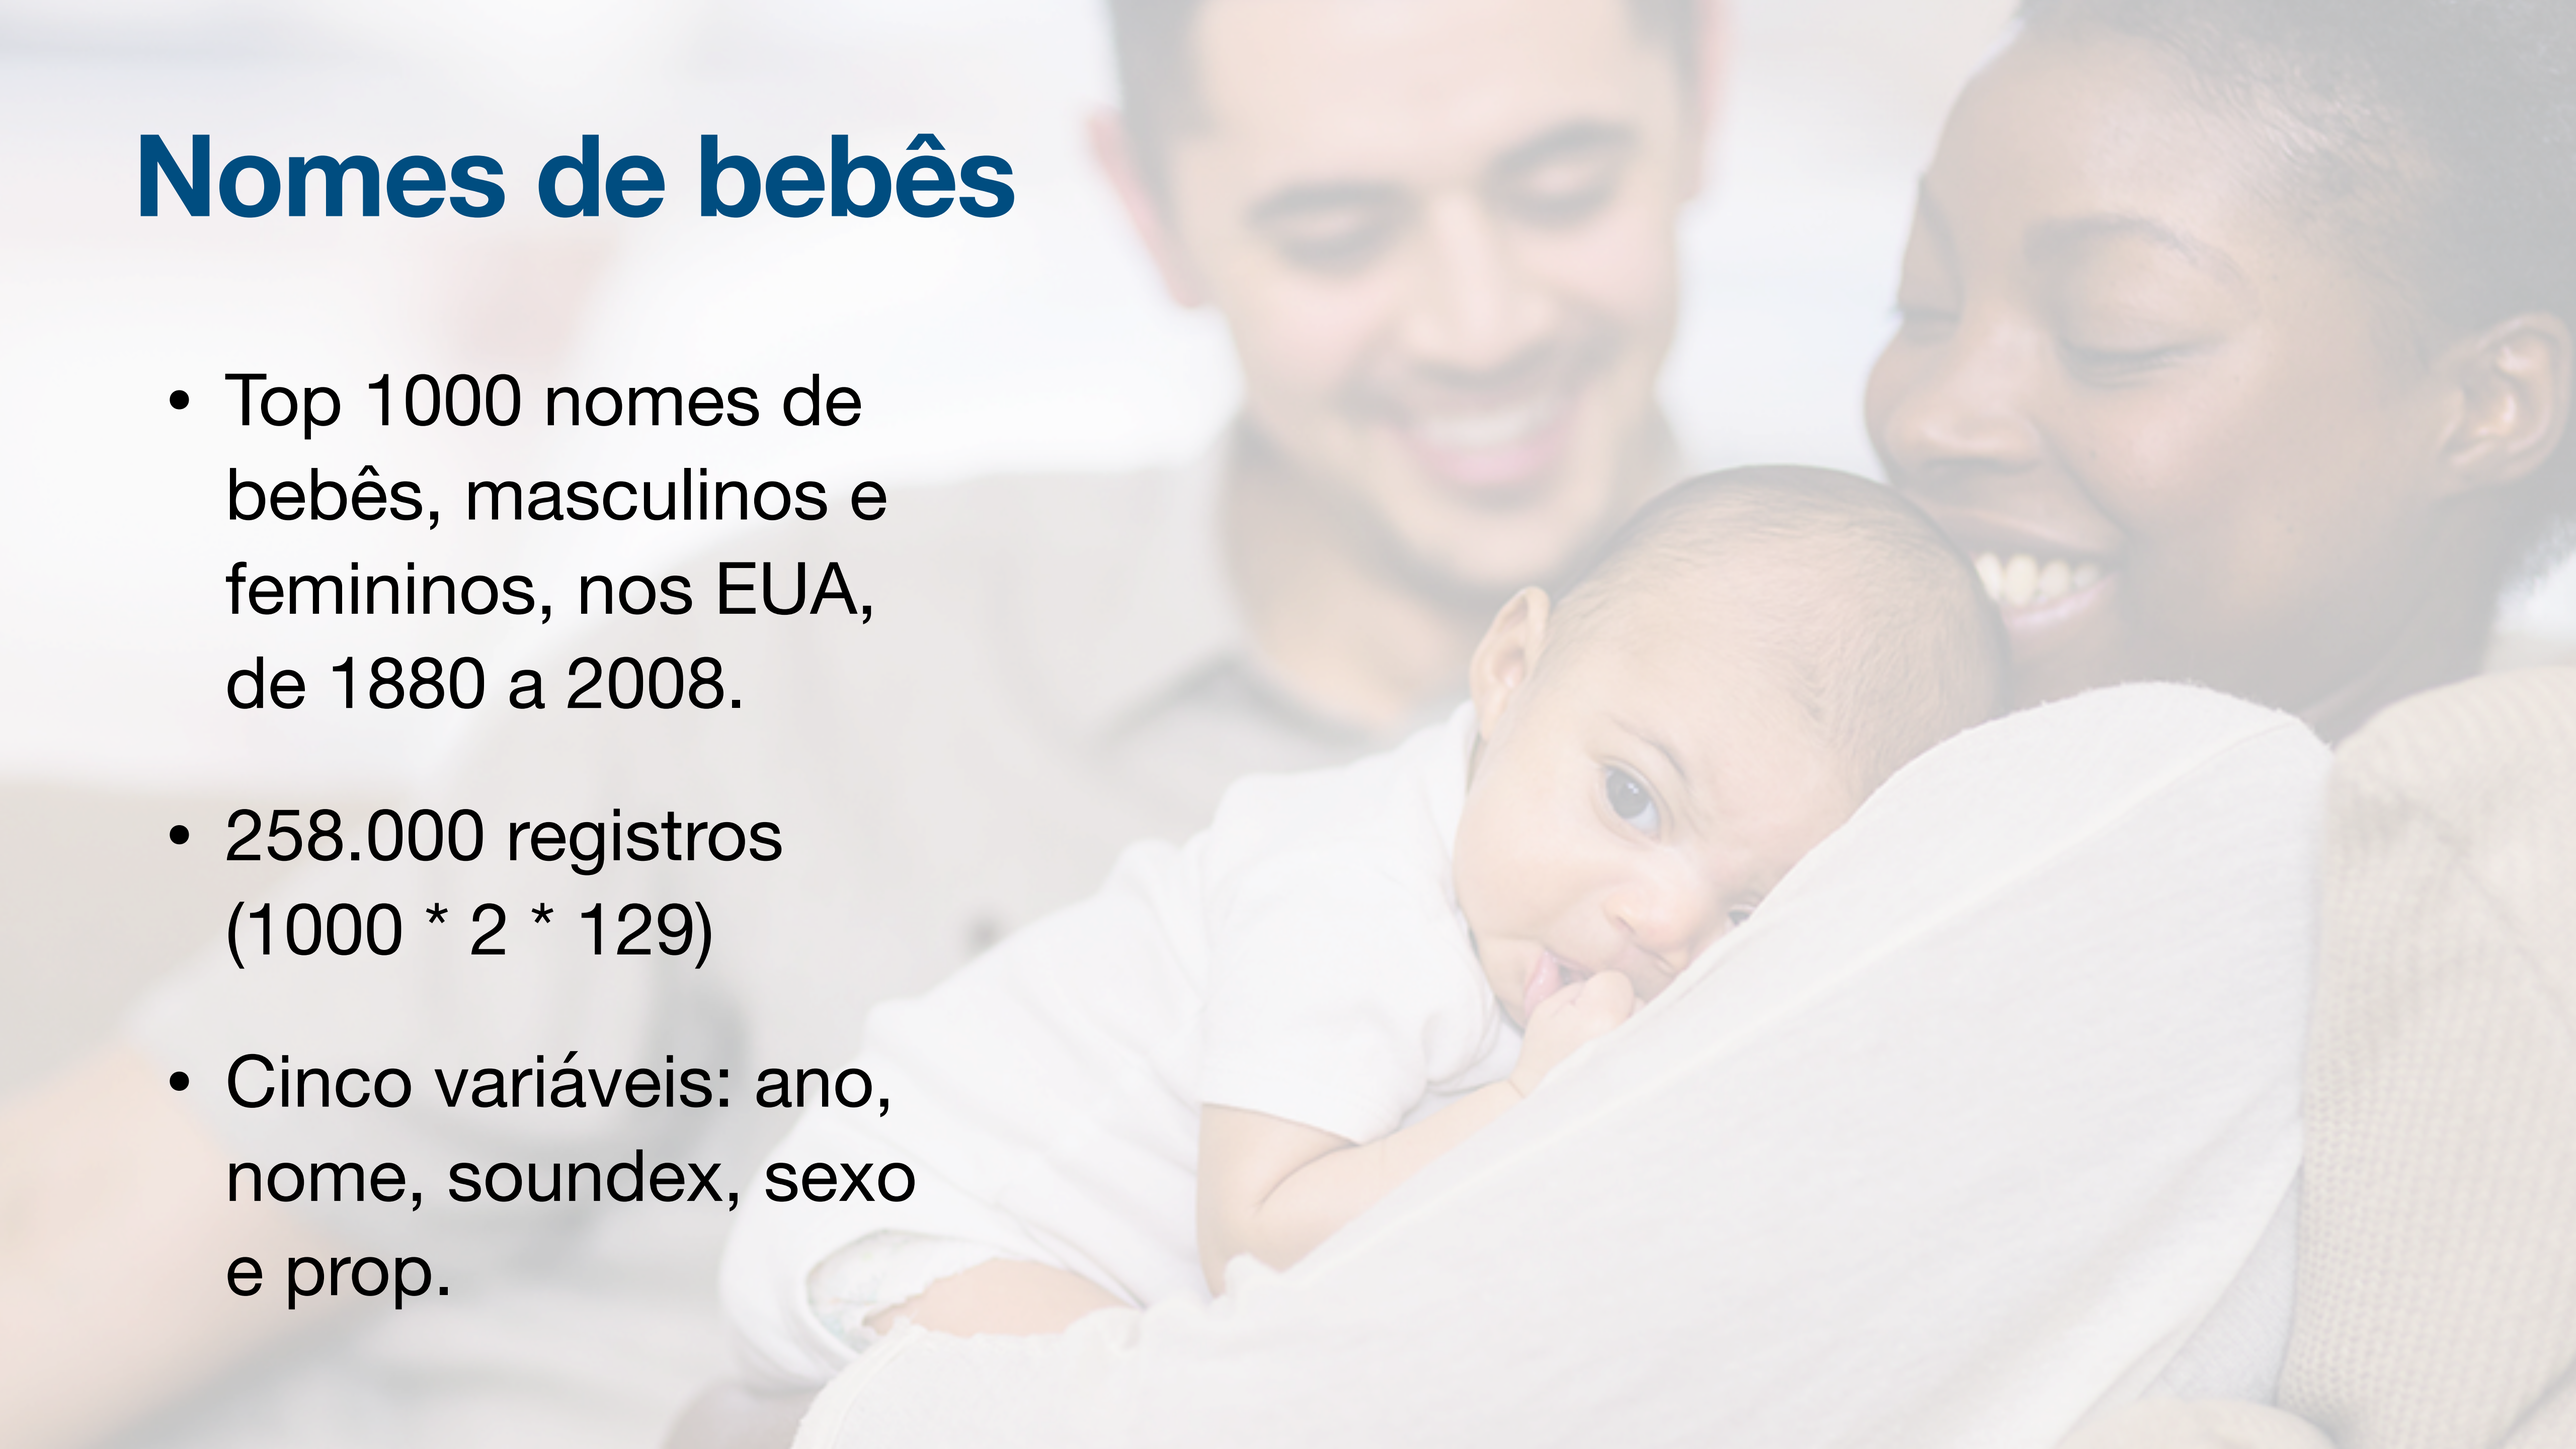
Transforme seus dados em informação

- Dados sobre nomes de bebês
- Manipulando bancos de dados

Dados sobre nomes de bebês

Nomes de bebês

- Top 1000 nomes de bebês, masculinos e femininos, nos EUA, de 1880 a 2008.
- 258.000 registros (1000 * 2 * 129)
- Cinco variáveis: ano, nome, soundex, sexo e prop.



Carregando os dados

```
bnames <- read.csv("bnames.csv.bz2")
```

```
> str(bnames)
'data.frame':       258000 obs. of  5 variables:
 $ year   : int  1880 1880 1880 1880 1880 1880 1880 1880 1880 1880 ...
 $ name   : chr  "John" "William" "James" "Charles" ...
 $ prop   : num  0.0815 0.0805 0.0501 0.0452 0.0433 ...
 $ sex    : chr  "boy" "boy" "boy" "boy" ...
 $ soundex: chr  "J500" "W450" "J520" "C642" ...
```

Carregando os dados

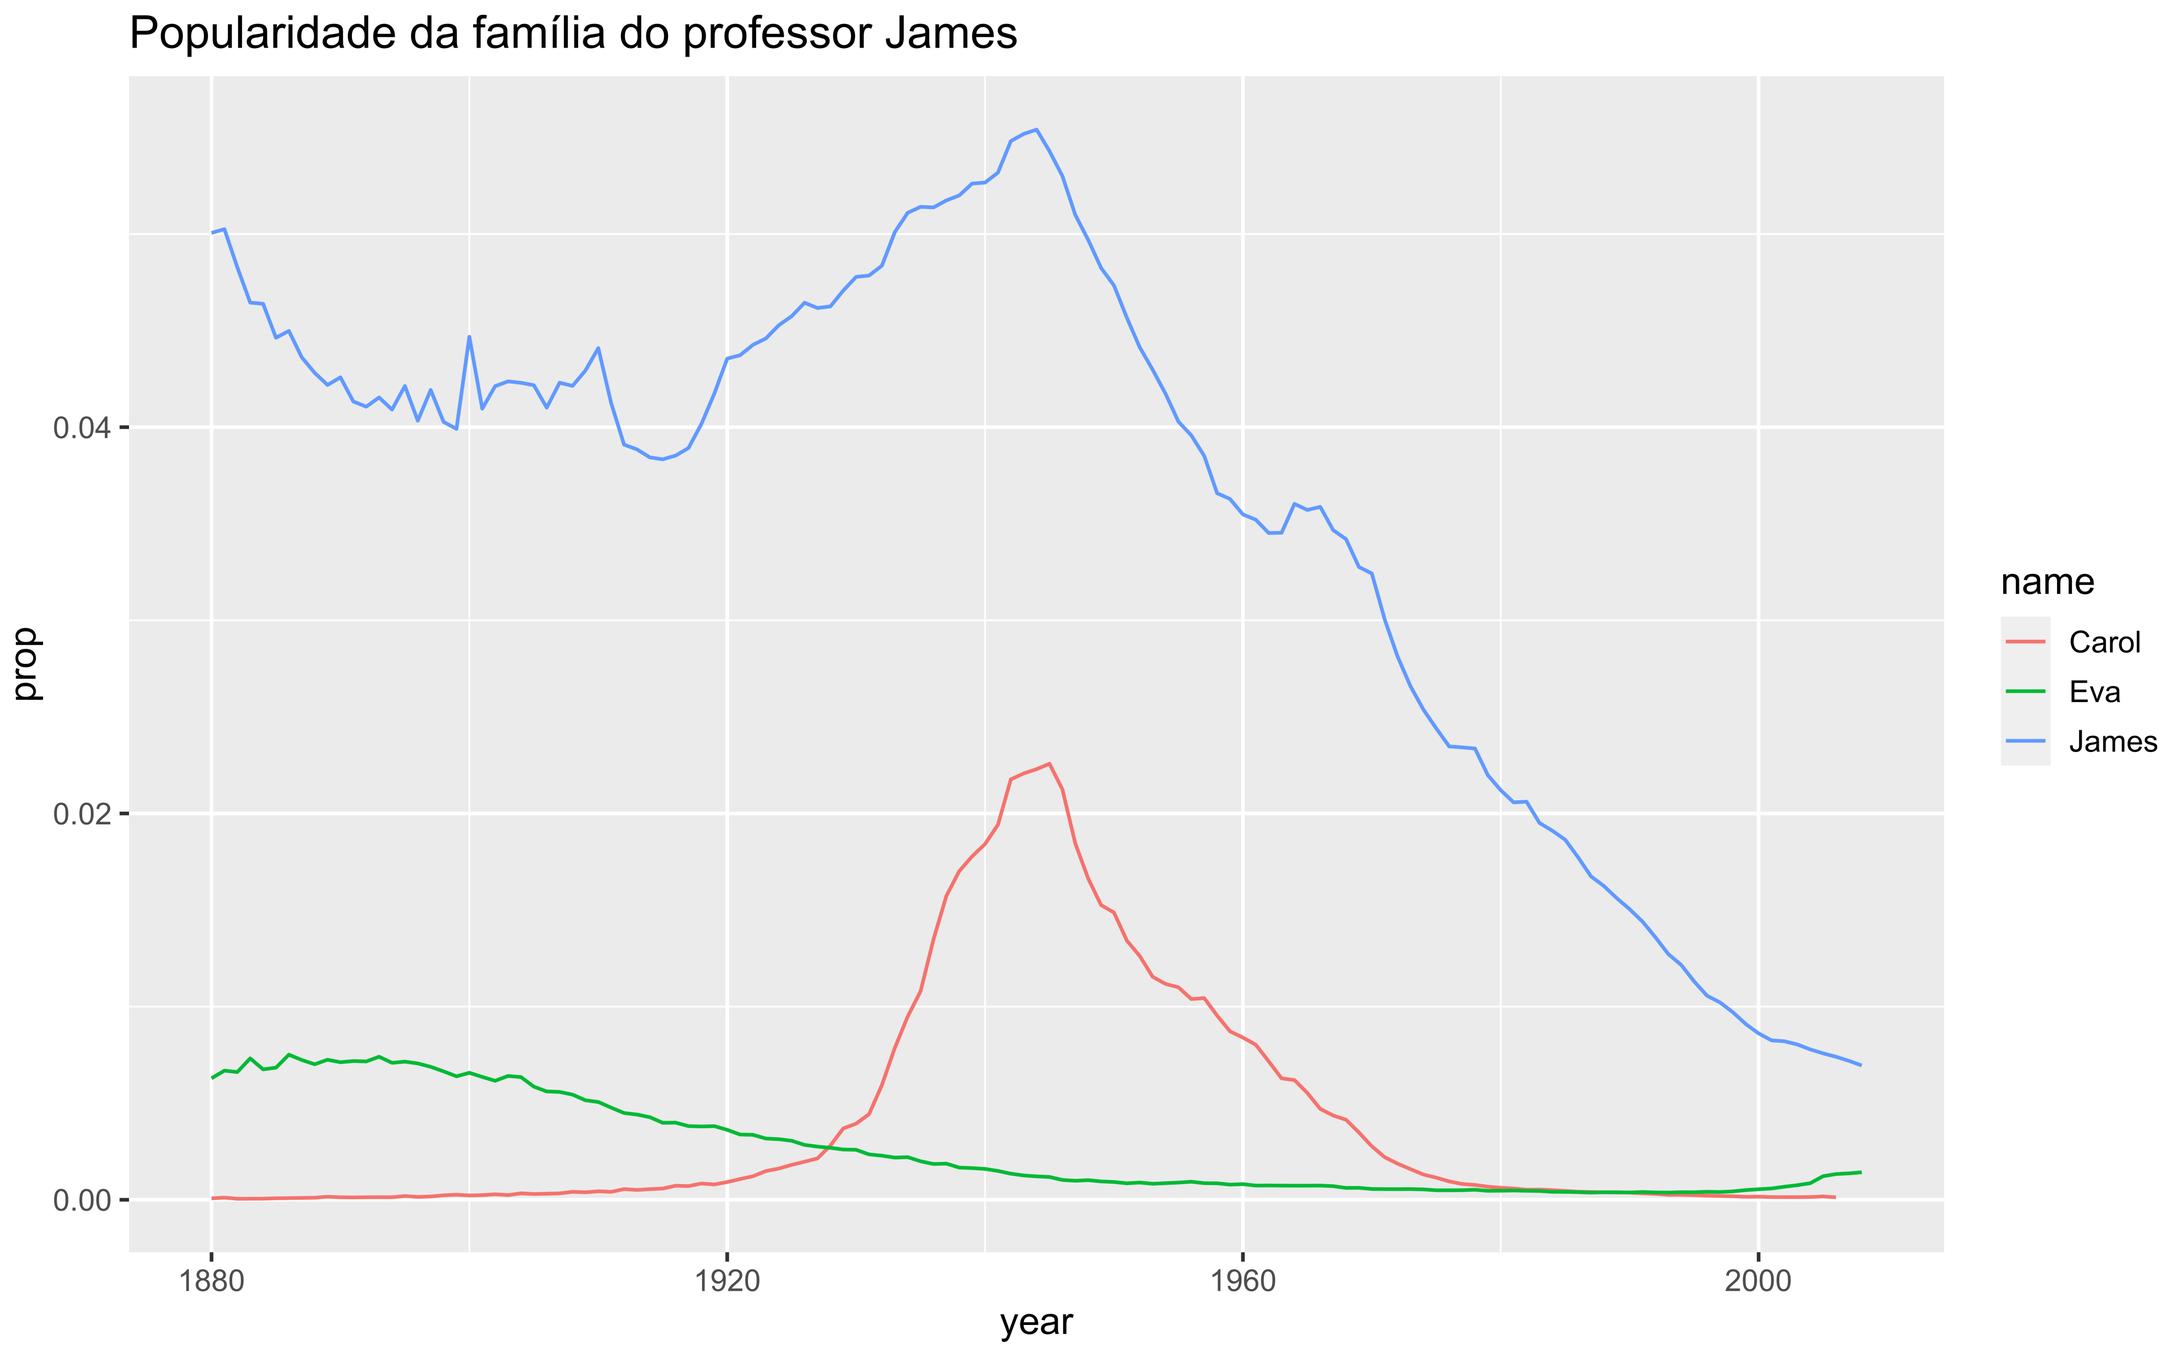
```
bnames <- read.csv("bnames.csv.bz2")
```

```
> head(bnames)
  year    name     prop sex soundex
1 1880    John 0.081541 boy    J500
2 1880 William 0.080511 boy    W450
3 1880   James 0.050057 boy    J520
4 1880 Charles 0.045167 boy    C642
5 1880  George 0.043292 boy    G620
6 1880   Frank 0.027380 boy    F652
```

Carregando os dados

```
bnames <- read.csv("bnames.csv.bz2")
```

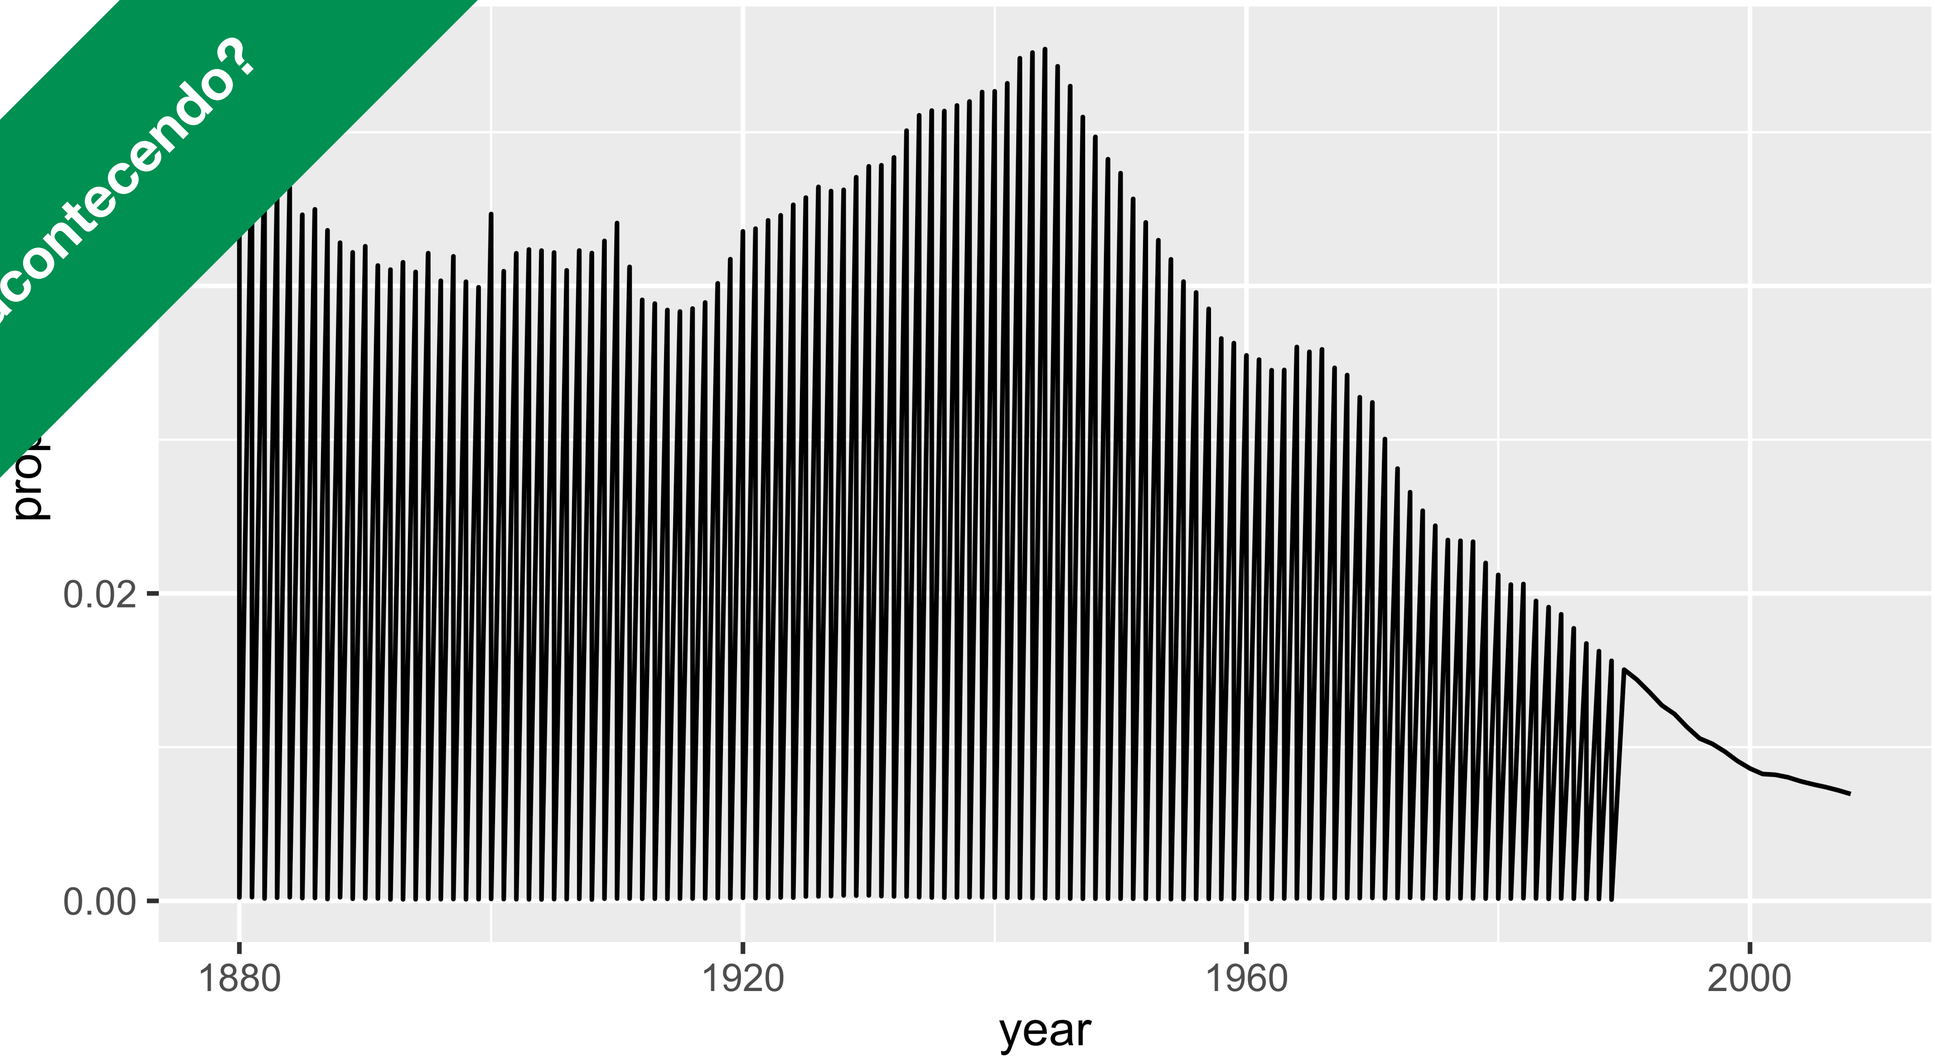
```
> tail(bnames)
        year      name      prop  sex soundex
257995 2008      Diya 0.000128 girl    D000
257996 2008 Carleigh 0.000128 girl    C642
257997 2008     Iyana 0.000128 girl    I500
257998 2008    Kenley 0.000127 girl    K540
257999 2008    Sloane 0.000127 girl    S450
258000 2008   Elianna 0.000127 girl    E450
```


Popularidade da família do professor James
prop
0.04
0.02
0.00
1880
1920
1960
2000
year
name
Carol
Eva
James

SUA VEZ

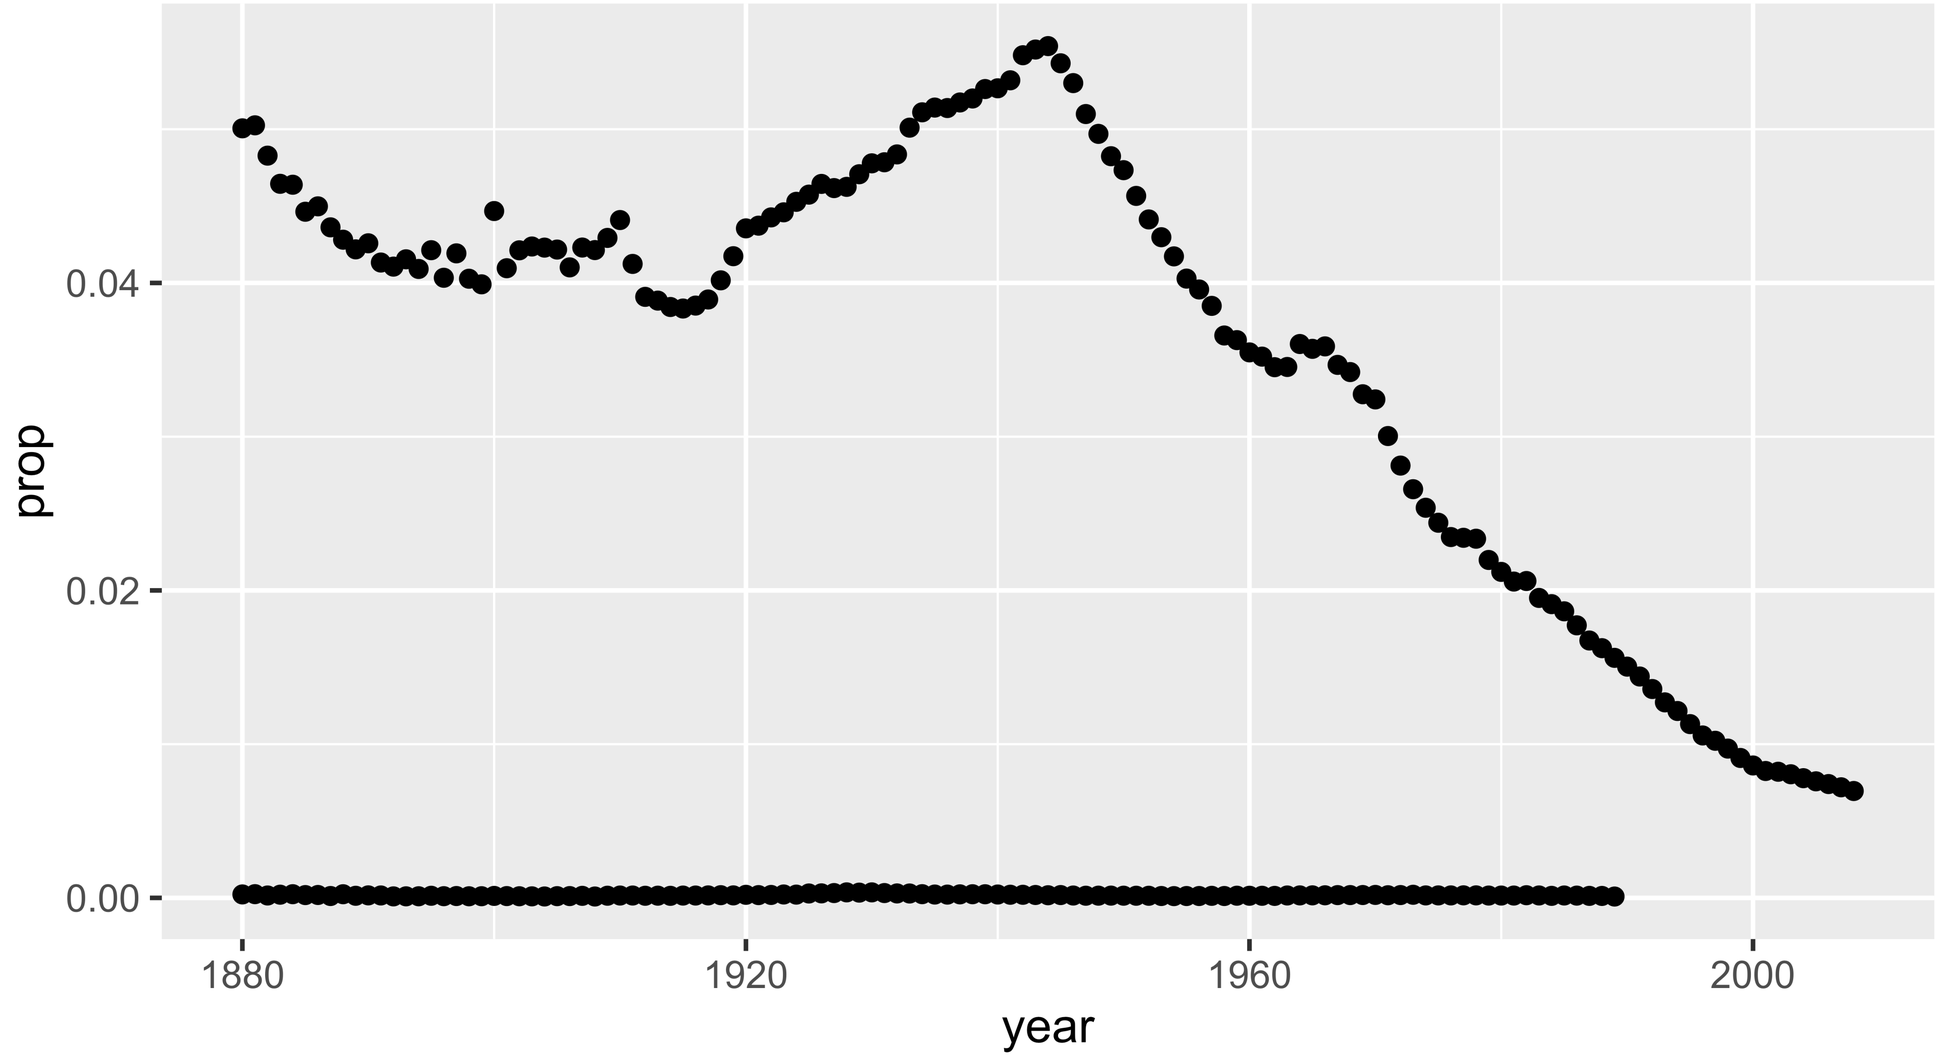
- Utilize filtros para extrair o seu nome do conjunto de dados.
- Plote a tendência ao longo dos anos.
  - *Que geometria você deve utilizar?*
  - *Será preciso alguma estética adicional?*

O que está acontecendo?



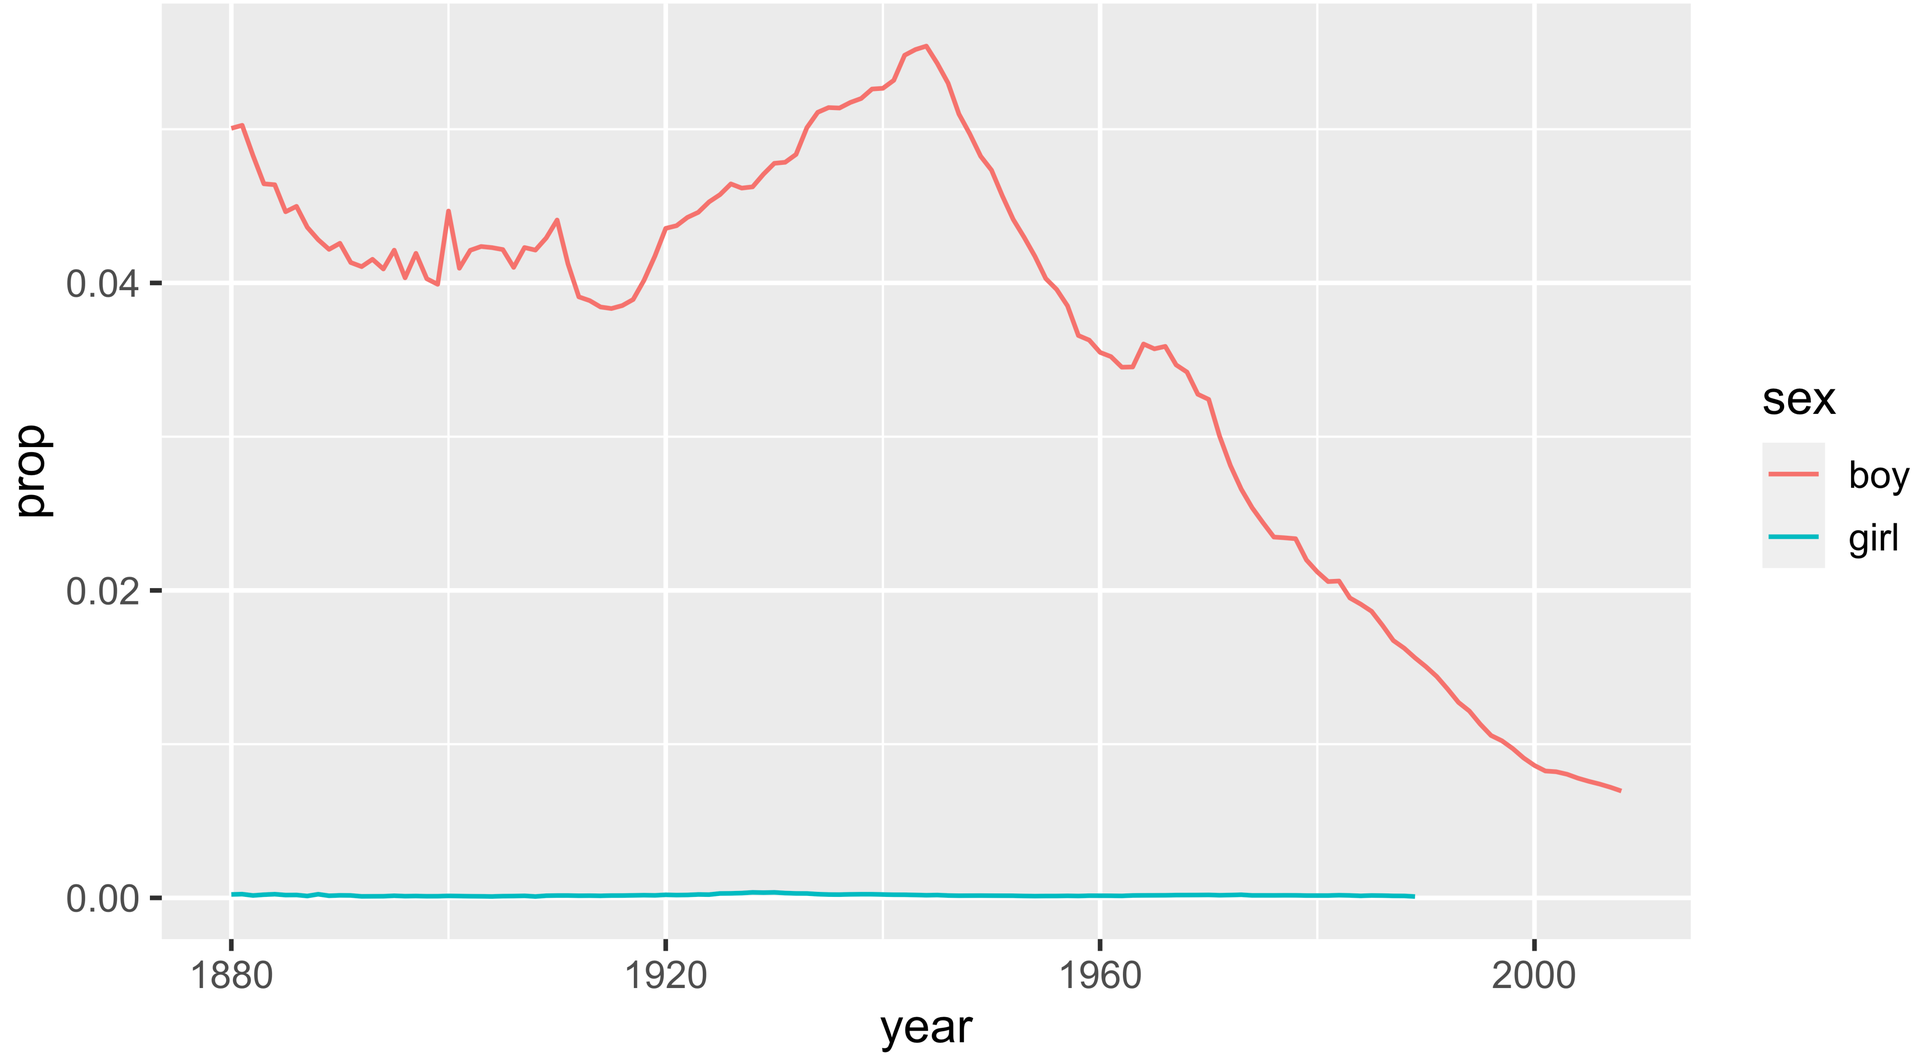

```
james <- bnames[ bnames$name == "James", ]

ggplot( james, aes(year, prop) ) + geom_line( )
```




```
james <- bnames[ bnames$name == "James", ]

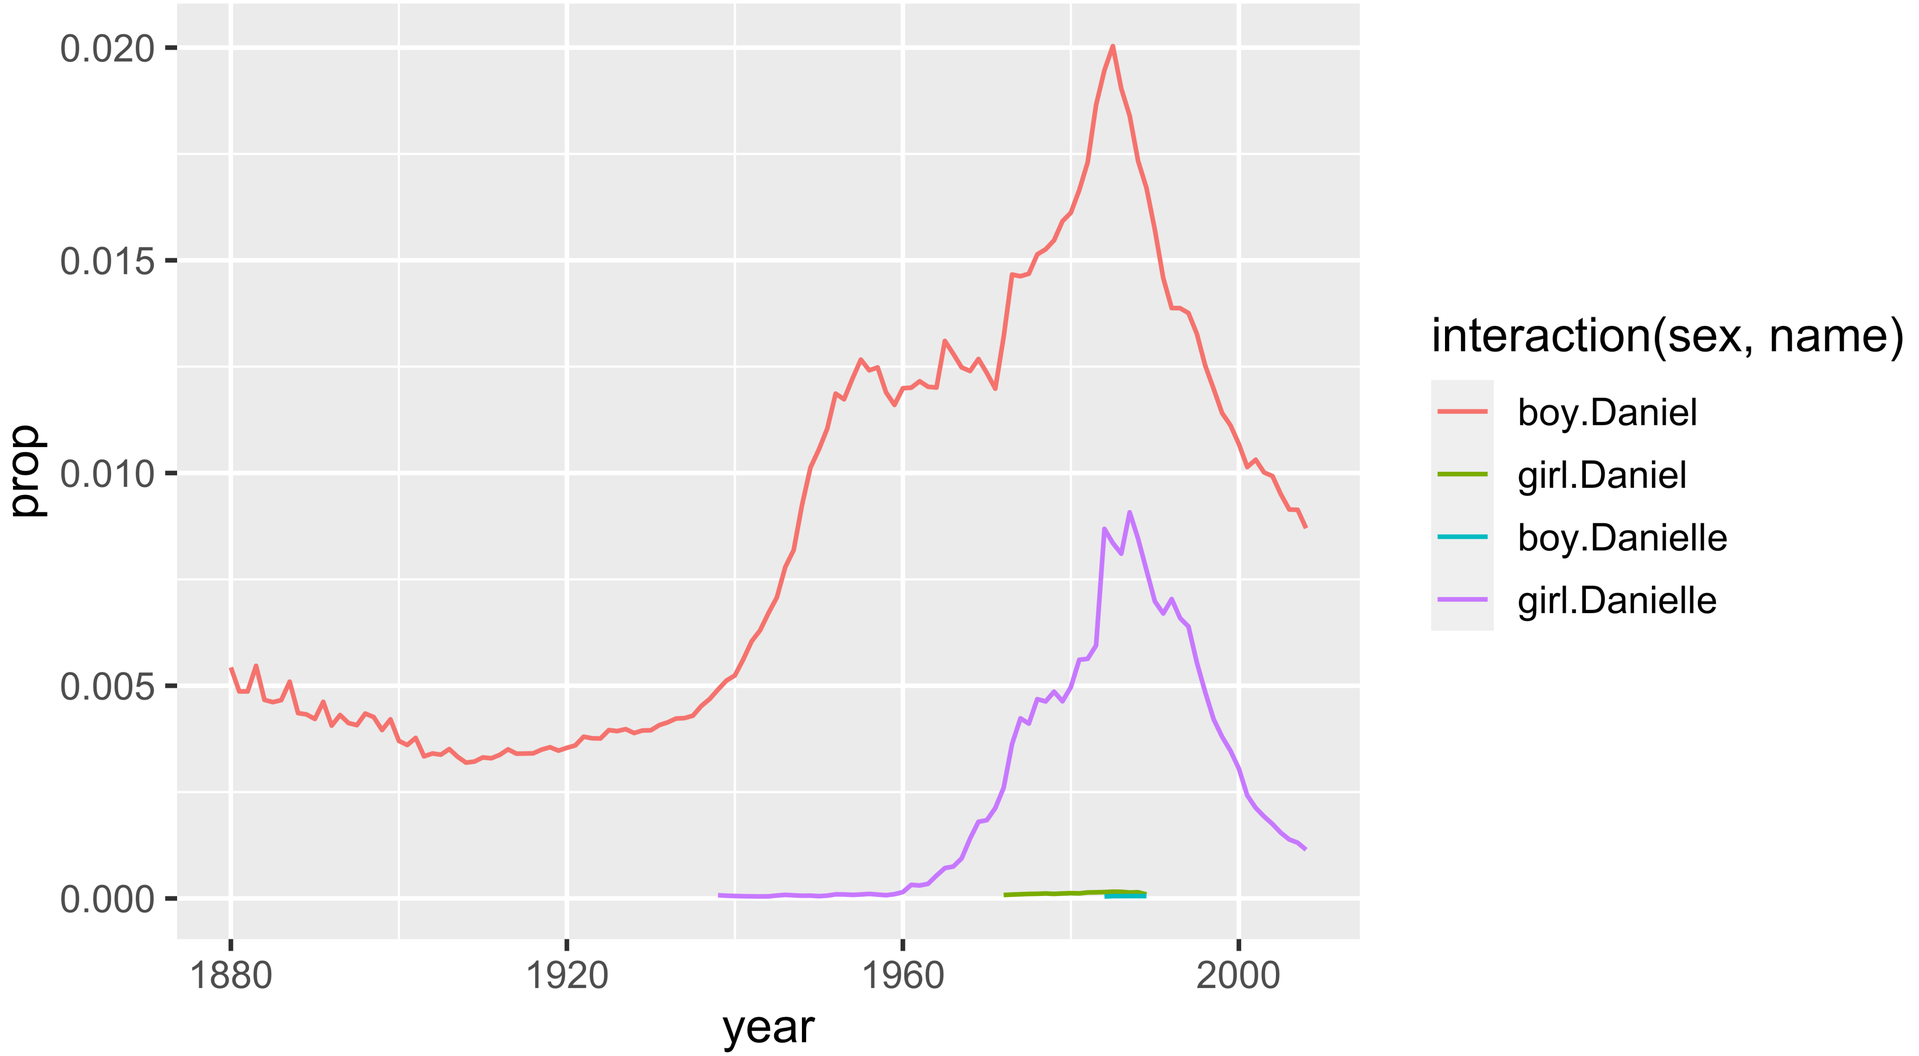
ggplot( james, aes(year, prop) ) + geom_point( )
```




```
james <- bnames[ bnames$name == "James", ]

ggplot( james, aes(year, prop) ) + geom_line( aes(color = sex) )
```

```
dans <- bnames[ bnames$name == "Daniel" |
  bnames$name == "Danielle", ]
```




```
ggplot( dans, aes(year, prop) ) +
  geom_line( aes( color = interaction(sex, name) ) )
```

dplyr

Manipulando bancos de dados

dplyr

- Um pacote do R para manipulação de dados
  - Mais fácil
  - Mais rápido
- Faz parte do `tidyverse`

filter
select
mutate
summarise
arrange



Estrutura

- O primeiro argumento é um data frame
- Os argumentos subsequentes dizem o que fazer com o data frame
- A saída é um data frame

```
df <- data.frame(
  Cor = c("Branco", "Branco", "Azul", "Azul", "Azul"),
  Valor = 1:5 )
```

filter

df

Cor	Valor
Branco	1
Branco	2
Azul	3
Azul	4
Azul	5



Cor	Valor
Azul	3
Azul	4
Azul	5

```
filter( df, Cor == "Azul" )
```

filter

df

Cor	Valor
Branco	1
Branco	2
Azul	3
Azul	4
Azul	5



Cor	Valor
Branco	2
Azul	4

```
filter( df, Valor %in% c(2, 4) )
```

SUA VEZ

- Utilize `filter` para extrair o nome de todas as garotas cujos anos de nascimento terminam com 00's

```
> bnames %>% filter( sex == "girl" &
+                      (year == 1900 | year == 2000) ) %>%
+   head()
  year       name     prop  sex soundex
1 1900       Mary 0.052567 girl    M600
2 1900      Helen 0.019953 girl    H450
3 1900       Anna 0.019236 girl    A500
4 1900   Margaret 0.016688 girl    M626
5 1900       Ruth 0.014989 girl    R300
6 1900 Elizabeth 0.012888 girl    E421
```

select

df

Cor	Valor
Branco	1
Branco	2
Azul	3
Azul	4
Azul	5



```
select( df, Cor )
```

Cor
Branco
Branco
Azul
Azul
Azul

select

df

Cor	Valor
Branco	1
Branco	2
Azul	3
Azul	4
Azul	5



```
select( df, !Cor )
```

Valor
1
2
3
4
5

- `filter` seleciona linhas segundo critérios
- `select` seleciona colunas por nomes

SUA VEZ

- Utilize `select` para extrair todas as colunas, exceto `soundex`. Mostre apenas as 6 primeiras linhas.

```
bnames %>%
  select( !soundex ) %>%
  head()
```

```
  year    name      prop sex
1 1880    John 0.081541 boy
2 1880 William 0.080511 boy
3 1880   James 0.050057 boy
4 1880 Charles 0.045167 boy
5 1880  George 0.043292 boy
6 1880   Frank 0.027380 boy
```

arrange

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



```
arrange( df, Valor )
```

Cor	Valor
Ice	1
Sky	2
Aqua	3
Ocean	4
Night	5

arrange

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



```
arrange( df, desc(Valor) )
```

Cor	Valor
Night	5
Ocean	4
Aqua	3
Sky	2
Ice	1

arrange

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



```
arrange( df, Cor )
```

Cor	Valor
Aqua	3
Ice	1
Night	5
Ocean	4
Sky	2

SUA VEZ

- Reordene o banco `bnames` da maior para a menor proporção. Qual nome foi o mais popular, para um ano, ao longo desse período?

```
bnames %>%
  arrange( desc(prop) ) %>%
  head()
```

```
  year    name      prop sex soundex
1 1880    John 0.081541 boy    J500
2 1881    John 0.080975 boy    J500
3 1880 William 0.080511 boy    W450
4 1883    John 0.079066 boy    J500
5 1881 William 0.078712 boy    W450
6 1882    John 0.078314 boy    J500
```

SUA VEZ

- Em que ano o seu nome foi mais popular?

```
james %>%
  arrange( desc(prop) ) %>%
  head()
```

	year	name	prop	sex	soundex
1	1944	James	0.055406	boy	J520
2	1943	James	0.055183	boy	J520
3	1942	James	0.054812	boy	J520
4	1945	James	0.054288	boy	J520
5	1941	James	0.053182	boy	J520
6	1946	James	0.052999	boy	J520

mutate

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



Cor	Valor	Dobro
Ocean	4	8
Ice	1	2
Sky	2	4
Night	5	10
Aqua	3	6

```
mutate( df, Dobro = 2 * Valor )
```

mutate

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



Cor	Valor	Dobro	Quadruplo
Ocean	4	8	16
Ice	1	2	4
Sky	2	4	8
Night	5	10	20
Aqua	3	6	12

```
mutate( df, Dobro = 2 * Valor,
  Quadruplo = 2 * Dobro )
```

summarise

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



Total
15

```
summarise( df, Total = sum(Valor) )
```

summarise

df

Cor	Valor
Ocean	4
Ice	1
Sky	2
Night	5
Aqua	3



Total	Media
15	3

```
summarise( df, Total = sum(Valor),
 Media = mean(Valor) )
```

- `arrange` reordena linhas
- `mutate` adiciona novas variáveis
- `summarise` resume variáveis em medidas

SUA VEZ

- A partir do banco de dados relativo ao seu nome:

  1. Adicione uma nova variável que mostre a proporção em percentual.

```
james <- james %>%
  mutate( perc = prop * 100 )
```

SUA VEZ

- A partir do banco de dados relativo ao seu nome:

  1. Adicione uma nova variável que mostre a proporção em percentual.

```
james %>%
  head()
```

	year	name	prop	sex	soundex	perc
3	1880	James	0.050057	boy	J520	5.0057
1003	1881	James	0.050253	boy	J520	5.0253
2003	1882	James	0.048281	boy	J520	4.8281
3003	1883	James	0.046449	boy	J520	4.6449
4003	1884	James	0.046389	boy	J520	4.6389
5003	1885	James	0.044632	boy	J520	4.4632

SUA VEZ

- A partir do banco de dados relativo ao seu nome:

  2. Crie um resumo que mostre o mínimo, a média e o máximo da proporção para o seu nome.

```
james %>%
  summarise( min = min(prop),
             mean = mean(prop),
             max = max(prop) )
```

	min	mean	max
1	0.044632	0.04767683	0.050253

SUA VEZ

- A partir do banco de dados relativo ao seu nome:

  3. Crie um resumo que mostre o mínimo, a média e o máximo do percentual para o seu nome.

```
james %>%
  summarise( min = min(perc),
             mean = mean(perc),
             max = max(perc) )
```

```
      min     mean    max
1 4.4632 4.767683 5.0253
```

Resumo

- `filter` seleciona linhas segundo critérios
- `select` seleciona colunas por nomes
- `arrange` reordena linhas
- `mutate` adiciona novas variáveis
- `summarise` resume variáveis em medidas

Combine bancos de dados



Nascimentos

- O número de meninos e meninas nascidos a cada ano de 1880 a 2009
- 260 registros (2 * 130)
- Três variáveis: ano, sexo, nascimentos

```
births <- read.csv("births.csv")
```

```
> head(bnames)
  year     name      prop sex soundex
1 1880     John 0.081541 boy    J500
2 1880  William 0.080511 boy    W450
3 1880    James 0.050057 boy    J520
4 1880  Charles 0.045167 boy    C642
5 1880   George 0.043292 boy    G620
6 1880    Frank 0.027380 boy    F652
```

```
> head(births)
  year sex births
1 1880 boy 118405
2 1881 boy 108290
3 1882 boy 122034
4 1883 boy 112487
5 1884 boy 122745
6 1885 boy 115948
```

Como você combinaria esses conjuntos de dados?

Descreva uma estratégia

Combinando conjuntos de dados

```
x <- data.frame(
  name = c("John", "Paul", "George", "Ringo", "Gene", "Jimmy"),
  instrument = c("guitar", "bass", "guitar", "drums", "bass", "guitar")
  )


y <- data.frame(
  name = c("John", "Paul", "George", "Ringo", "Brian"),
  band = c("TRUE", "TRUE", "TRUE",  "TRUE", "FALSE")
  )
```

Combinando conjuntos de dados

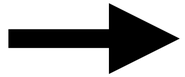
x

name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums
Gene	bass
Jimmy	guitar

+

y

name	band
John	TRUE
Paul	TRUE
George	TRUE
Ringo	TRUE
Brian	FALSE





Combinando conjuntos de dados

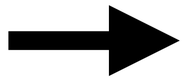
x

name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums
Gene	bass
Jimmy	guitar

+

y

name	band
John	TRUE
Paul	TRUE
George	TRUE
Ringo	TRUE
Brian	FALSE



name	instrument	band
John	guitar	TRUE
Paul	bass	TRUE
George	guitar	TRUE
Ringo	drums	TRUE
Gene	bass	NA
Jimmy	guitar	NA

```
left_join(x, y, by = "name")
```

Combinando conjuntos de dados

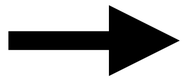
x

name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums
Gene	bass
Jimmy	guitar

+

y

name	band
John	TRUE
Paul	TRUE
George	TRUE
Ringo	TRUE
Brian	FALSE



name	instrument	band
John	guitar	TRUE
Paul	bass	TRUE
George	guitar	TRUE
Ringo	drums	TRUE

```
inner_join(x, y, by = "name")
```

Combinando conjuntos de dados

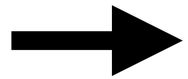
x

name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums
Gene	bass
Jimmy	guitar

+

y

name	band
John	TRUE
Paul	TRUE
George	TRUE
Ringo	TRUE
Brian	FALSE



name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums

```
semi_join(x, y, by = "name")
```

Combinando conjuntos de dados

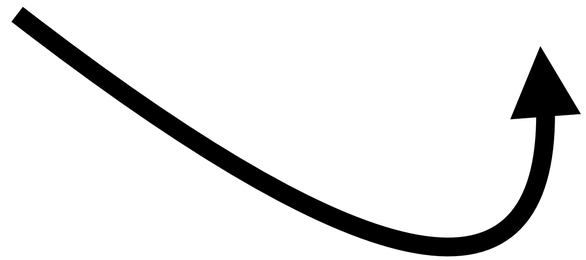
x

name	instrument
John	guitar
Paul	bass
George	guitar
Ringo	drums
Gene	bass
Jimmy	guitar

+

y

name	band
John	TRUE
Paul	TRUE
George	TRUE
Ringo	TRUE
Brian	FALSE



name	instrument
Gene	bass
Jimmy	guitar

```
anti_join(x, y, by = "name")
```

Comando	Ação
`left_join`	Inclui todas as linhas de x e as linhas correspondentes de y
`inner_join`	Inclui as linhas de x que aparecem em y e as linhas correspondentes de y
`semi_join`	Inclui as linhas de x que aparecem em y
`anti_join`	inclui as linhas de x que não aparecem em y

SUA VEZ

- Combine `bnames` com `births` (nomeie `bnames2`) e crie uma nova coluna que mostre o número total de bebês nascidos em cada ano para cada nome.

```
> head(bnames)
  year     name      prop sex soundex
1 1880     John 0.081541 boy    J500
2 1880  William 0.080511 boy    W450
3 1880    James 0.050057 boy    J520
4 1880  Charles 0.045167 boy    C642
5 1880   George 0.043292 boy    G620
6 1880    Frank 0.027380 boy    F652
```

```
> head(births)
  year sex births
1 1880 boy 118405
2 1881 boy 108290
3 1882 boy 122034
4 1883 boy 112487
5 1884 boy 122745
6 1885 boy 115948
```

SUA VEZ

- Combine `bnames` com `births` (nomeie `bnames2`) e crie uma nova coluna que mostre o número total de bebês nascidos em cada ano para cada nome.

```
bnames2 <- bnames %>%
  left_join( births, by = c("year", "sex") ) %>%
  mutate( n = round(prop * births) )
```

```
> head(bnames2, 18)
    year         name     prop sex soundex births    n
1   1880         John 0.081541 boy    J500 118405 9655
2   1880      William 0.080511 boy    W450 118405 9533
3   1880        James 0.050057 boy    J520 118405 5927
4   1880      Charles 0.045167 boy    C642 118405 5348
5   1880       George 0.043292 boy    G620 118405 5126
6   1880        Frank 0.027380 boy    F652 118405 3242
7   1880       Joseph 0.022229 boy    J210 118405 2632
8   1880       Thomas 0.021401 boy    T520 118405 2534
9   1880        Henry 0.020641 boy    H560 118405 2444
10  1880       Robert 0.020404 boy    R163 118405 2416
11  1880       Edward 0.019965 boy    E363 118405 2364
12  1880        Harry 0.018175 boy    H600 118405 2152
13  1880       Walter 0.014822 boy    W436 118405 1755
14  1880       Arthur 0.013504 boy    A636 118405 1599
15  1880         Fred 0.013251 boy    F630 118405 1569
16  1880       Albert 0.012609 boy    A416 118405 1493
17  1880       Samuel 0.008648 boy    S540 118405 1024
18  1880        David 0.007339 boy    D130 118405  869
```

```
> tail(bnames2, 18)
        year     name     prop  sex soundex  births   n
257983 2008  Desirae 0.000130 girl    D260 2072756 269
257984 2008   Kianna 0.000130 girl    K500 2072756 269
257985 2008   Laurel 0.000130 girl    L640 2072756 269
257986 2008   Neveah 0.000130 girl    N100 2072756 269
257987 2008   Amaris 0.000129 girl    A562 2072756 267
257988 2008 Hadassah 0.000129 girl    H320 2072756 267
257989 2008    Dania 0.000129 girl    D500 2072756 267
257990 2008   Hailie 0.000129 girl    H400 2072756 267
257991 2008   Jamiya 0.000129 girl    J500 2072756 267
257992 2008    Kathy 0.000129 girl    K300 2072756 267
257993 2008   Laylah 0.000129 girl    L400 2072756 267
257994 2008     Riya 0.000129 girl    R000 2072756 267
257995 2008     Diya 0.000128 girl    D000 2072756 265
257996 2008 Carleigh 0.000128 girl    C642 2072756 265
257997 2008    Iyana 0.000128 girl    I500 2072756 265
257998 2008   Kenley 0.000127 girl    K540 2072756 263
257999 2008   Sloane 0.000127 girl    S450 2072756 263
258000 2008  Elianna 0.000127 girl    E450 2072756 263
```

group_by

Operações agrupadas



Número total de nascidos por nome?

1	Aaden	959
2	Aaliyah	39665
3	Aarav	219
4	Aaron	509464
5	Ab	25
6	Abagail	2682
7	Abb	16
⋮		
6776	Zoey	19341
6777	Zoie	4694
6778	Zola	4874
6779	Zollie	63
6780	Zona	3250
6781	Zora	4578
6782	Zula	3602

Você possui informação suficiente para obter esses valores?

Lembre-se

df

Cor	Valor
Blue	4
Red	1
Blue	2
Blue	5
Red	3



Total
15

```
summarise( df, Total = sum(Valor) )
```

Já sabemos fazer para uma variável completa

```
james <- filter( bnames2, name == "James" )
```

```
sum(james$n)
```

```
[1] 5043259
```

```
james %>%
  summarise( total = sum(n) )
```

```
     total
1 5043259
```

Por cor ?

df

Cor	Valor
Blue	4
Red	1
Blue	2
Blue	5
Red	3



Cor	Total
Blue	11
Red	4

```
df %>%
  group_by( Cor ) %>%
  summarise( Total = sum(Valor) )
```

SUA VEZ

- Agrupe `bnames2` por nome e verifique as 6 primeiras linhas.

```
bnames2 %>%
  group_by( name ) %>%
  head()
```



```
# A tibble: 6 × 7
# Groups:   name [6]
   year name       prop sex   soundex births     n
  <int> <chr>     <dbl> <chr> <chr>     <int> <dbl>
1  1880 John    0.0815 boy   J500     118405  9655
2  1880 William 0.0805 boy   W450     118405  9533
3  1880 James   0.0501 boy   J520     118405  5927
4  1880 Charles 0.0452 boy   C642     118405  5348
5  1880 George  0.0433 boy   G620     118405  5126
6  1880 Frank   0.0274 boy   F652     118405  3242
```

SUA VEZ

- Agrupe `bnames2` por nome e verifique o total registrado para cada nome ao longo dos anos

```
bnames2 %>%
  group_by( name ) %>%
  summarise( total = sum(n) )
```

```
# A tibble: 6,782 × 2
   name      total
   <chr>     <dbl>
 1 Aaden       959
 2 Aaliyah   39665
 3 Aarav       219
 4 Aaron    509464
 5 Ab           25
 6 Abagail    2682
 7 Abb          16
 8 Abbey      14348
 9 Abbie      16622
10 Abbigail    6800
# … with 6,772 more rows
# ℹ Use `print(n = ...)` to see
more rows
```

SUA VEZ

- Repita o passo anterior, por ordem decrescente de popularidade

```
bnames2 %>%
  group_by( name ) %>%
  summarise( total = sum(n) ) %>%
  arrange( desc(total) )
```

```
# A tibble: 6,782 × 2
   name      total
   <chr>     <dbl>
 1 James   5043259
 2 John    5036828
 3 Robert  4771447
 4 Michael 4226596
 5 Mary    4111514
 6 William 3966170
 7 David   3506995
 8 Richard 2542864
 9 Joseph  2498276
10 Charles 2331143
# ℹ 6,772 more rows
# ℹ Use `print(n = ...)` to see
more rows
```

tibble



tibble

- `tibble` é um tipo especial de data frame que pode ser manipulado de maneira mais fácil

```
class( bnames )
[1] "data.frame"

class( births )
[1] "data.frame"
```

tibble

- `tibble` é um tipo especial de data frame que pode ser manipulado de maneira mais fácil

```
bnames <- tibble( bnames )
births <- tibble( births )


class( bnames )
[1] "tbl_df"     "tbl"        "data.frame"

class( births )
[1] "tbl_df"     "tbl"        "data.frame"
```

tibble

- `tibble` é um tipo especial de data frame que pode ser manipulado de maneira mais fácil

- Se algum comando do pacote `dplyr` for utilizado em um data frame, automaticamente, o formato `tibble` será assinalado para o resultado

Interações



Interações

- Utilize agrupamento de múltiplas variáveis para visualizar interações entre essas variáveis.

```
bnames2 %>%
  group_by( name, sex ) %>%
  summarise( total = sum(n) )
```

```
# A tibble: 7,455 × 3
# Groups:   name [6,782]
   name    sex    total
   <chr>   <chr>  <dbl>
 1 Aaden   boy      959
 2 Aaliyah girl   39665
 3 Aarav   boy      219
 4 Aaron   boy   508094
 5 Aaron   girl    1370
 6 Ab      boy       25
 7 Abagail girl    2682
 8 Abb     boy       16
 9 Abbey   girl   14348
10 Abbie   boy       10
# … with 7,445 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Exercícios



Calcule o número total de bebês para cada soundex.

```
bnames2 %>%
  group_by( soundex ) %>%
  summarise( total = sum(n) )
```

```
# A tibble: 1,392 × 2
   soundex  total
   <chr>    <dbl>
 1 A000        11
 2 A100    193837
 3 A120     15652
 4 A124    256458
 5 A130        11
 6 A134      5181
 7 A135       901
 8 A140     30815
 9 A146        69
10 A150         6
# … with 1,382 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Qual soundex é o mais popular ?

```
bnames2 %>%
  group_by( soundex ) %>%
  summarise( total = sum(n) ) %>%
  arrange( desc(total) )
```

```
# A tibble: 1,392 × 2
   soundex   total
   <chr>     <dbl>
 1 J500    9991737
 2 M240    5823791
 3 M600    5553703
 4 J520    5524958
 5 R163    5047182
 6 W450    4116109
 7 C623    4016919
 8 J200    3859240
 9 D500    3774287
10 D130    3506995
# … with 1,382 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Quais nomes pertencem ao soundex mais popular ?

Dica: o comando `unique()`

mostra os elementos únicos de um conjunto

Quais nomes pertencem ao soundex mais popular ?

```
bnames2 %>%
  filter( soundex == "J500" ) %>%
  select( name ) %>%
  unique()
```

```
[1] "John"     "Jim"      "Juan"     "Jimmie"   "Johnnie"  "Johnny"   "Johnie"   "Jean"     "June"
[10] "Jonah"    "Jennie"   "Jimmy"    "Johny"    "Jonnie"   "Johney"   "Jamie"    "Jon"      "Joan"
[19] "Jan"      "Jame"     "Jaime"    "Jamey"    "Jaimie"   "Jammie"   "Jayme"    "Juwan"    "Johan"
[28] "Jaheim"   "Jahiem"   "Jaheem"   "Jane"     "Janie"    "Johanna"  "Joanna"   "Jannie"   "Jenny"
[37] "Jeanne"   "Johannah" "Juana"    "Junie"    "Jinnie"   "Jeanie"   "Jeannie"  "Junia"    "Janey"
[46] "Jeane"    "Joanne"   "Joann"    "Jayne"    "Jana"     "Janna"    "Jann"     "Joni"     "Joanie"
[55] "Jeanna"   "Jami"     "Johnna"   "Jeana"    "Jonna"    "Jena"     "Jenni"    "Jenna"    "Janae"
[64] "Jaimee"   "Janay"    "Joana"    "Janiya"   "Johana"   "Jamya"    "Janiyah"  "Janiah"   "Jamiya"
```

Calcule o número total de meninos e meninas por ano.

```
bnames2 %>%
  group_by( year, sex ) %>%
  summarise( births = sum(n) )
```

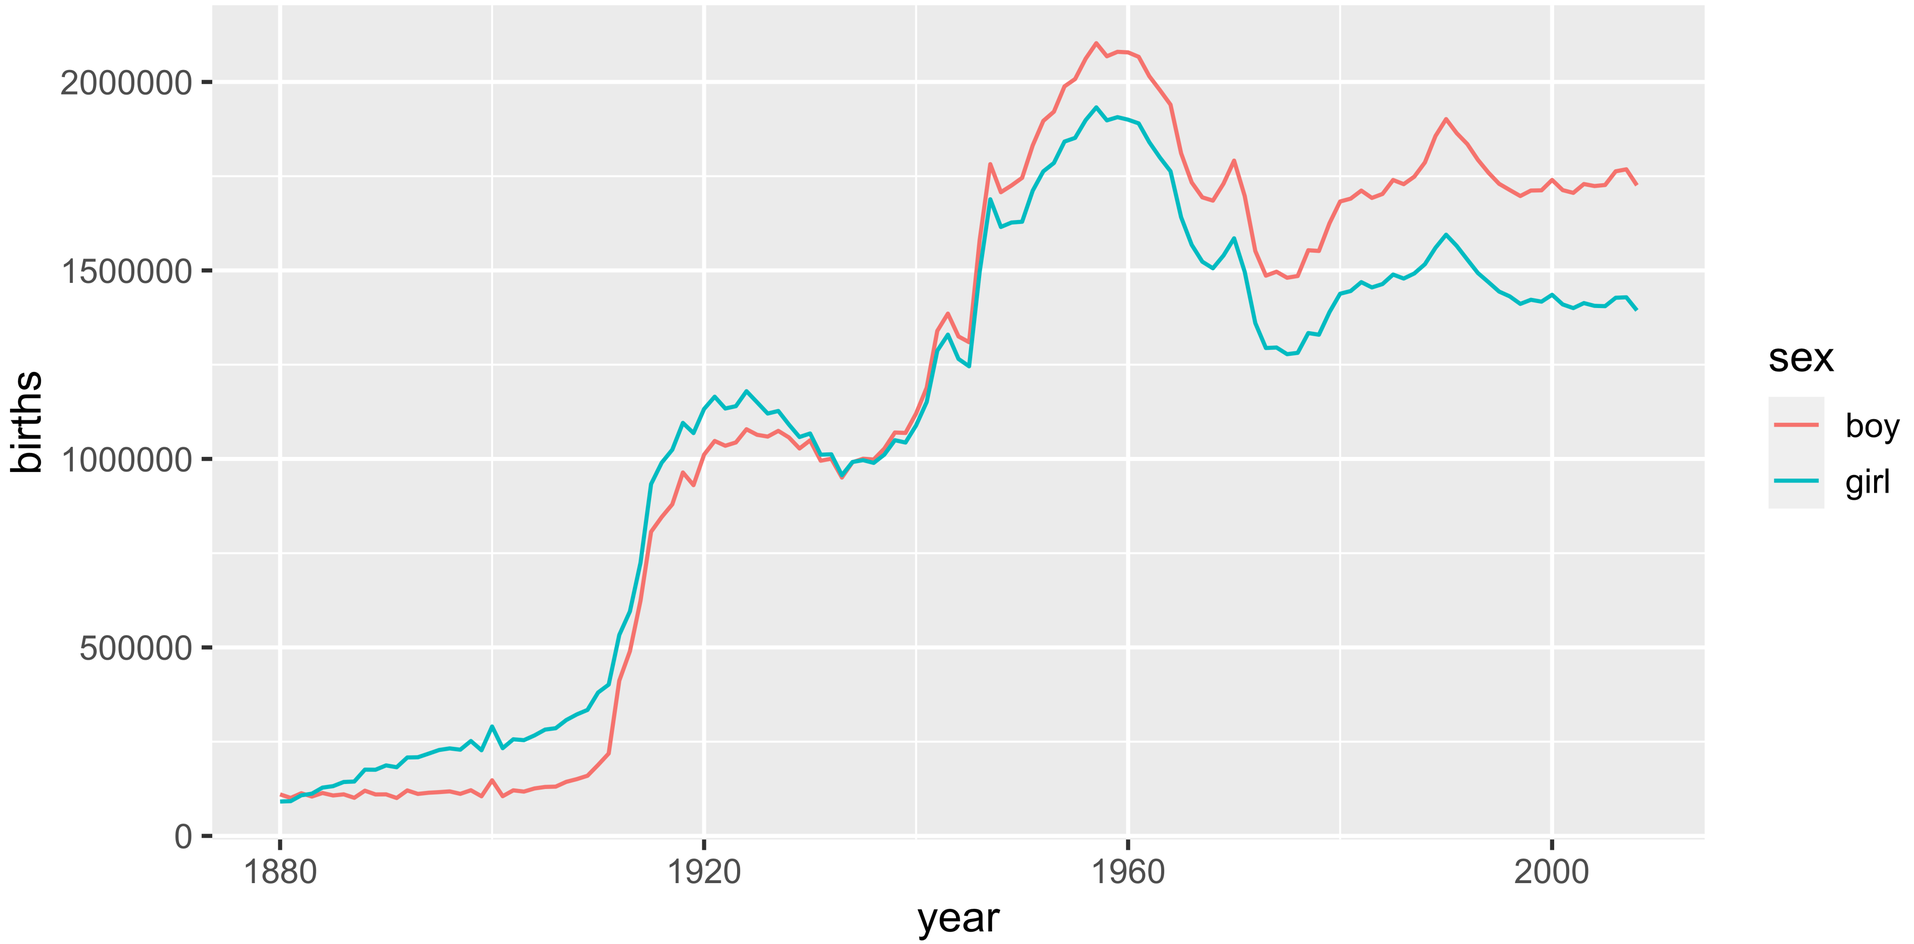
```
# A tibble: 258 × 3
# Groups:   year [129]
    year sex   births
   <int> <chr>  <dbl>
 1  1880 boy   110207
 2  1880 girl   91227
 3  1881 boy   100763
 4  1881 girl   92204
 5  1882 boy   113194
 6  1882 girl  107713
 7  1883 boy   104487
 8  1883 girl  112054
 9  1884 boy   113822
10  1884 girl  128140
# … with 248 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Salve o comando anterior no objeto `year_sex` e faça um gráfico dos nascimentos ao longo dos anos

```
year_sex <- bnames2 %>%
  group_by( year, sex ) %>%
  summarise( births = sum(n) )


year_sex %>%
  ggplot( aes(year, births) ) +
  geom_line( aes(color = sex) )
```

Salve o comando anterior no objeto `year_sex` e faça um gráfico dos nascimentos ao longo dos anos



Calcule um rank para cada nome em cada ano e para cada gênero e salve o resultado em um objeto `ranks`

Dica: crie uma nova variável `rank( desc(prop) )`

Calcule um rank para cada nome em cada ano e para cada gênero e salve o resultado em um objeto `ranks`

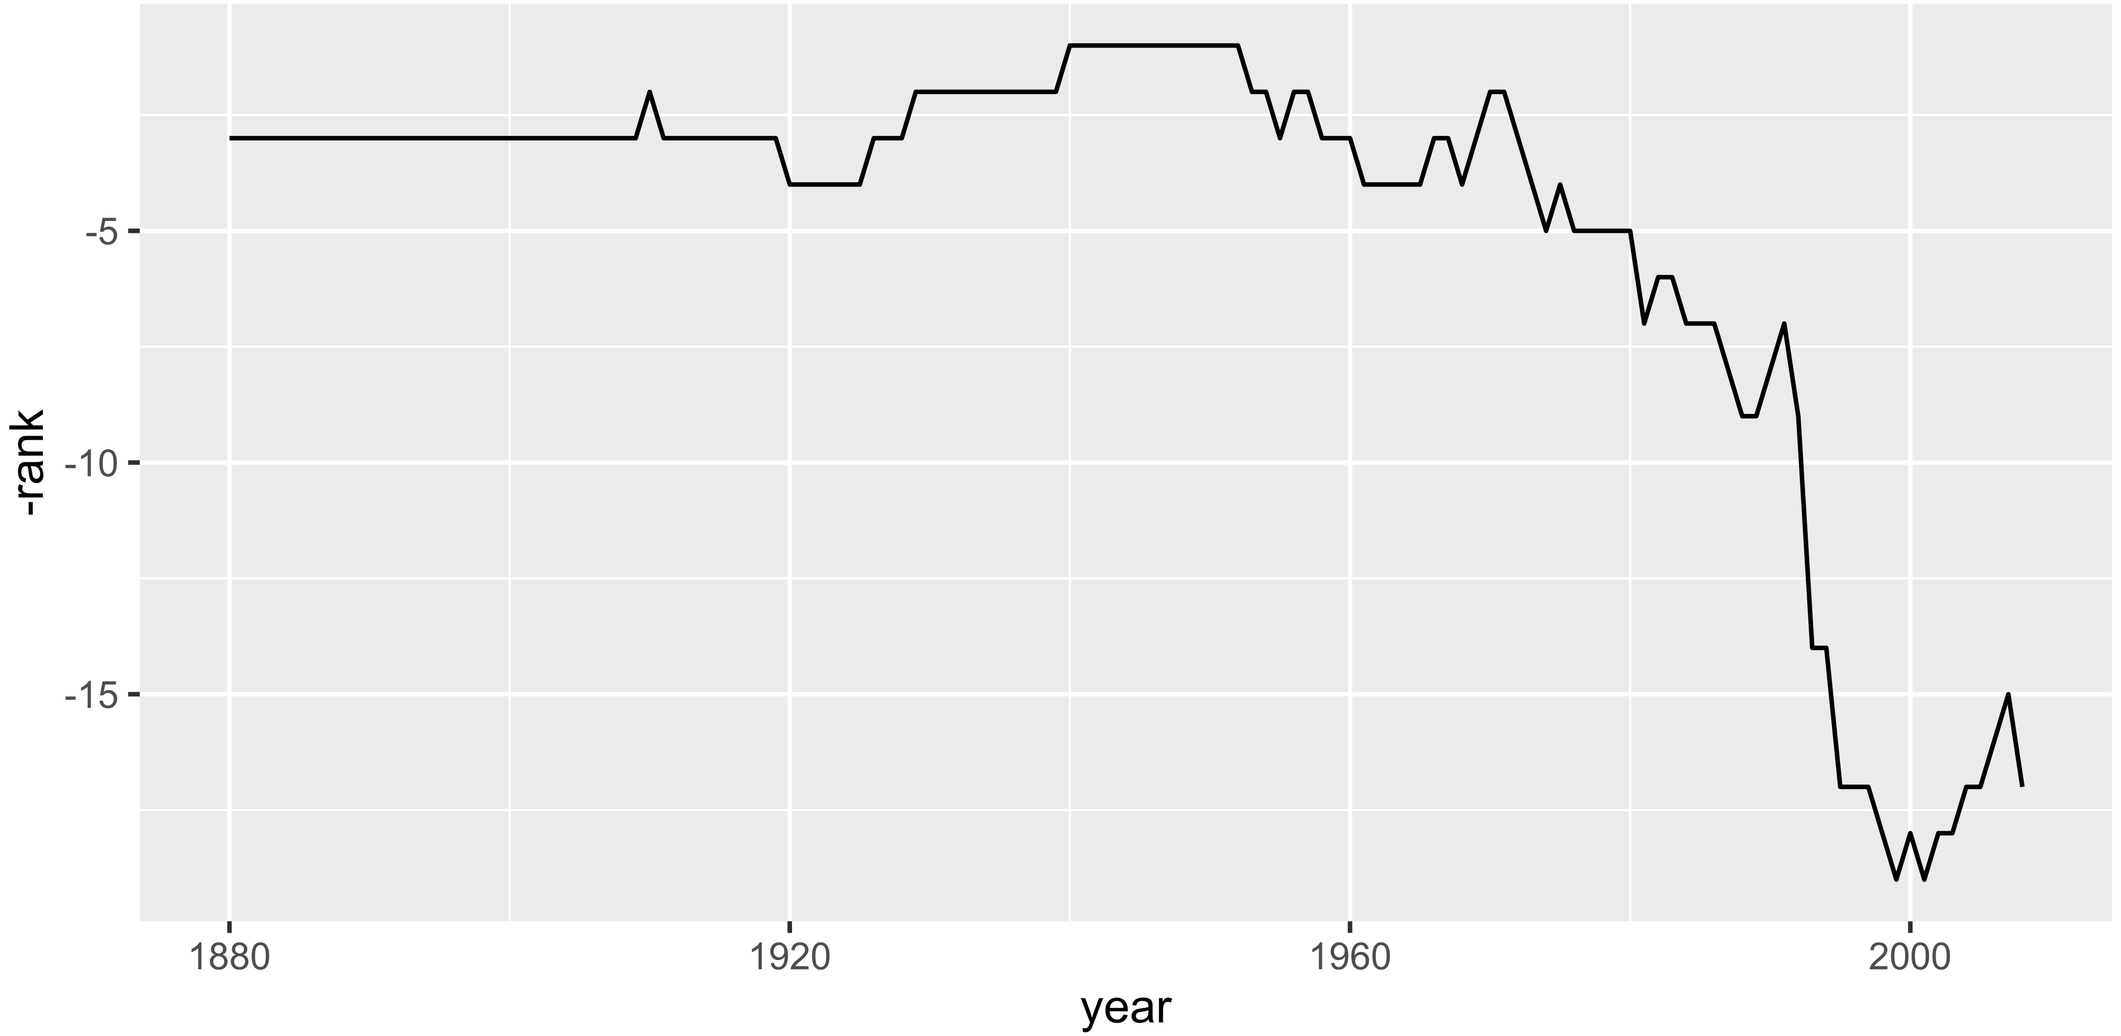
```
ranks <- bnames2 %>%
  group_by( year, sex ) %>%
  mutate( rank = rank( desc(prop) ) )
```

```
> head(ranks)
# A tibble: 6 x 8
# Groups:   year, sex [1]
   year name       prop sex   soundex births     n  rank
  <int> <chr>     <dbl> <chr> <chr>     <int> <dbl> <dbl>
1  1880 John    0.0815 boy   J500     118405  9655     1
2  1880 William 0.0805 boy   W450     118405  9533     2
3  1880 James   0.0501 boy   J520     118405  5927     3
4  1880 Charles 0.0452 boy   C642     118405  5348     4
5  1880 George  0.0433 boy   G620     118405  5126     5
6  1880 Frank   0.0274 boy   F652     118405  3242     6
```

Faça um gráfico do rank do seu nome ao longo dos anos

```
ranks %>%
  filter( name == "James", sex == "boy") %>%
  ggplot( aes(year, -rank) ) +
  geom_line()
```

Faça um gráfico do rank do seu nome ao longo dos anos



Quais nomes foram rankeados número 1 ao longo dos anos por gênero ?

```
ranks %>%
  filter( rank == 1 ) %>%
  select( year, name, sex)
```

Ruim para visualizar as meninas

```
# A tibble: 258 × 3
# Groups:   year, sex [258]
    year name  sex
   <int> <chr> <chr>
 1  1880 John  boy
 2  1881 John  boy
 3  1882 John  boy
 4  1883 John  boy
 5  1884 John  boy
 6  1885 John  boy
 7  1886 John  boy
 8  1887 John  boy
 9  1888 John  boy
10  1889 John  boy
# … with 248 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Refaça o item anterior transformando cada gênero em uma nova variável.

```
ranks %>%
  filter( rank == 1 ) %>%
  select( year, name, sex) %>%
  pivot_wider( names_from = "sex",
               values_from = "name" )
```

```
# A tibble: 129 × 3
# Groups:   year [129]
    year boy   girl
   <int> <chr> <chr>
 1  1880 John  Mary
 2  1881 John  Mary
 3  1882 John  Mary
 4  1883 John  Mary
 5  1884 John  Mary
 6  1885 John  Mary
 7  1886 John  Mary
 8  1887 John  Mary
 9  1888 John  Mary
10  1889 John  Mary
# … with 119 more rows
# ℹ Use `print(n = ...)` to see
more rows
```