Estatística Exploratória – Professor Luís Gustavo Vinha

Lista2

1) Uma amostra de 200 habitantes de uma cidade foi coletada para analisar a atitude frente a um certo projeto governamental. O resultado foi o seguinte:

	Local de residência		
Opinião	Urbana	Suburbana	Rural
A favor	30	35	35
Contra	60	25	15

   a) Calcule as proporções em relação ao total das colunas.
   b) Represente os dados graficamente.
   c) Encontre uma medida de associação entre as variáveis. Interprete o resultado.
   d) Com base nos resultados obtidos nos itens anteriores você diria que a opinião independe do local de residência?

2) A companhia A de dedetização afirma que o processo por ela utilizado garante um efeito mais prolongado do que aquele obtido por suas concorrentes mais diretas. Uma amostra de vários ambientes dedetizados foi colhida e anotou-se a duração do efeito de dedetização. Os resultados estão na tabela abaixo. Verifique se existe alguma evidência descritiva a favor ou contra a afirmação feita pela companhia A.

	Duração do efeito de dedetização		
Companhia	Menos de 4 meses	De 4 a 8 meses	Mais de 8 meses
A	64	120	16
B	104	175	21
C	27	48	5

3) A Associação de Imprensa do Estado de São Paulo fez um levantamento com 1300 leitores, para verificar se a preferência por leitura de um determinado jornal é independente do nível de instrução do indivíduo. No arquivo o jornal em questão é identificado como D. Descreva os dados e comente. (arquivo *lista2.txt - Leitores*)

4) Para avaliar a estratégia de distribuição de pastas de dentes em pontos de venda, uma organização de pesquisa de mercado foi encarregada de determinar, com base nas informações abaixo, se há relação entre o tamanho da embalagem de pastas de dente que a pessoa compra e o número de pessoas em sua residência:

	Tamanho da família		
Tamanho da embalagem	Pequena	Média	Grande
Pequena	68	31	25
Média	25	54	32
Grande	23	116	102

   a) Identifique as variáveis e classifique-as.
   b) Represente os dados graficamente.
   c) Calcule um coeficiente que mensure a força da associação entre as variáveis e interprete-o.
   d) A associação entre o tamanho da embalagem e o número de pessoas na residência é forte? É positiva?

5) Uma pesquisa foi realizada entre adolescentes para entender as preferências em relação a diferentes tipos de músicas. Os 427 participantes responderam o quanto gostavam de dois gêneros de música: funk e sertanejo, os dados são apresentados a seguir. Pode-se afirmar que a associação é negativa? É forte? Como você explicaria para outra pessoa esse resultado?

	Gosta de funk		
Gosta de sertanejo	Nada	Pouco	Muito
Nada	25	21	89
Pouco	58	54	18
Muito	125	15	22

6) Esse exercício refere-se ao arquivo *lista2.xlsx - Mundo*. Neste arquivo, você encontrará informações sobre 85 países. São apresentadas as variáveis:

- Populaca: população em milhares de habitantes
- Densidad: pessoas por km^2
- Urbana: percentual da população que vive em áreas urbanas
- Vidafem: expectativa de vida das mulheres
- Vidamasc: expectativa de vida dos homens
- Crespop: crescimento populacional anual (%)
- Mortinf: Motalidade infantil em 1000 nascidos vivos
- Pibcapit: PIB per capita
- Lemasc: % de homens alfabetizados
- Lefem: % de mulheres alfabetizadas

a) Construa um diagrama de dispersão do PIB per capita (y) em função do percentual da população que vive em áreas urbanas (x). Interprete o gráfico.
b) Um modelo de regressão linear seria adequado para modelar a relação entre essas variáveis?
c) Calcule os coeficientes de correlação de Pearson e Spearman. Comente as diferenças.
d) Construa um diagrama de dispersão entre o logaritmo do PIB per capita (y) em função do percentual da população que vive em áreas urbanas. Você acha que um modelo de regressão linear poderia ser adotado para analisar esses dados?
e) Estime o modelo de regressão linear sugerido no item (c). Interprete os parâmetros.
f) Suponha que você tenha que fazer a previsão de quanto é o PIB per capita de um país com 50% de população que vive em áreas urbanas. Usando o modelo estimado em (d), faça a previsão do PIB per capita para este país.

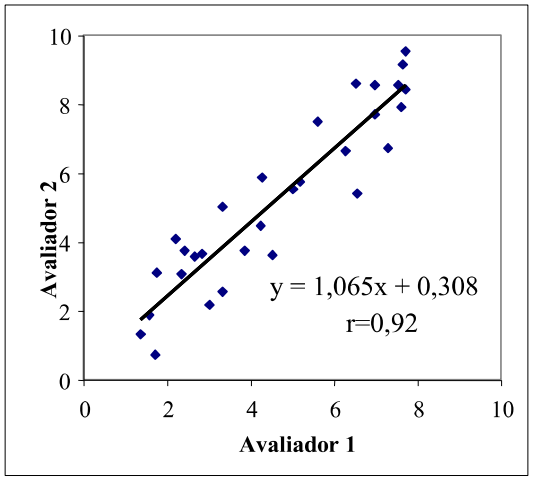
7) Abaixo estão os dados referentes à porcentagem da população economicamente ativa empregada no setor primário e o respectivo índice de analfabetismo para algumas regiões metropolitanas brasileiras.

Região Metropolitana	Setor Primário	Índice de Analfabetismo
São Paulo	2,0	17,5
Rio de Janeiro	2,5	18,5
Belém	2,9	19,5
Belo Horizonte	3,3	22,2
Salvador	4,1	26,5
Porto Alegre	4,3	16,6
Recife	7,0	36,6
Fortaleza	13,0	38,4

a) Faça o diagrama de dispersão. Você acha que existe alguma relação linear entre as variáveis?
b) Calcule o coeficiente de correlação linear de Pearson amostral e interprete o resultado. Existe alguma região com comportamento diferente das demais? Se existe, elimine o valor correspondente a tal região e recalcule o coeficiente de correlação. Interprete as diferenças obtidas.
c) Estime a reta de mínimos quadrados entre Setor primário (Y) e Índice de analfabetismo (X) considerando que exista uma relação linear entre as 2 variáveis. Interprete o significado dos coeficientes com base no problema.
d) Para cada cidade, encontre o resíduo $e_i = y_i - y_i$ ajustado. Existe alguma cidade com valor muito exagerado?

8) Para alavancar suas vendas, uma loja de móveis investiu em comerciais de TV. No arquivo *lista2.xlsx - Vendas* são apresentados os dados do desempenho da loja e do número de comerciais veiculados em 19 semanas.
a) Há evidências de que a veiculação de comerciais alavanca as vendas? Por que?
b) Na próxima semana pretende-se veicular 19 comerciais. Que volume de vendas você prevê para a loja?
c) O gerente de marketing propôs a veiculação de 70 comerciais em uma semana. Critique essa proposta (se você a considera boa, justifique e se você a considerar ruim, faça uma contraproposta).

9) Uma empresa de recursos humanos é responsável pelo processo seletivo de várias empresas com sede em São Paulo. Em uma das etapas do processo o candidato faz uma apresentação oral e é avaliado por 2 avaliadores. O dono da empresa está suspeitando que estes avaliadores adotam critérios diferentes de avaliação e para verificar se esta suspeita se confirma ele resolveu fazer um estudo. Neste estudo foram registradas as notas dos dois avaliadores para 30 candidatos, veja os resultados abaixo.



a) O modelo ajustado é adequado? Por que? Respostas sem justificativas serão ignoradas.
b) Interprete os coeficientes apresentados.
c) Você acha que as suspeitas do dono da empresa se confirmam? Por que? Em caso afirmativo, qual avaliador faz melhores avaliações? Justifique. Respostas sem justificativas serão ignoradas.
d) Qual deve ser a nota esperada do Avaliador 2 para um candidato que obteve nota 6,5 com o avaliador 1?

10) Um professor suspeita que as notas das provas de matemática e física estão diretamente associadas. Uma amostra de 10 alunos foi avaliada com os dois testes e os dados são apresentados a seguir.

Aluno	1	2	3	4	5	6	7	8	9	10
Nota Matemática	39	52	74	80	60	70	83	30	68	62
Nota Física	12	13	46	40	26	11	75	11	28	10

a) Calcule o coeficiente de Spearman entre as nota de Matemática e Física.
b) Faça o diagrama de dispersão e comente.
c) Por que o coeficiente de Pearson não é adequando para esse caso?

11) A renda dos trabalhadores de duas categorias profissionais está sendo avaliada. A renda de 72 trabalhadores da Categoria A e 58 da categoria B foi registrada e analisada utilizando o pacote estatístico R. Com base nas informações abaixo compare as rendas e calcule o coeficiente R^2. Existe relação entre a renda e a categoria? É forte?

```
> describe(dados$Renda)
   vars   n    mean    sd  median trimmed     mad     min     max   range skew kurtosis    se
X1    1 130 6276.46 823.4 6153.54  6271.5 1068.59 4637.17 7809.41 3172.24 0.08    -1.16 72.22

> describeBy(dados2$Renda,dados2$Categoria)
Descriptive statistics by group
group: A
   vars  n    mean     sd  median trimmed    mad     min     max   range  skew kurtosis    se
X1    1 72 5637.54 418.95 5640.77 5654.01 401.28 4637.17 6507.85 1870.68 -0.27     -0.5 49.37
group: B
   vars  n    mean     sd  median trimmed    mad     min     max  range  skew kurtosis    se
X1    1 58 7069.59 400.02 7069.74 7083.35 340.38 6133.11 7809.41 1676.3 -0.26    -0.25 52.52


> quantile(dados2[dados2$Categoria=="A",]$Renda)
      0%      25%      50%      75%     100%
4637.169 5372.976 5640.775 5926.474 6507.852

> quantile(dados2[dados2$Categoria=="B",]$Renda)
      0%      25%      50%      75%     100%
6133.113 6850.809 7069.737 7359.043 7809.410
```

12) O desempenho de funcionário de uma empresa está sendo estudado. Essa empresa tem três fábricas que funcio nam dia e noite com trabalhadores divididos em dois turnos (*lista2.xlsx – Desempenho*). Existe diferença entre os desempenhos se comparadas os funcionários das três fábricas? Se sim, calcule o R^2 e interprete. Existe dife