ESTATÍSTICA EXPLORATÓRIA

EST0033

Luís Gustavo do Amaral Vinha

1° semestre de 2024

Unidade II – aula 4



- **Estatística** é a ciência que tem por objetivo orientar a coleta, o resumo, a apresentação, a análise e a interpretação de dados.

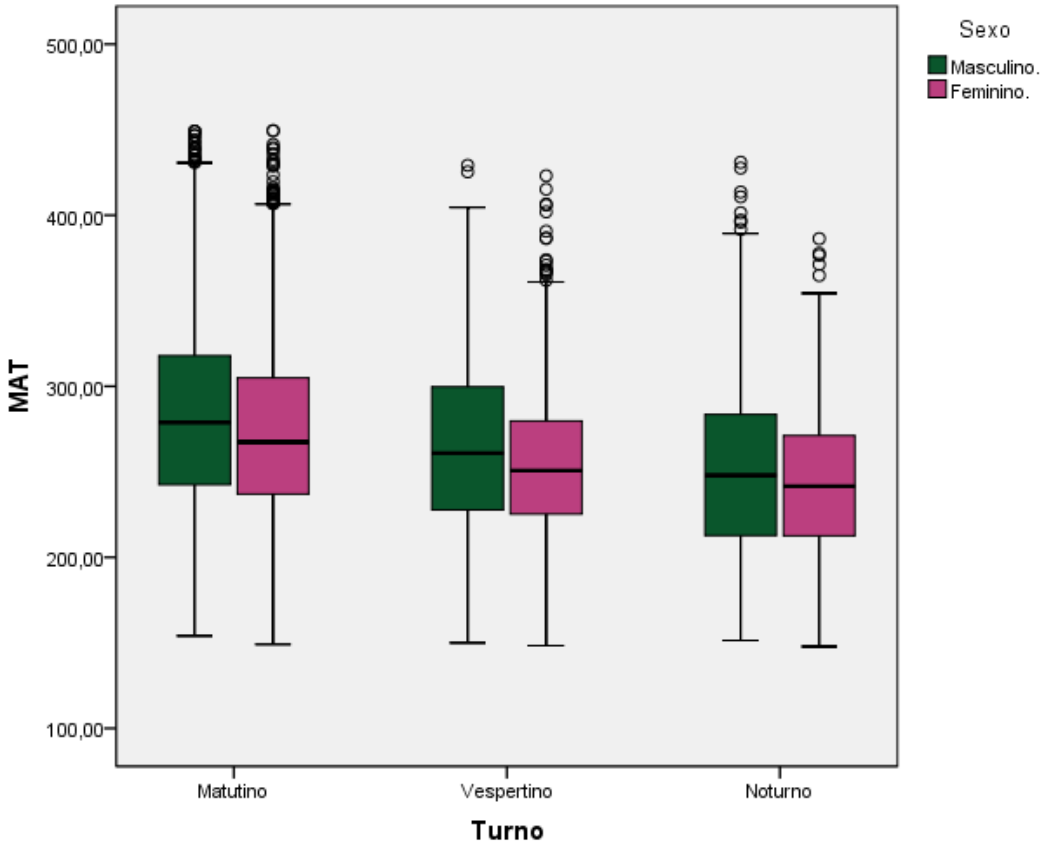
- **Estatística Descritiva**: é o ramo da estatística voltada para a organização, o resumo e a descrição de conjuntos de dados.

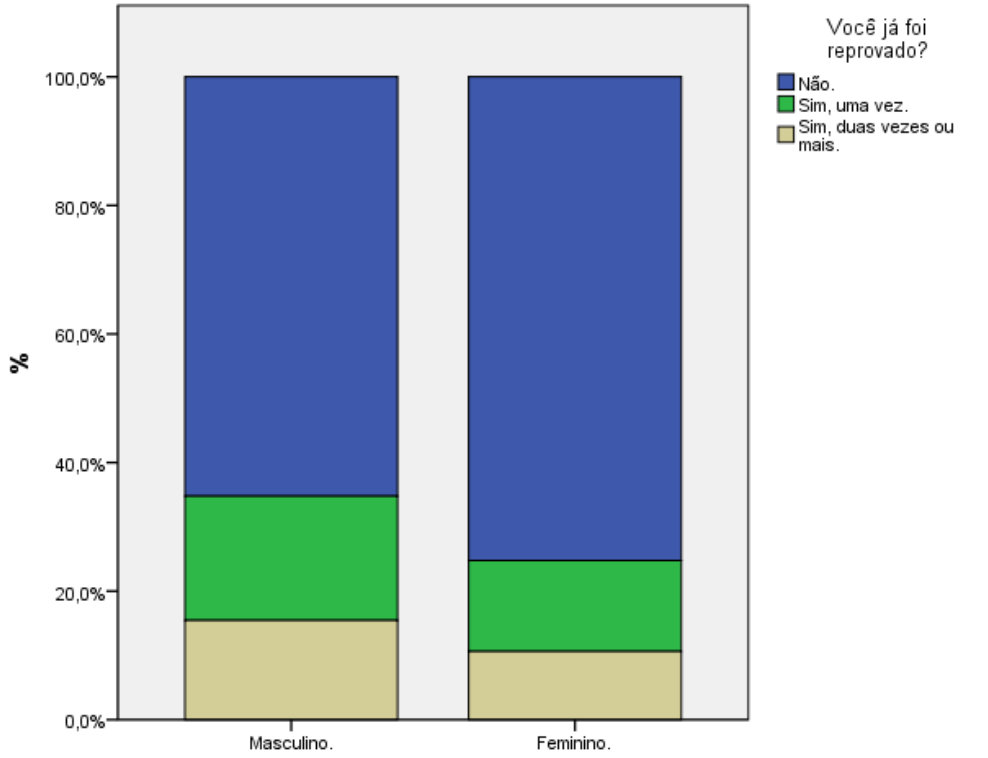
- **Inferência Estatística**: é o ramo da estatística que utiliza dados obtidos de uma amostra para fazer estimativas ou testar hipóteses sobre características de interesse de uma população.

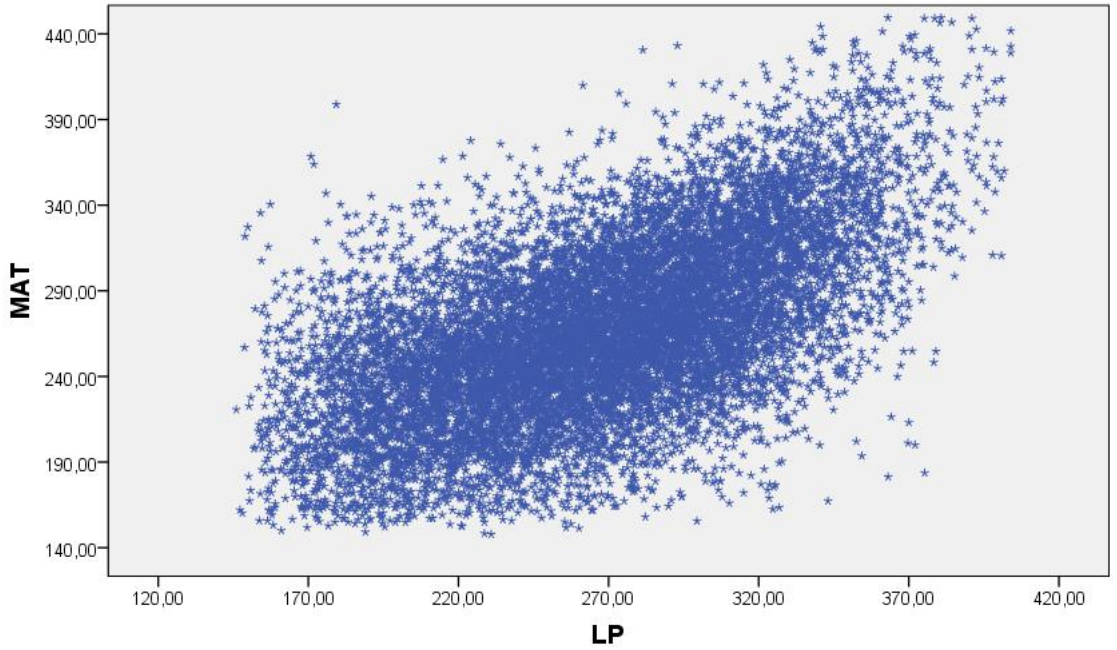
ESTATÍSTICA DESCRITIVA

BIDIMENSIONAL

ESTUDOS DE ASSOCIAÇÃO







ESTUDOS DE ASSOCIAÇÃO – ANÁLISE BIDIMENSIONAL

De acordo com a situação, as técnicas de análise de dados são diferentes para cada tipo de variável envolvida:

- Uma variável quanti e outra quali: comparação com gráficos apresentados (histograma, box-plot) e medida R^2.

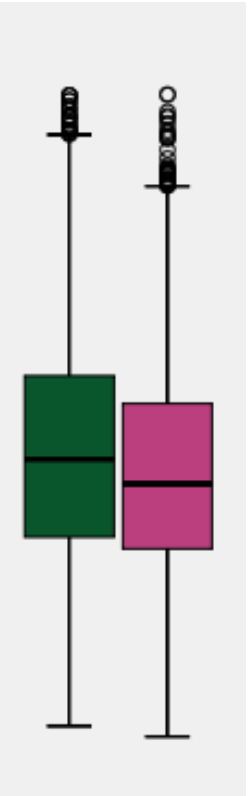
- 2 variáveis quantitativas: os dados são resumidos em gráficos de dispersão (coeficiente de correlação linear de Pearson, coeficiente de Spearman);

- 2 variáveis qualitativas: os dados são resumidos em tabelas de contingência ou de dupla entrada (estatística qui-quadrado, coeficiente de contigência, gamma de Goodman,...);

ESTUDOS DE ASSOCIAÇÃO – ANÁLISE BIDIMENSIONAL

Objetivo: encontrar associação ou relação entre as variáveis. Essas relações podem ser identificadas apor gráficos ou medidas numéricas.

Associação: mudança de opinião sobre o comportamento de uma variável na presença ou não de informação sobre a segunda variável.



ASSOCIAÇÃO – VARIÁVEIS QUALITATIVAS

OUTRO EXEMPLO

- Conduziu-se uma pesquisa para avaliar a possível relação entre a satisfação com um determinado produto tem relação com o sexo do consumidor.

Consumidor	Gênero	Avaliação
1	M	Positiva
2	F	Positiva
3	F	Indiferente
4	F	Positiva
5	M	Negativa
6	F	Negativa
...	...	...
285	M	Indiferente

MEDIDAS DE ASSOCIAÇÃO

- Os gráficos e tabelas apresentados anteriormente são importantes para entender como as variáveis se comportam conjuntamente. No entanto, não é possível quantificar a **força da associação**.

			Avaliação			Total
			Positiva	Indiferente	Negativa	
Sexo	Masculino		54	36	22	112
		% linha	48,2%	32,1%	19,6%	100%
	Feminino		115	41	17	173
		% linha	66,5%	23,7%	9,8%	100%
	Total		169	77	39	285
		% linha	59,3%	27,0%	13,7%	100%

MEDIDAS DE ASSOCIAÇÃO

- Uma forma de medir a força da associação entre duas variáveis qualitativas baseia-se na comparação entre a tabela de valores observados e a tabela de valores esperados sob a hipótese de não associação.

Count

		Avaliação			
		Positiva	Indiferente	Negativa	Total
Sexo	Masculino	54	36	22	112
	Feminino	115	41	17	173
Total		169	77	39	285

	Positiva	Indiferente	Negativa	**Total**
Masculino				**112**
Feminino				**173**
Total	169 (0,593)	77 (0,270)	39 (0,137)	**285 (1,000)**

NOTAÇÃO

n_{ij}: frequência observada na linha *i* coluna *j;*

$n_{i.}$: frequência total observada na linha *i;*

$n_{.j}$: frequência total observada na coluna *j;*

n: frequência total (tamanho da amostra);

n^*_{ij} $\frac{n_{i.} \times n_{.j}}{n}$: frequência esperada na linha *i* coluna *j.*

NOTAÇÃO

X \ Y	B_1	B_2	...	B_j	...	B_s	Total
A_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1s}	$n_{1.}$
A_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2s}	$n_{2.}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
A_i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{is}	$n_{i.}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
A_r	n_{r1}	n_{r2}	...	n_{rj}	...	n_{rs}	$n_{r.}$
Total	$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.s}$	$n..$

TABELA OBSERVADA

Count

		Avaliação			
		Positiva	Indiferente	Negativa	Total
Sexo	Masculino	54	36	22	112
	Feminino	115	41	17	173
Total		169	77	39	285

TABELA ESPERADA

	Positiva	Indiferente	Negativa	**Total**
Masculino				**112**
Feminino				**173**
Total	169 (0,593)	77 (0,270)	39 (0,137)	**285** **(1,000)**

TABELA ESPERADA

	Positiva	Indiferente	Negativa	**Total**
Masculino	66,414 (0,593)	30,260 (0,270)	15,326 (0,137)	**112**
Feminino	102,586 (0,593)	46,740 (0,270)	23,674 (0,137)	**173**
Total	169 (0,593)	77 (0,270)	39 (0,137)	**285 (1,000)**

$$n_{11}^{*} = \frac{n_{1.} \times n_{.1}}{n} = \frac{112 \times 169}{285} = 112 \times 0{,}593 = 66{,}414$$

$$n_{23}^{*} = \frac{n_{2.} \times n_{.3}}{n} = \frac{173 \times 39}{285} = 173 \times 0{,}137 = 23{,}674$$

ESTATÍSTICA QUI-QUADRADO

$$X^2 = \sum_{i=1}^{r} \sum_{j=1}^{s} \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}$$

onde
r é o número de linhas
s é o número de colunas

Note que Qui-quadrado é uma medida não negativa, sem limite superior. Quanto maior a associação entre as variáveis maior será o valor.

ESTATÍSTICA QUI-QUADRADO

j	n	e	n - e	**(n - e)^2/e**
1	54	66,414	-12,414	**2,320**
2	36	30,260	5,740	**1,089**
3	22	15,326	6,674	**2,906**
4	115	102,586	12,414	**1,502**
5	41	46,740	-5,740	**0,705**
6	17	23,674	-6,674	**1,881**
Total	285	285	0	**10,404**

MEDIDAS DE ASSOCIAÇÃO PARA DADOS NOMINAIS

COEFICIENTE DE CONTINGÊNCIA

Esse coeficiente é utilizado para medir a força da associação de duas variáveis qualitativas, calculado a partir da estatística Qui-quadrado.

$$C = \sqrt{\frac{X^2}{X^2 + n}}$$

O coeficiente varia entre 0 e $\sqrt{\frac{t-1}{t}}$, onde t é o mínimo entre o número de linhas e o número de colunas.

COEFICIENTE DE CONTINGÊNCIA MODIFICADO

Para que a medida de associação tenha limites 0 e 1, a seguinte modificação é proposta

$$C^* = \frac{C}{C_{max}}, \text{ onde } C_{max} = \sqrt{\frac{t-1}{t}}$$

Dessa forma

$$0 \leq C^* \leq 1$$

COEFICIENTE DE CONTINGÊNCIA MODIFICADO

Para o problema: $\chi^2 = 10{,}404$

$$C = \sqrt{\frac{10{,}404}{10{,}404 + 285}} = 0{,}188$$

$$C_{\text{Máx}} = \sqrt{\frac{2-1}{2}} = 0{,}707$$

$$C^* = \frac{0{,}188}{0{,}707} = 0{,}265$$

ALTERNATIVAS AO COEFICIENTE DE CONTINGÊNCIA

Como mencionado anteriormente, o problema de se usar o Coeficiente de Contingência é que seu valor máximo depende do tamanho da tabela.

- O valor máximo de CC para uma tabela 2 x 2 é 0.707. O valor máximo de CC para uma tabela 4 x 4 é 0.87.
- Recomenda-se usar **Phi** ou **V de Cramér** no estudo de associação entre duas variáveis qualitativas nominais.

COEFICIENTE PHI E V DE CRAMER

O coeficiente Phi é dado por $\phi = \sqrt{\frac{X^2}{n}}$

O coeficiente V de Cramér é dado por $V = \sqrt{\frac{X^2}{n.(L-1)}}$

L é o mínimo entre o número de linhas e colunas.

Para tabelas 2x2 esses coeficientes são iguais. O V de Cramér é mais apropriado para tabelas maiores.

COEFICIENTE PHI E V DE CRAMER

Para o problema: $\chi^2 = 10{,}404$

$$C = \sqrt{\frac{10{,}404}{10{,}404 + 285}} = 0{,}188$$

$$\phi = \sqrt{\frac{10{,}404}{285}} = 0{,}191$$

$$C * = \frac{0{,}188}{0{,}707} = 0{,}265$$

$$V = \sqrt{\frac{10{,}404}{285.(2-1)}} = 0{,}191$$

VARIÁVEIS QUALITATIVAS ORDINAIS

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

- Medida de associação para variáveis qualitativas ordinais
- Mede a magnitude e direção da associação
- Baseia-se em conceitos de concordância e discordância

Exemplo: uma amostra de clientes foi selecionada e eles opinaram sobre 2 produtos A e B:

	Produto B		
Produto A	Ruim	Mediano	Bom
Ruim	85	21	14
Mediano	12	40	15
Bom	8	14	35

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

Exemplo:

- **Produto A:** opinião sobre produto A: ruim, mediano e bom
- **Produto B:** opinião sobre produto B: ruim, mediano e bom

- Opiniões do indivíduo 1: A- ruim, B – ruim
- Opiniões do indivíduo 2: A- bom, B – bom

$\Rightarrow$ Indivíduos 1 e 2 são **concordantes**

Comparando o indivíduo 1 com o 2, a opinião melhorou para as 2 variáveis

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

Exemplo:

- **Produto A:** opinião sobre produto A: ruim, mediano e bom
- **Produto B:** opinião sobre produto B: ruim, mediano e bom

- Opiniões do indivíduo 3: A- ruim, B – mediano
- Opiniões do indivíduo 4: A- bom, B – ruim

$\Rightarrow$ Indivíduos 3 e 4 são **discordantes**

Comparando o indivíduo 3 com o 4, a opinião sobre A melhorou A e, sobre B, piorou

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

- Quando 2 variáveis ordinais apresentam muitos pares concordantes a associação e positiva. Caso contrário, a associação é negativa.

- O coeficiente γ e dado pela equação: $$\gamma = \frac{n_c - n_d}{n_c + n_d}$$

em que n_c representa o número de pares concordantes e n_d, o número de pares discordantes.

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

- O coeficiente γ e dado pela equação:

$$\gamma = \frac{n_c - n_d}{n_c + n_d}$$

- O coeficiente γ varia entre -1 e 1.

  γ = 1 quando só houver pares concordantes,

  γ = -1 quando só houver pares discordantes,

  γ = 0 quando o numero de pares concordantes e discordantes for igual.

COEFICIENTE GAMA DE GOODMAN E KRUSKAL (γ)

- γ pode ser calculado se existirem caselas com frequências absolutas simples iguais a zero, mas não se uma linha (ou mais) ou uma coluna (ou mais) inteira for de frequências iguais a zero.

Var 1	Var 2		
	a	b	c
A	(1,1)	(1,2)	(1,3)
B	(2,1)	(2,2)	(2,3)
C	(3,1)	(3,2)	(3,3)

EXEMPLO

Classificação de 1425 crianças segundo suas habilidades para música e para matemática

Habilidade para matemática	Habilidade para música		
	Menor	Mediana	Maior
Menor	209	101	237
Mediana	151	126	426
Maior	16	21	138

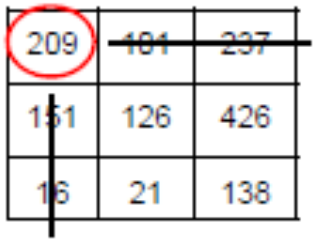
Fonte: Dados fictícios

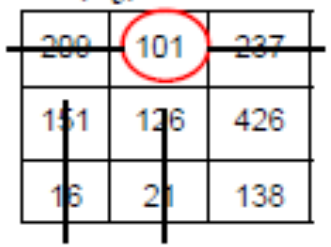
As categorias das duas variáveis precisam estar numa mesma ordem (ordem crescente ou decrescente) para que se possa contar o número de pares concordantes e discordantes!!

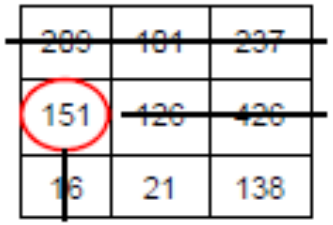
Habilidade para MAT	Habilidade para música		
	Menor	Mediana	Maior
Menor	209	101	237
Mediana	151	126	426
Maior	16	21	138

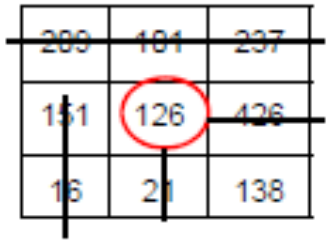
Habilidade para MAT	Habilidade para música		
	Menor	Mediana	Maior
Menor	209	101	237
Mediana	151	126	426
Maior	16	21	138

Número de pares concordantes (n_c):







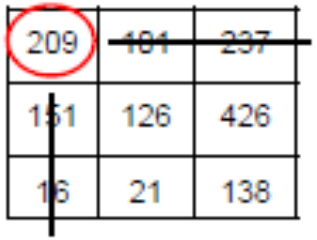


n_c = 209 x (126 + 426 + 21 +138) + 101 x (426 +138) + 151 x (21 +138) + 126 x (138)

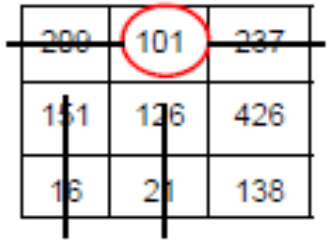
n_c = 246.960

Habilidade para MAT	Habilidade para música		
	Menor	Mediana	Maior
Menor	209	101	237
Mediana	151	126	426
Maior	16	21	138

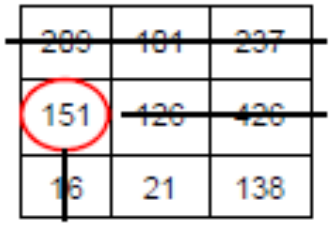
Número de pares concordantes (n_c):



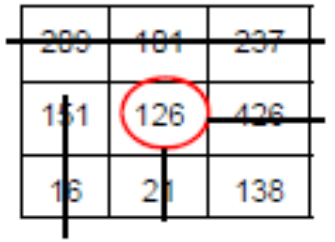
n_c = 209 x (126 + 426 + 21 +138)



+ 101 x (426 +138)



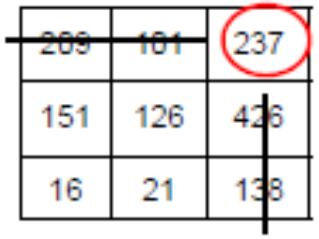
+ 151 x (21 +138)



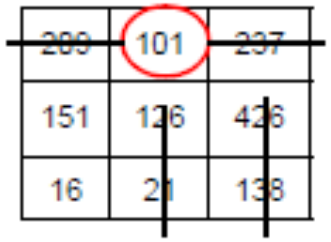
+ 126 x (138)

n_c = 246.960

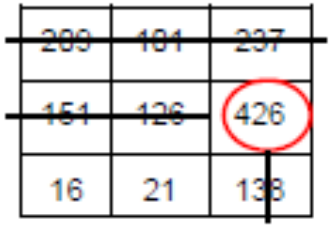
Número de pares disconcordantes (n_d):



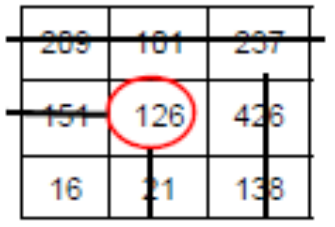
n_c = 237 x (151 + 126 + 16 + 21)



+ 101 x (151 + 16)



+ 426 x (16 + 21)



+ 126 x (16)

n_d = 109.063

EXEMPLO

Habilidade para MAT	Habilidade para música		
	Menor	Mediana	Maior
Menor	209	101	237
Mediana	151	126	426
Maior	16	21	138

$n_c = 246.960$

$n_d = 109.063$

$\gamma = (264960 - 109063)/ (264960 + 109063) = 0,39$

Pode-se concluir que existe uma associação positiva moderada entre habilidade musical e matemática no grupo estudado.

EXEMPLO DADOS_ATIVIDADES

- **Relação entre sentimento com relação à escola e deveres de casa**

- Gama = 0,400

