ESTATÍSTICA EXPLORATÓRIA

EST0033

Luís Gustavo do Amaral Vinha

1° semestre de 2024

Unidade II – aula 5



- **Estatística** é a ciência que tem por objetivo orientar a coleta, o resumo, a apresentação, a análise e a interpretação de dados.

- **Estatística Descritiva**: é o ramo da estatística voltada para a organização, o resumo e a descrição de conjuntos de dados.

- **Inferência Estatística**: é o ramo da estatística que utiliza dados obtidos de uma amostra para fazer estimativas ou testar hipóteses sobre características de interesse de uma população.

ESTATÍSTICA DESCRITIVA

UNIDIMENSIONAL

TIPOS DE VARIÁVEIS

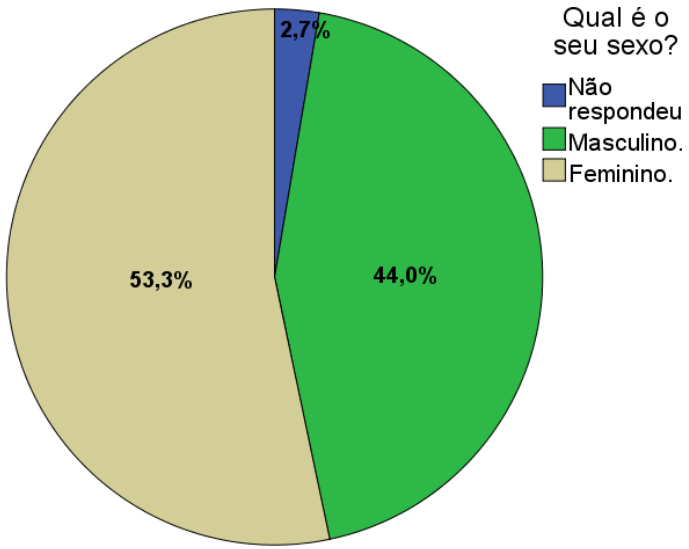
Qualitativas ou categóricas	Nominais Ordinais
Quantitativas ou numéricas	Discretas Contínuas

Qualitativas

Nominais

Qual é o seu sexo?

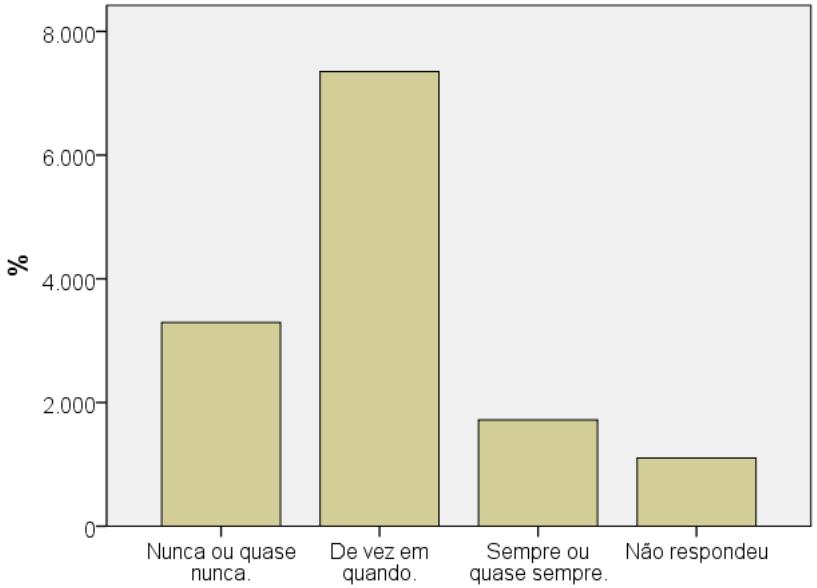
		Frequency	Percent
Valid	Feminino.	7178	53,3
	Masculino.	5928	44,0
	Não respondeu	360	2,7
	Total	13466	100,0



Ordinais

Com qual frequência você lê: Revistas informativas em geral.

	Frequency	Percent	Cumulative Percent
Nunca ou quase nunca.	3293	24,5	24,5
De vez em quando.	7351	54,6	79,0
Sempre ou quase sempre.	1719	12,8	91,8
Não respondeu	1103	8,2	100,0
Total	13466	100,0	



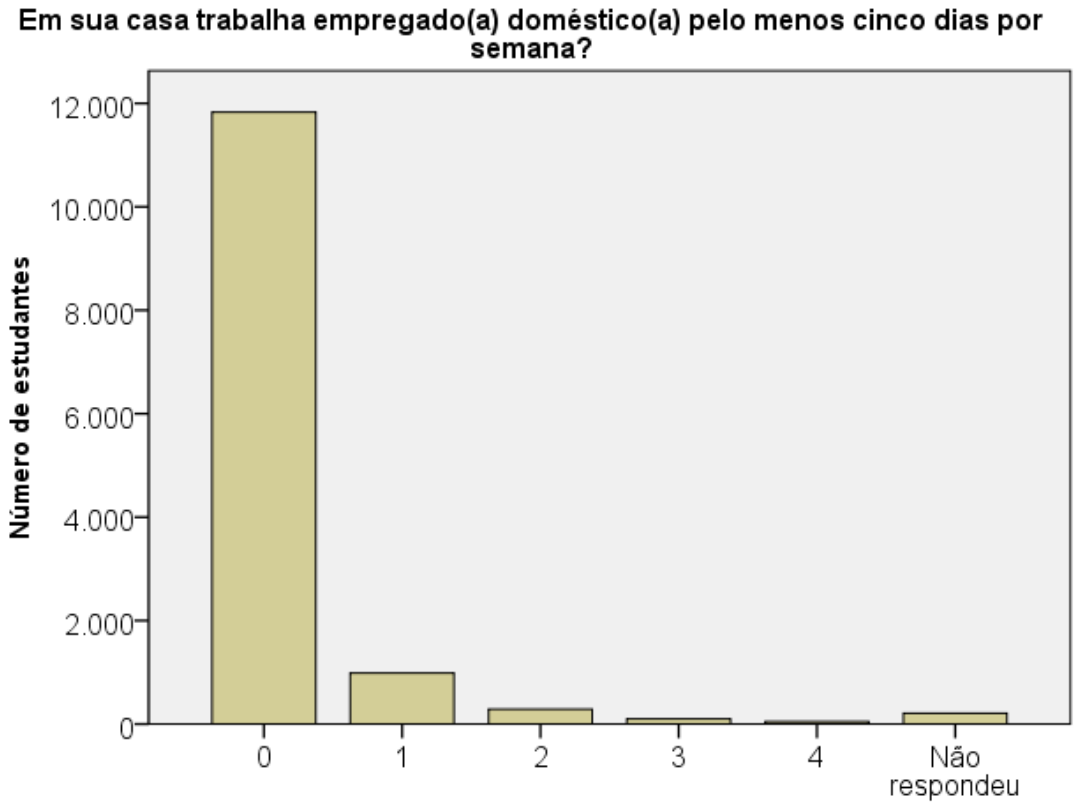
Com qual frequência você lê: Revistas informativas em geral.

Quantitativas

Discretas

Em sua casa trabalha empregado(a) doméstico(a) pelo menos cinco dias por semana?

	Frequency	Percent	Cumulative Percent
0	11831	87,9	87,9
1	985	7,3	95,2
2	288	2,1	97,3
3	101	,8	98,1
4	49	,4	98,4
Não respondeu	212	1,6	100,0
Total	13466	100,0	

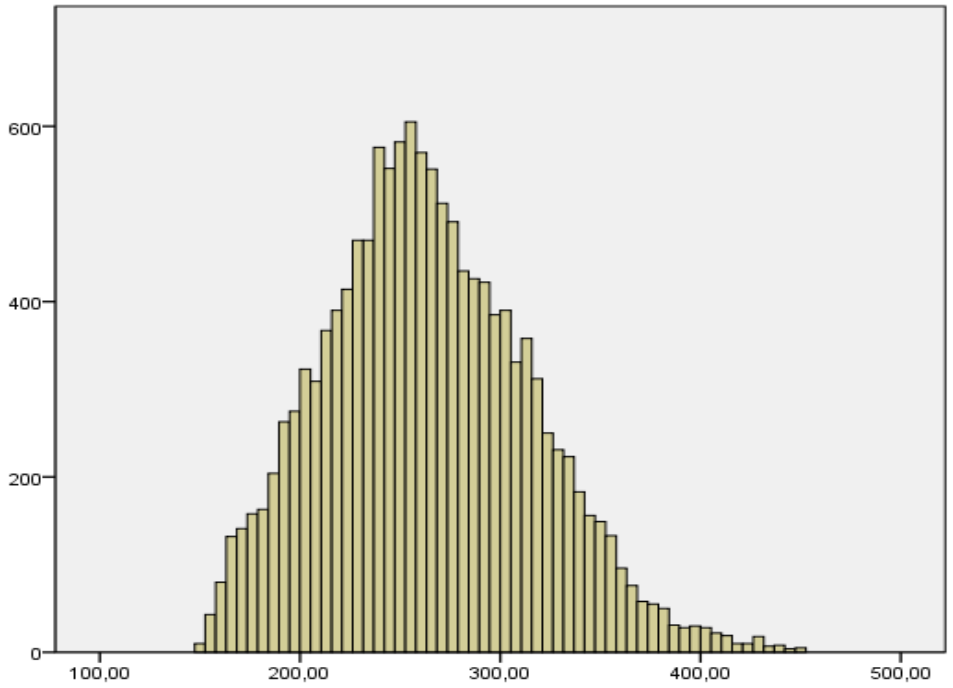


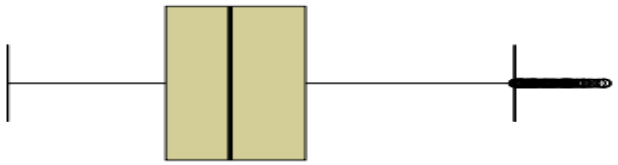
Descriptive Statistics

	N	Range	Minimum	Maximum	Mean	Std. Deviation
EMPREGADOS	13260	4,00	,00	4,00	,1554	,51451
Valid N (listwise)	13260					

Quantitativas

Contínuas





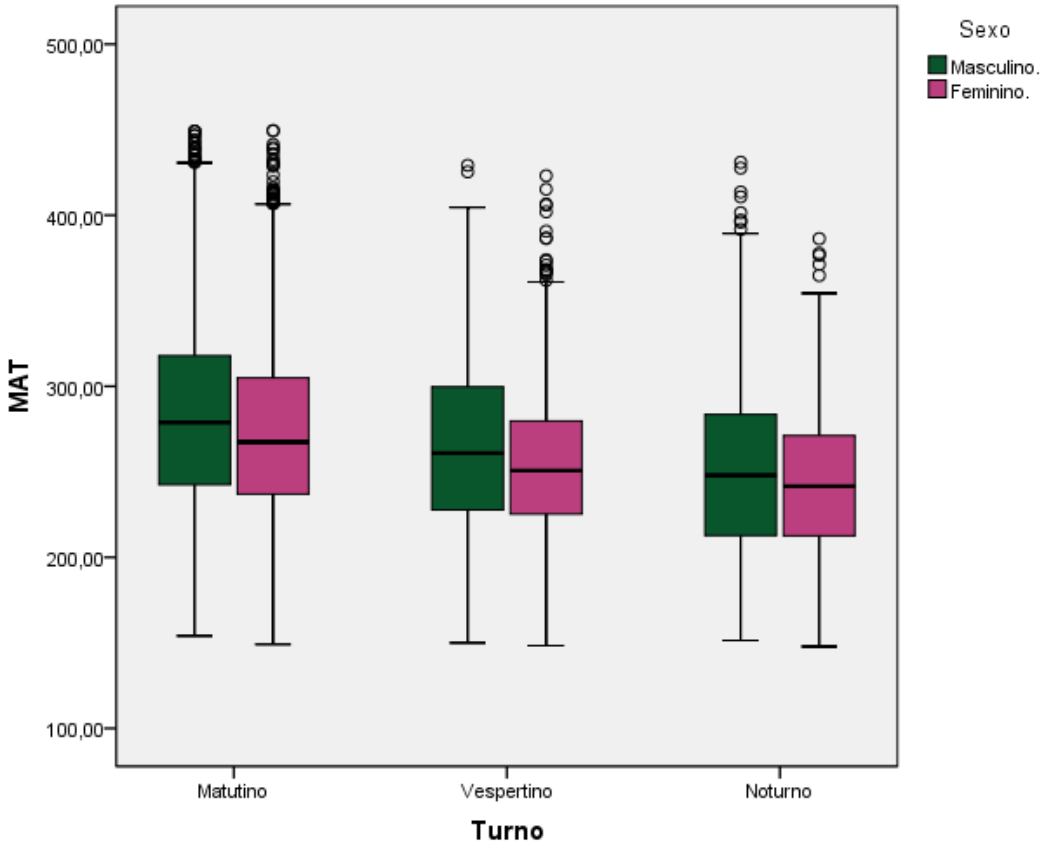
Descriptives

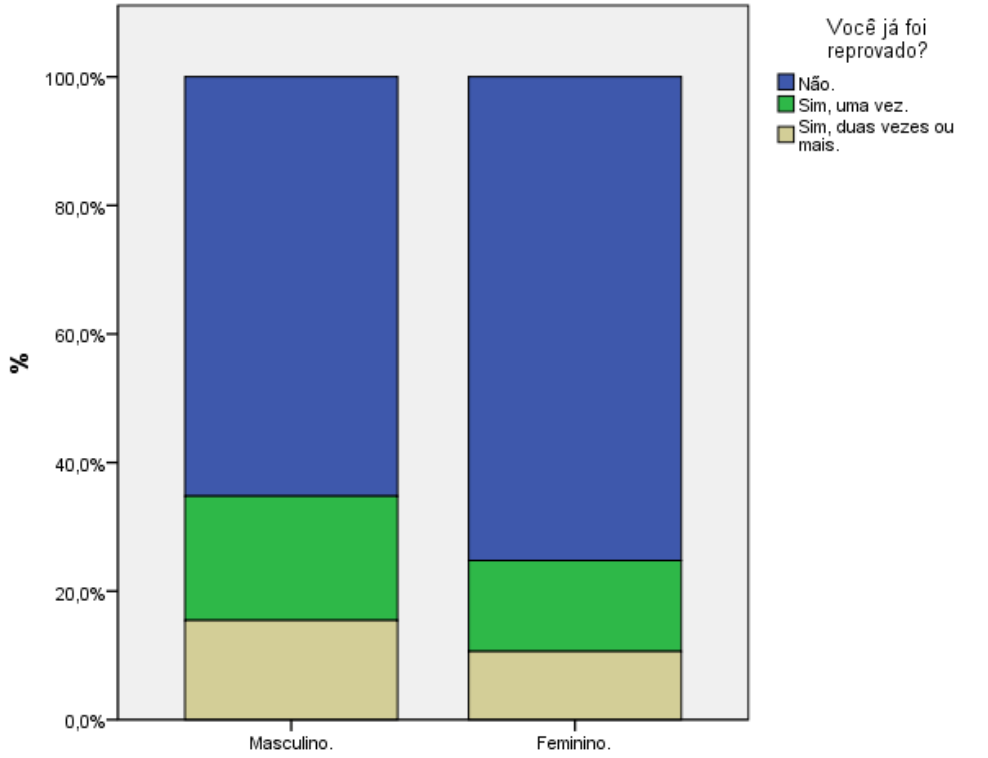
			Statistic	Std. Error
PROFICIENCIA_MT_SAEB	Mean		264.2252	.44469
	95% Confidence Interval for Mean	Lower Bound	263.3535	
		Upper Bound	265.0969	
	5% Trimmed Mean		263.0261	
	Median		260.4543	
	Variance		2662,742	
	Std. Deviation		51.60177	
	Minimum		147.82	
	Maximum		449.43	
	Range		301.60	
	Interquartile Range		70.53	
	Skewness		,351	,021
	Kurtosis		-,035	,042

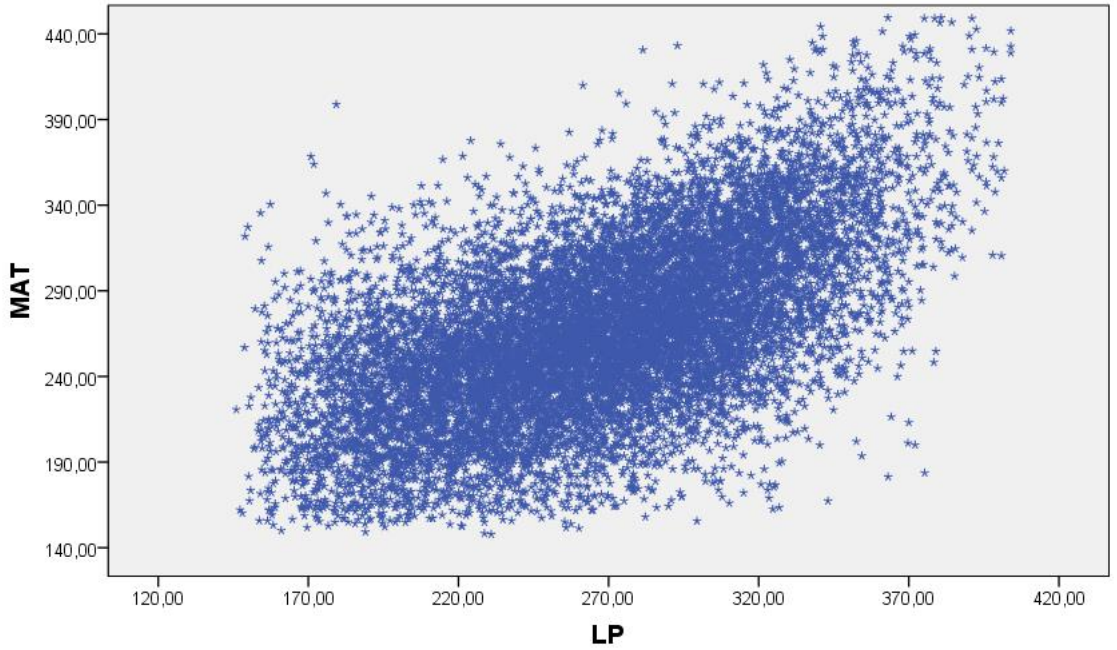
ESTATÍSTICA DESCRITIVA

BIDIMENSIONAL

ESTUDOS DE ASSOCIAÇÃO







ESTUDOS DE ASSOCIAÇÃO – ANÁLISE BIDIMENSIONAL

De acordo com a situação, as técnicas de análise de dados são diferentes para cada tipo de variável envolvida:

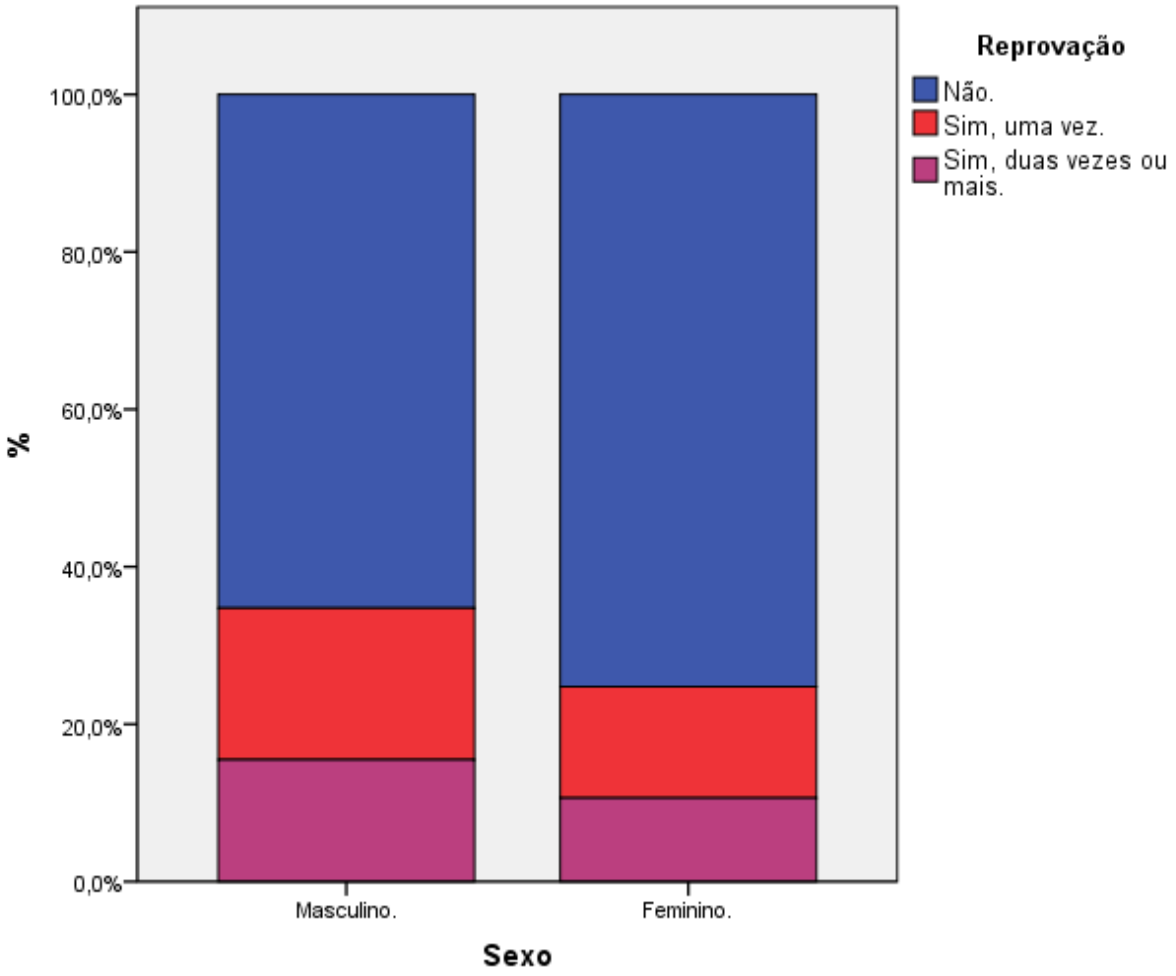
- 2 variáveis quantitativas: os dados são resumidos em gráficos de dispersão (coeficiente de correlação linear de Pearson, coeficiente de Spearman);

- 2 variáveis qualitativas: os dados são resumidos em tabelas de contingência ou de dupla entrada (estatística qui-quadrado, coeficiente de contigência, gamma de Goodman,...);
- Uma variável quanti e outra quali: comparação com gráficos apresentados (histograma, box-plot) e medida R^2.

ESTUDOS DE ASSOCIAÇÃO – ANÁLISE BIDIMENSIONAL

Objetivo: encontrar associação ou relação entre as variáveis. Essas relações podem ser identificadas apor gráficos ou medidas numéricas.

Associação: mudança de opinião sobre o comportamento de uma variável na presença ou não de informação sobre a segunda variável.

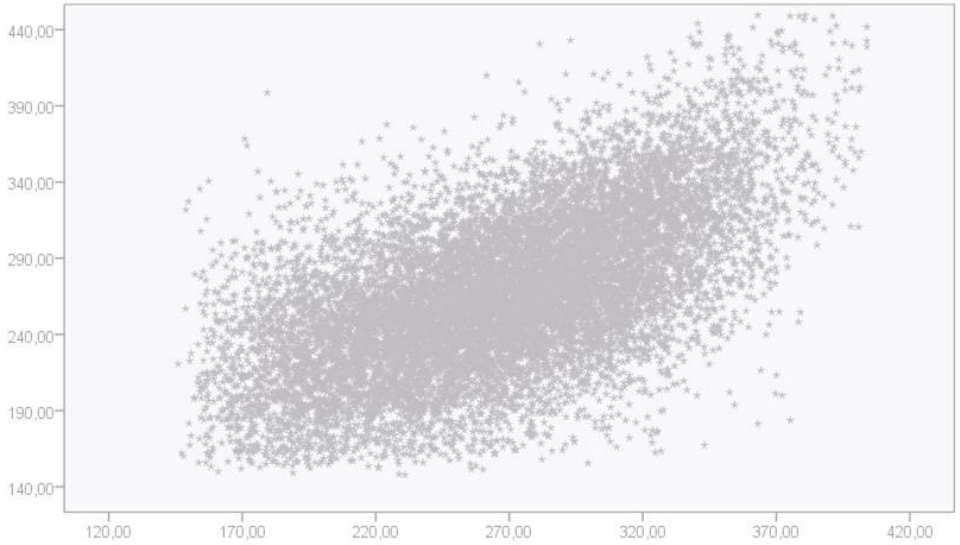


ASSOCIAÇÃO – VARIÁVEIS QUANTITATIVAS

ASSOCIAÇÃO – VARIÁVEIS QUANTITATIVAS

Diagrama de dispersão: recurso gráfico que nos permite visualizar o comportamento conjunto das duas variáveis.

Coeficiente de correlação: mede a intensidade da associação existente entre as variáveis.

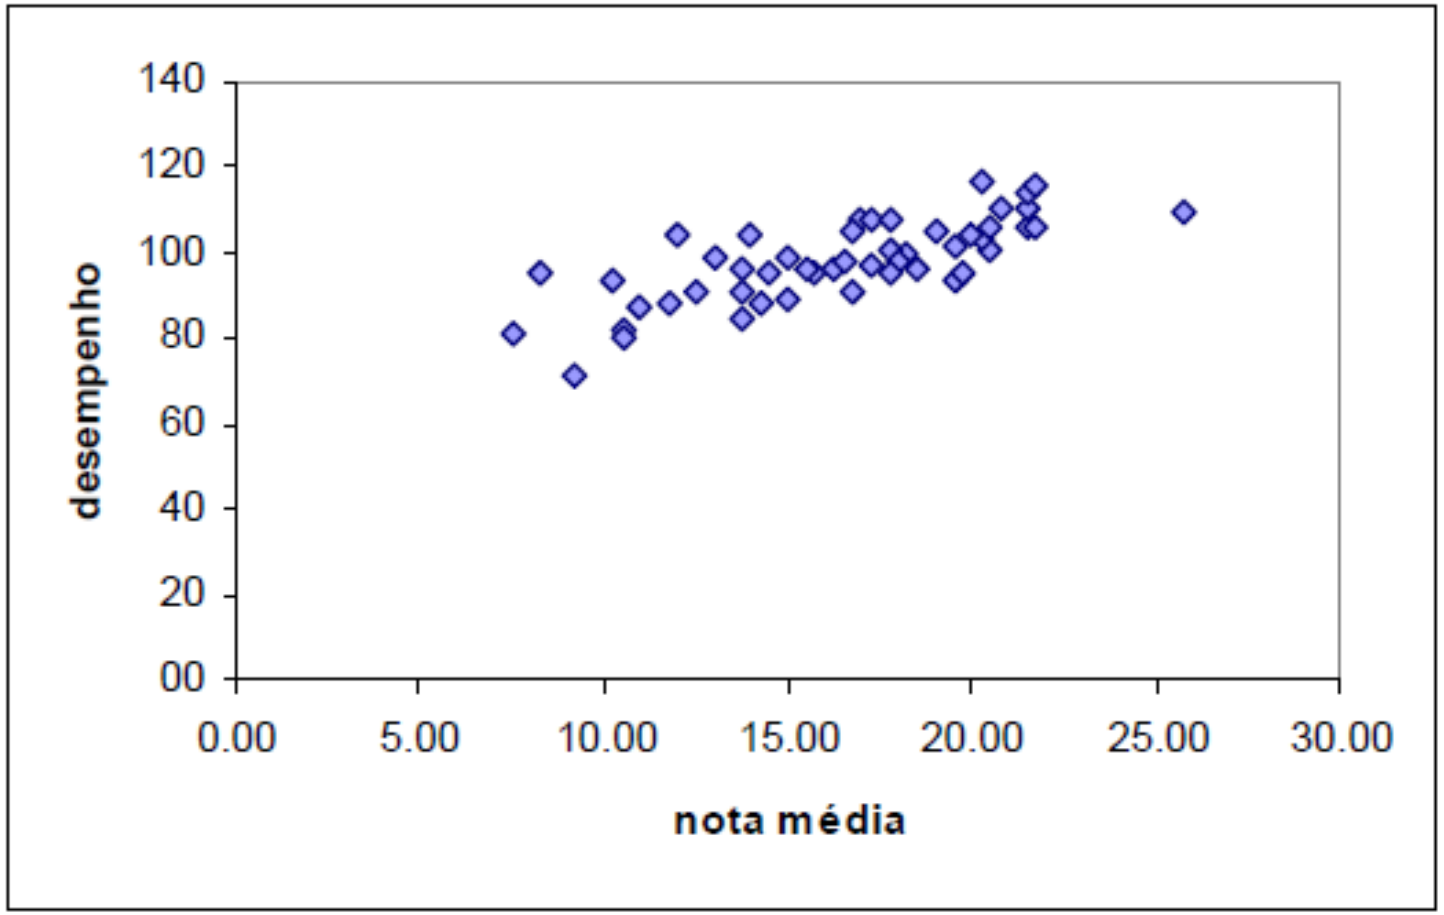


EXEMPLO – TESTE DE ADMISSÃO

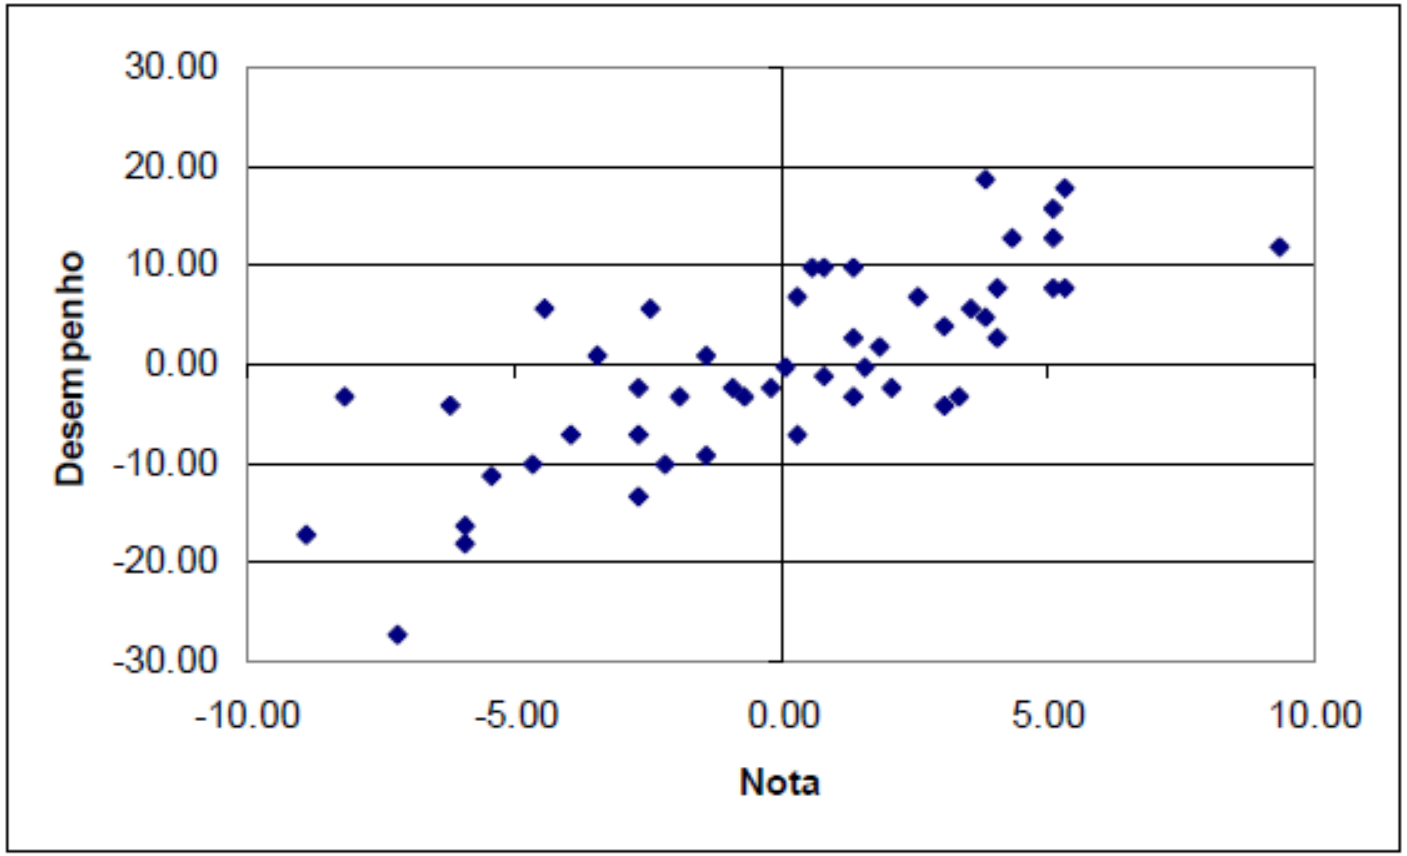
O departamento de RH de uma empresa deseja avaliar a eficácia dos testes aplicados para a seleção de funcionários. Para tanto, foi sorteada uma amostra de 50 funcionários e observou-se, para cada um, a nota média nos testes de Criatividade, Raciocínio mecânico, Raciocínio abstrato e Habilidade Matemática (notas de 0 a 26) e um escore que indica o seu desempenho profissional (0 a 120).

Existe alguma relação entre a nota do teste e o desempenho dos funcionários?

EXEMPLO – TESTE DE ADMISSÃO

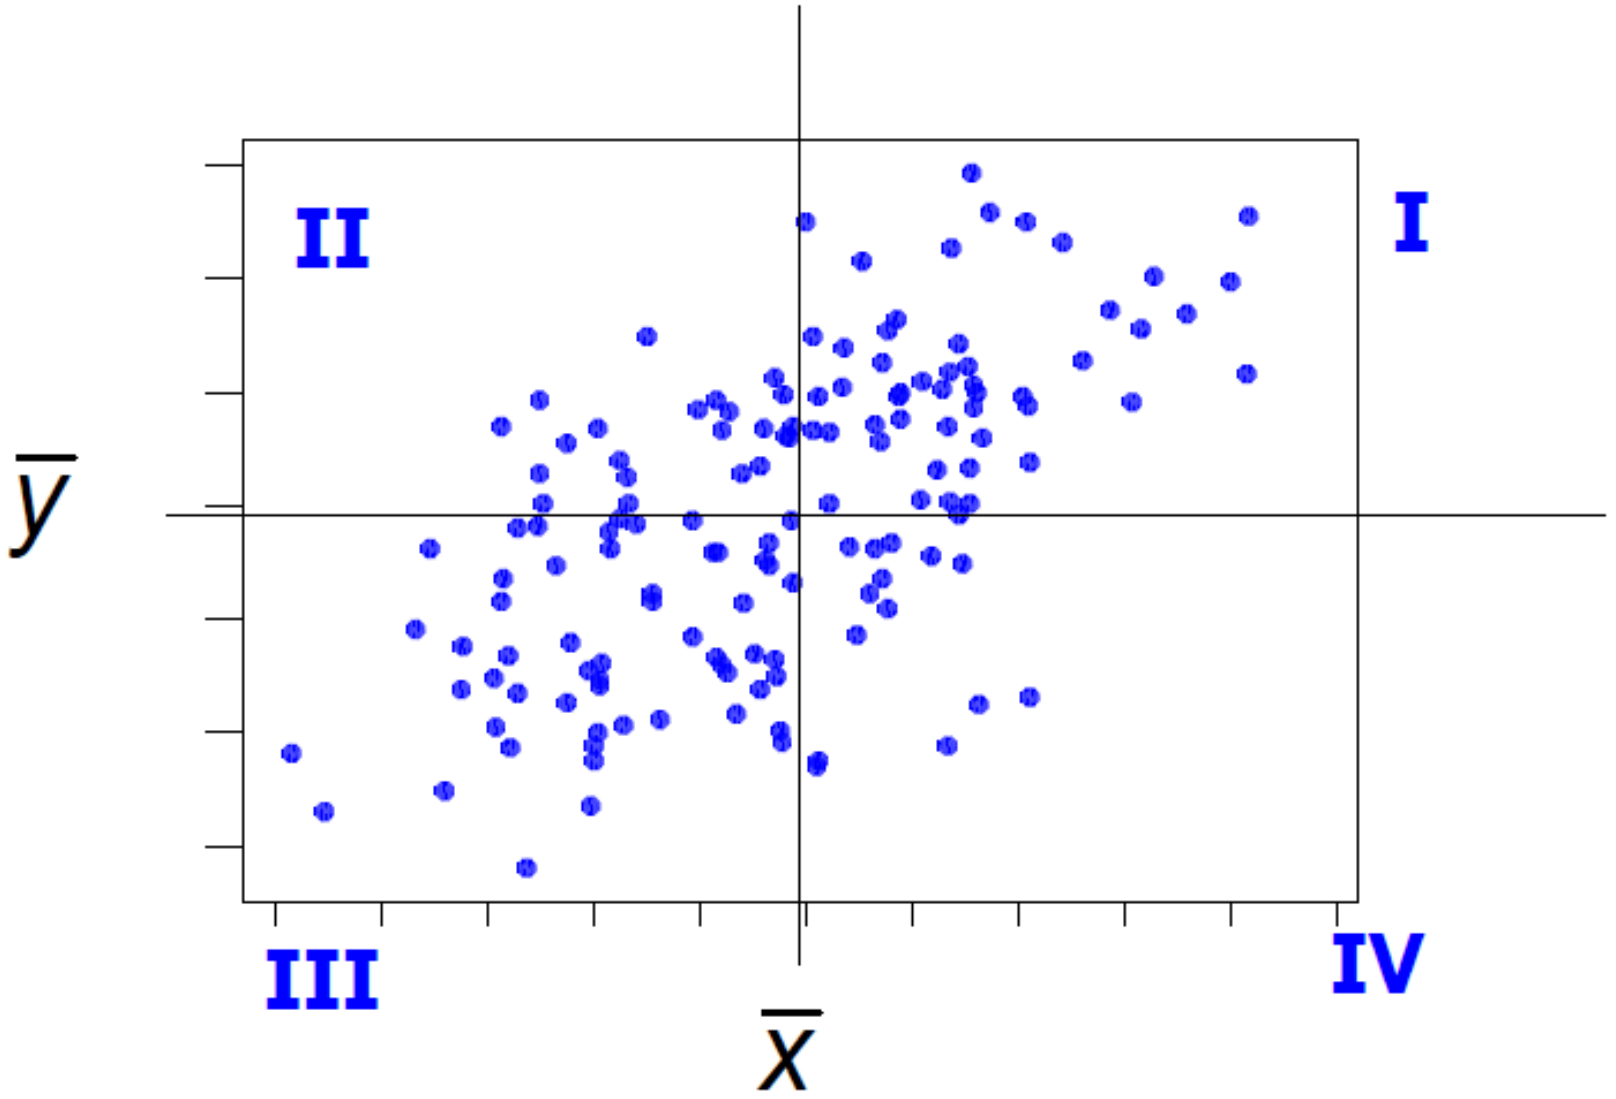


EXEMPLO – TESTE DE ADMISSÃO



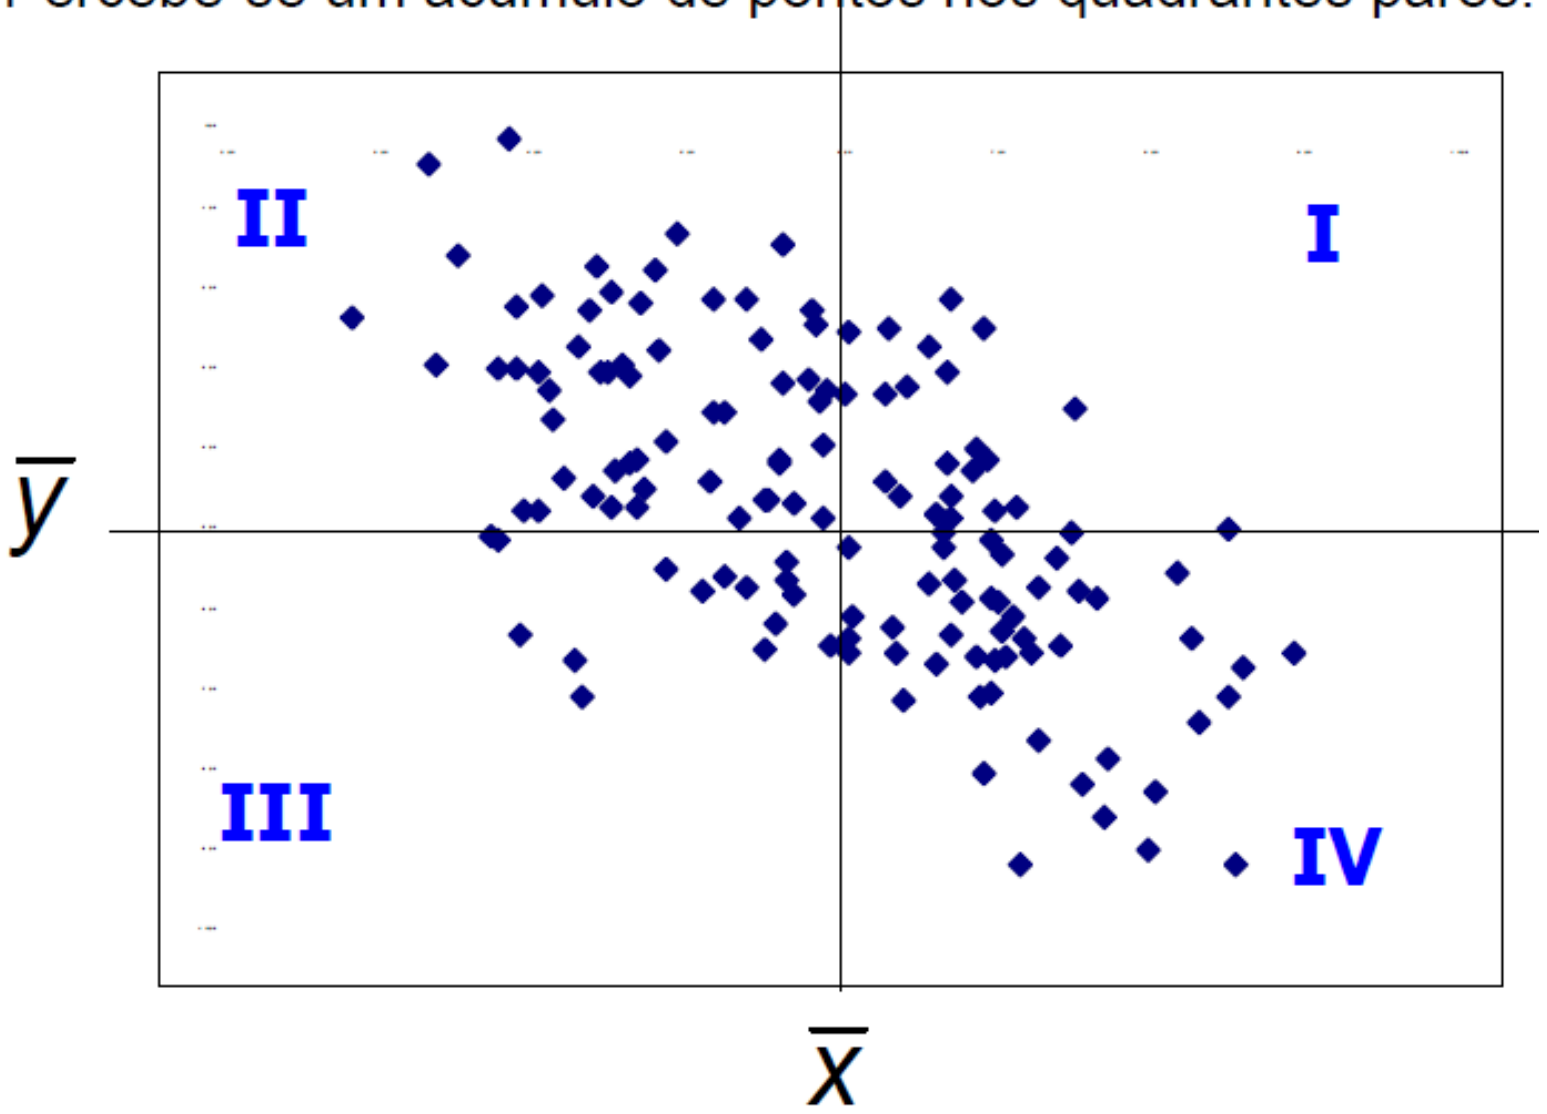
ASSOCIAÇÃO POSITIVA

Percebe-se um acúmulo de pontos nos quadrantes ímpares.



SE FOSSE NEGATIVA...

Percebe-se um acúmulo de pontos nos quadrantes pares.

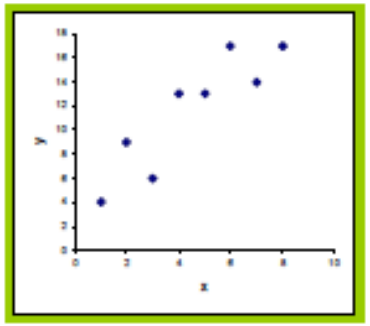


ASSOCIAÇÃO

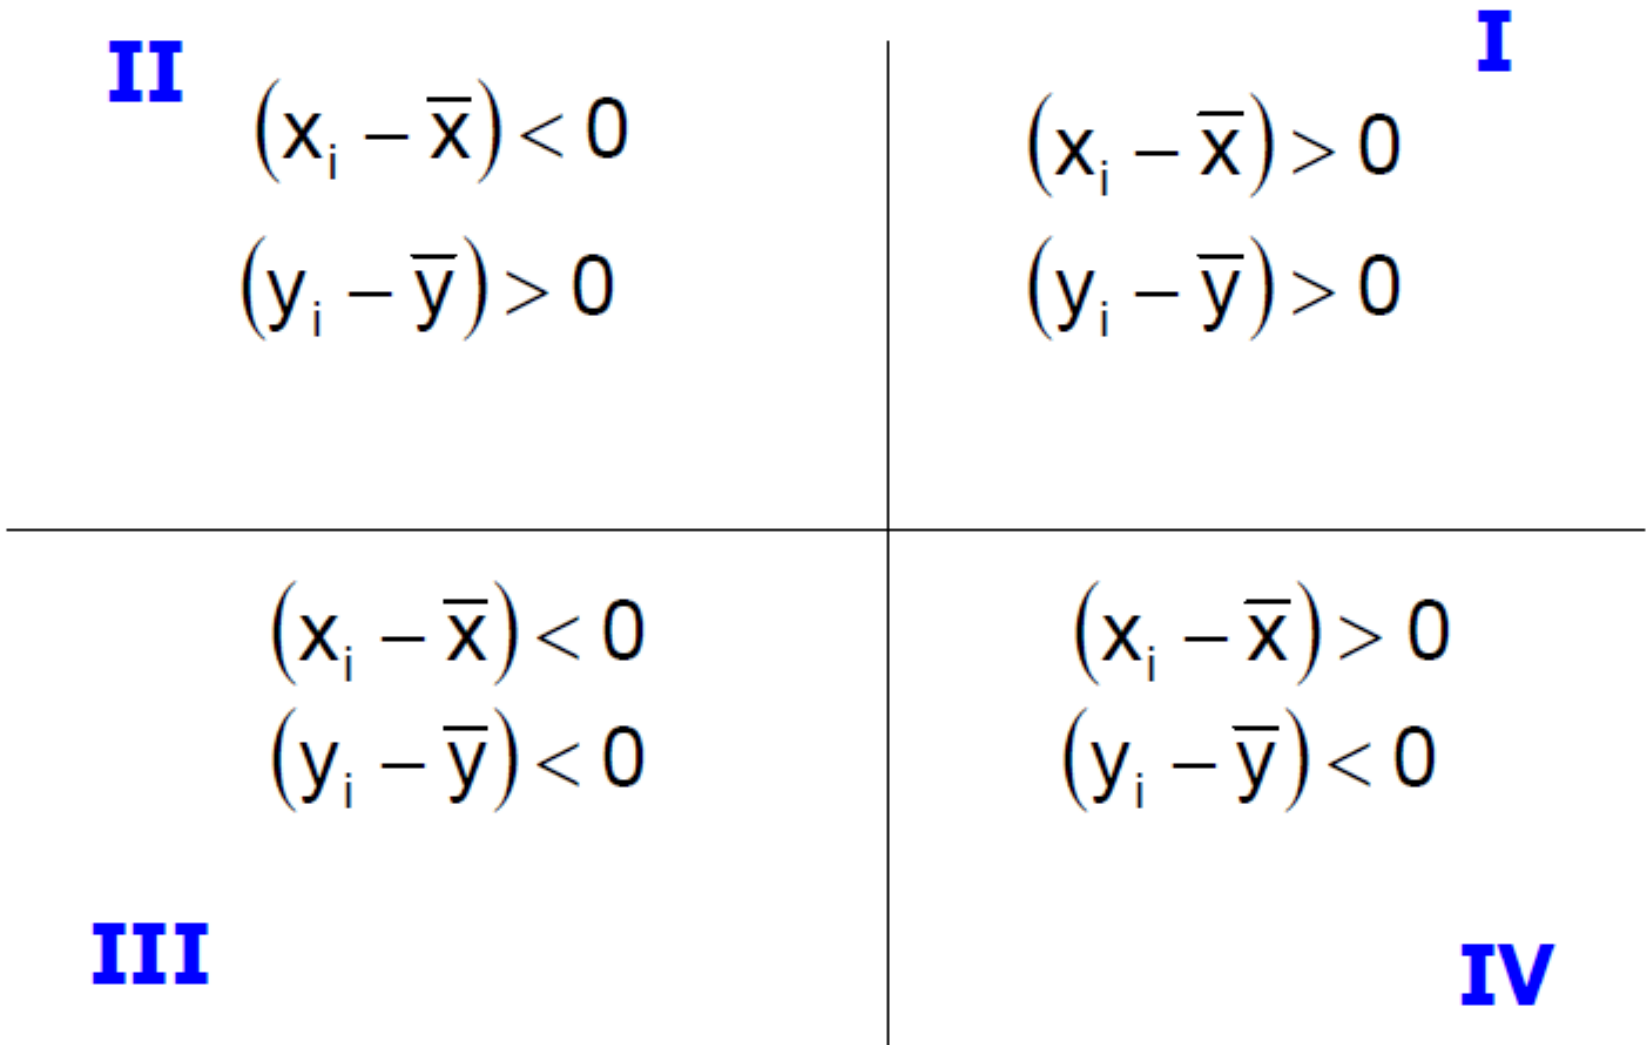
- Quando existe uma associação positiva (crescente) entre as variáveis, há um predomínio de pontos nos quadrantes ímpares.

- Quando existe uma associação negativa (decrescente) entre as variáveis, há um predomínio de pontos nos quadrantes pares.

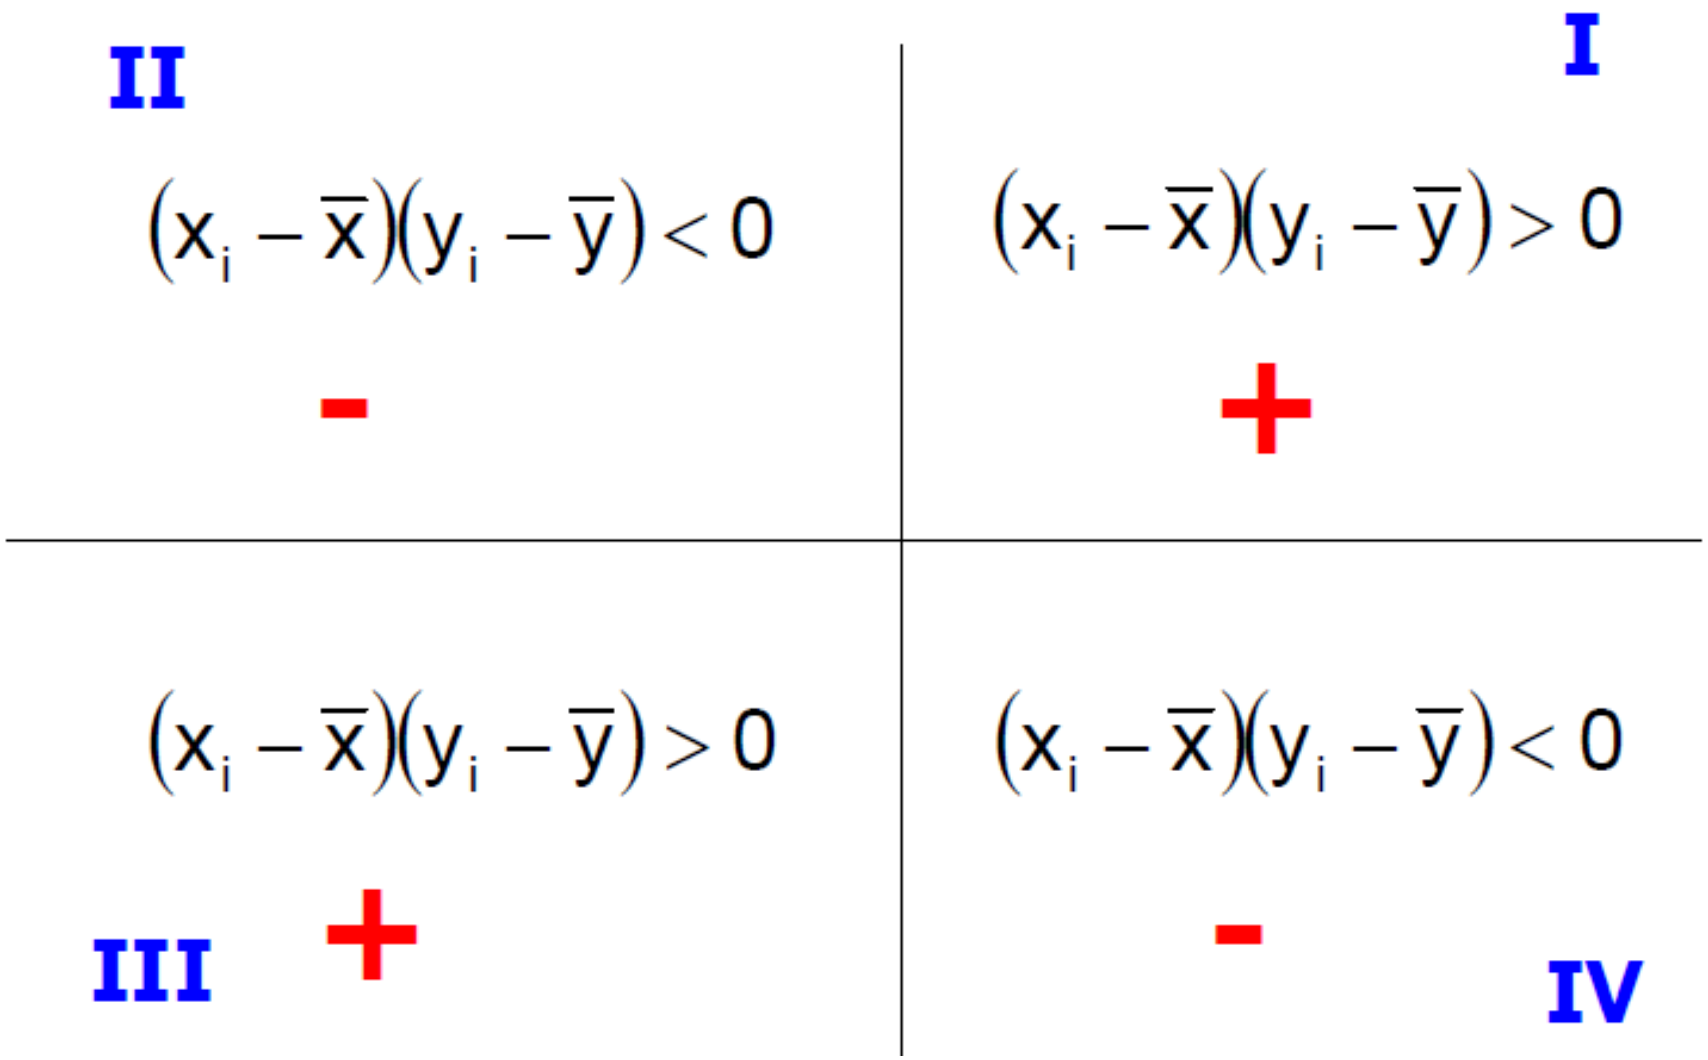
- Quanto mais próxima de uma reta estiverem os pontos, maior é o predomínio nos quadrantes ímpares (se crescente) ou pares (se decrescente).



ASSOCIAÇÃO


II
$(x_i - \bar{x}) < 0$
$(y_i - \bar{y}) > 0$
I
$(x_i - \bar{x}) > 0$
$(y_i - \bar{y}) > 0$
$(x_i - \bar{x}) < 0$
$(y_i - \bar{y}) < 0$
III
$(x_i - \bar{x}) > 0$
$(y_i - \bar{y}) < 0$
IV

ASSOCIAÇÃO


II
I
$(x_i - \bar{x})(y_i - \bar{y}) < 0$
$(x_i - \bar{x})(y_i - \bar{y}) > 0$
-
+
$(x_i - \bar{x})(y_i - \bar{y}) > 0$
$(x_i - \bar{x})(y_i - \bar{y}) < 0$
III
+
-
IV

COEFICIENTE DE COVARIÂNCIA

$$S_{XY} = \sum_{i=1}^{n} \frac{(x_i - \bar{x})(y_i - \bar{y})}{n}$$

$S_{XY} > 0$ se a associação linear for positiva.

$S_{XY} < 0$ se a associação linear for negativa.

$S_{XY} = 0$ indica que não existe associação linear positiva, nem negativa, mas pode existir outro tipo de associação.

Quanto mais próximos de uma reta estiverem os pontos, mais distante de zero estará S_{XY}.

COEFICIENTE DE COVARIÂNCIA

No exemplo:

$$\text{Cov(Nota, Desempenho)} = S_{XY} = 29{,}48$$

Este valor reflete a associação linear entre a nota média no teste de admissão e o desempenho dos funcionários. O que pode-se concluir é que existe relação linear positiva entre as 2 variáveis.

Problema: Quão grande é esta relação????

COEFICIENTE DE CORRELAÇÃO LINEAR

$$r = \frac{S_{XY}}{S_X S_Y} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{n.DP(X)DP(Y)}$$

Vantagem com relação ao coeficiente de covariância:

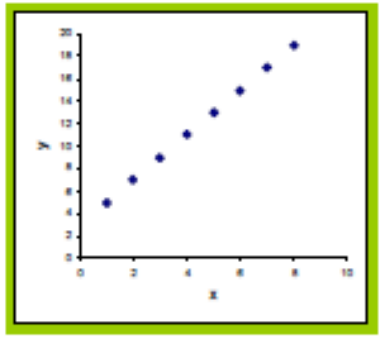
$$-1 \leq r \leq 1$$

COEFICIENTE DE CORRELAÇÃO LINEAR

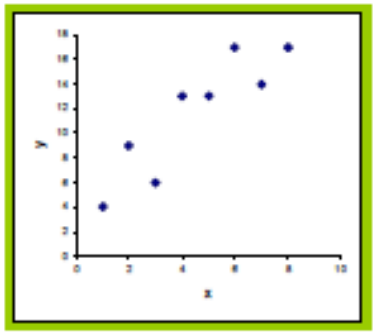
- Medida de associação linear entre duas variáveis quantitativas (varia entre –1 e +1).
- Valores próximos a +1: indicam forte relação linear positiva
- Valores próximos a -1 : indicam forte relação linear negativa
- Valores próximosa zero: indicam ausência de relação linear.

COEFICIENTE DE CORRELAÇÃO LINEAR

Relação perfeita

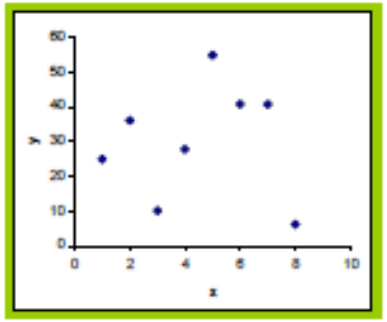


r = +1

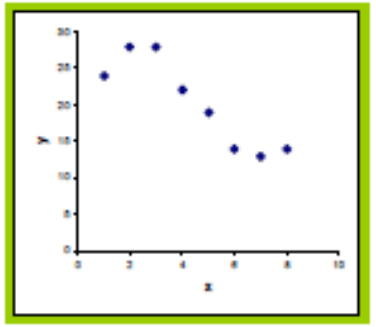


r ≈ 0,80

Ausência de relação

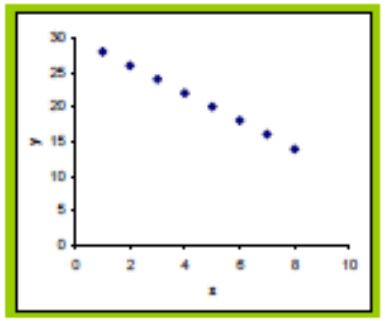


r ≈ 0



r ≈ -0,80

Relação perfeita



r = -1

COEFICIENTE DE COVARIÂNCIA

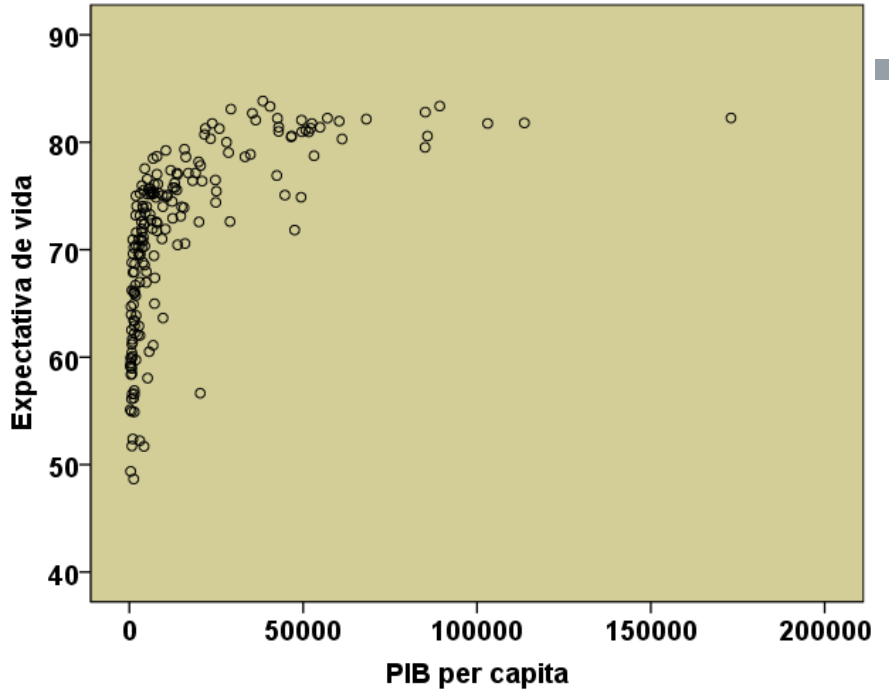


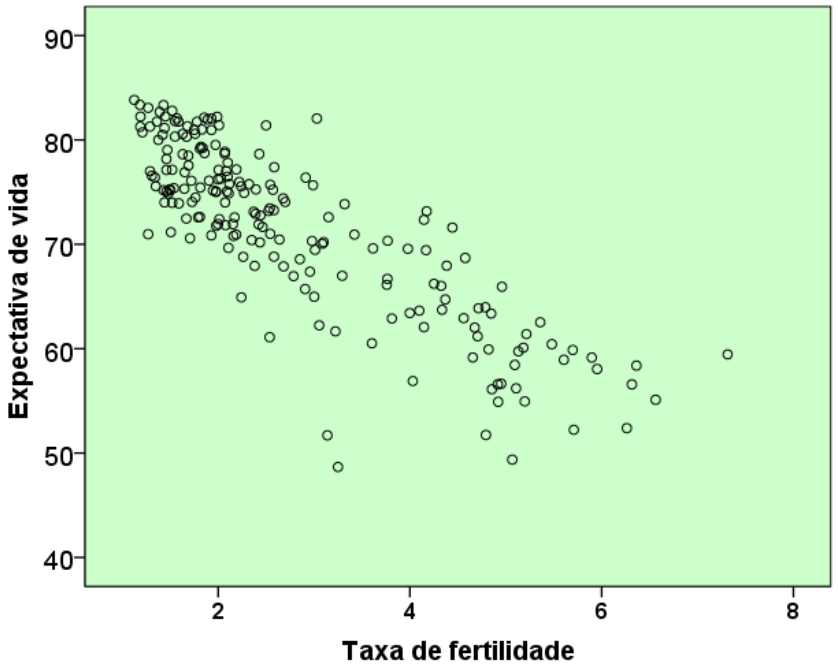
No exemplo:

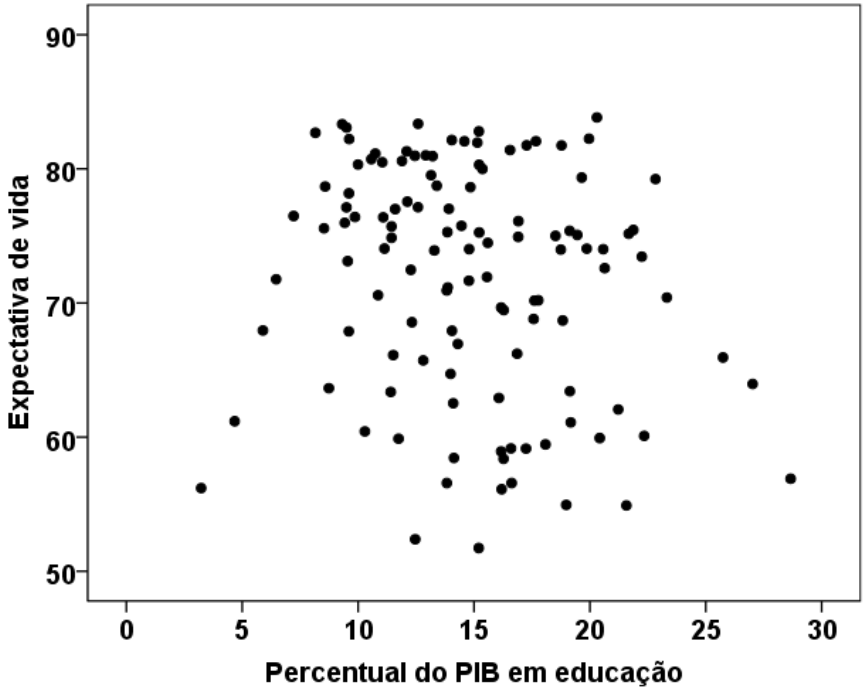
$$\text{Corr(Nota, Desempenho)} = r = 0{,}76$$

Este valor indica que a associação linear entre a nota média no teste de admissão e o desempenho dos funcionários é forte, positiva, indicando que quanto maior a nota média no teste de admissão, melhor o desempenho do funcionário.

EXEMPLO
ARQUIVO: INDICADORES MUNDO (2013)







COEFICIENTE DE CORRELAÇÃO LINEAR

- O coeficiente de correlação de Pearson é o coeficiente mais utilizado para mensurar a força da associação entre variáveis quantitativas.
- No entanto, esse coeficiente é recomendado quando a dispersão dos dados é uma nuvem "bem comportada".
- O coeficiente é sensível a assimetrias na distribuição, presença de outliers, não normalidade e não linearidade da relação.

COEFICIENTE DE CORRELAÇÃO - SPEARMAN

- Como alternativa pode-se usar o Coeficiente de Correlação de Spearman nos caso em que os dados não formam uma nuvem "bem comportada", com alguns pontos muito afastados dos restantes, ou em que parece existir uma relação crescente ou decrescente em formato de curva.

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n^3 - n}$$

COEFICIENTE DE CORRELAÇÃO - SPEARMAN

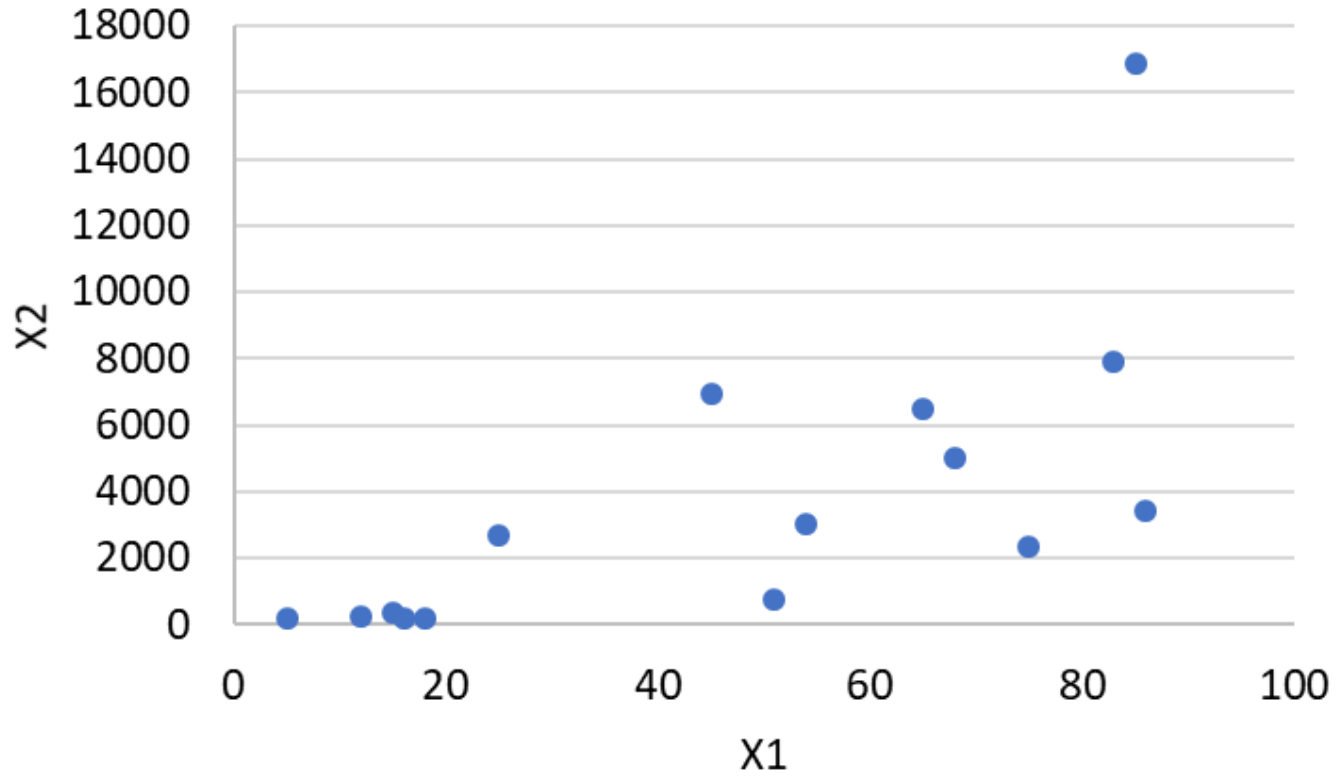
- O coeficiente é dado por:

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n^3 - n}$$

onde n é o número de pares (x_i, y_i) e

d_i=(postos de x_i dentre os valores de x)- (postos de y_i dentre os valores de y).

COEFICIENTE DE CORRELAÇÃO - SPEARMAN



Pearson	Spearman
0,68	0,77

ASSOCIAÇÃO – UMA QUANTITATIVA E UMA QUALITATIVA

ASSOCIAÇÃO

No estudo de associações entre duas variáveis, é comum analisar o comportamento uma VARIÁVEL QUANTITATIVA em cada categoria da VARIÁVEL QUALITATIVA.

Exemplos:

- Salário (em reais) x Nível de escolaridade (Nenhuma, Básico, Médio, Superior)
- Desempenho acadêmico (nota 0-10) x Sexo
- Peso (kg) x Sexo
- Nível de colesterol (mg/dL) x Hábito de fumar (Sim/Não)

ASSOCIAÇÃO

Podemos definir o grau de associação entre as duas variáveis como o ganho relativo na variância, obtido pela introdução da variável qualitativa. Explicitamente:

$$R^2 = \frac{var(X) - \overline{var(X)}}{var(X)} = 1 - \frac{\overline{var(X)}}{var(X)}$$

onde $var(X)$ é a variância de X (quantitativa) e $\overline{var(X)}$ é a variância média de X nas categorias da variável qualitativa.

$$\overline{var(X)} = \frac{\sum_{i=1}^{k} n_i . var(X_i)}{\sum_{i=1}^{k} n_i}$$

k é o número de categorias da variável qualitativa e n_i é o número de observações da categoria i.

ASSOCIAÇÃO

Note que $0 \leq R^2 \leq 1$. O símbolo R^2 é usual em análise de variância e regressão.

Essa medida representa o grau de associação entre as duas variáveis como o ganho relativo na variância, obtido pela introdução da variável qualitativa.

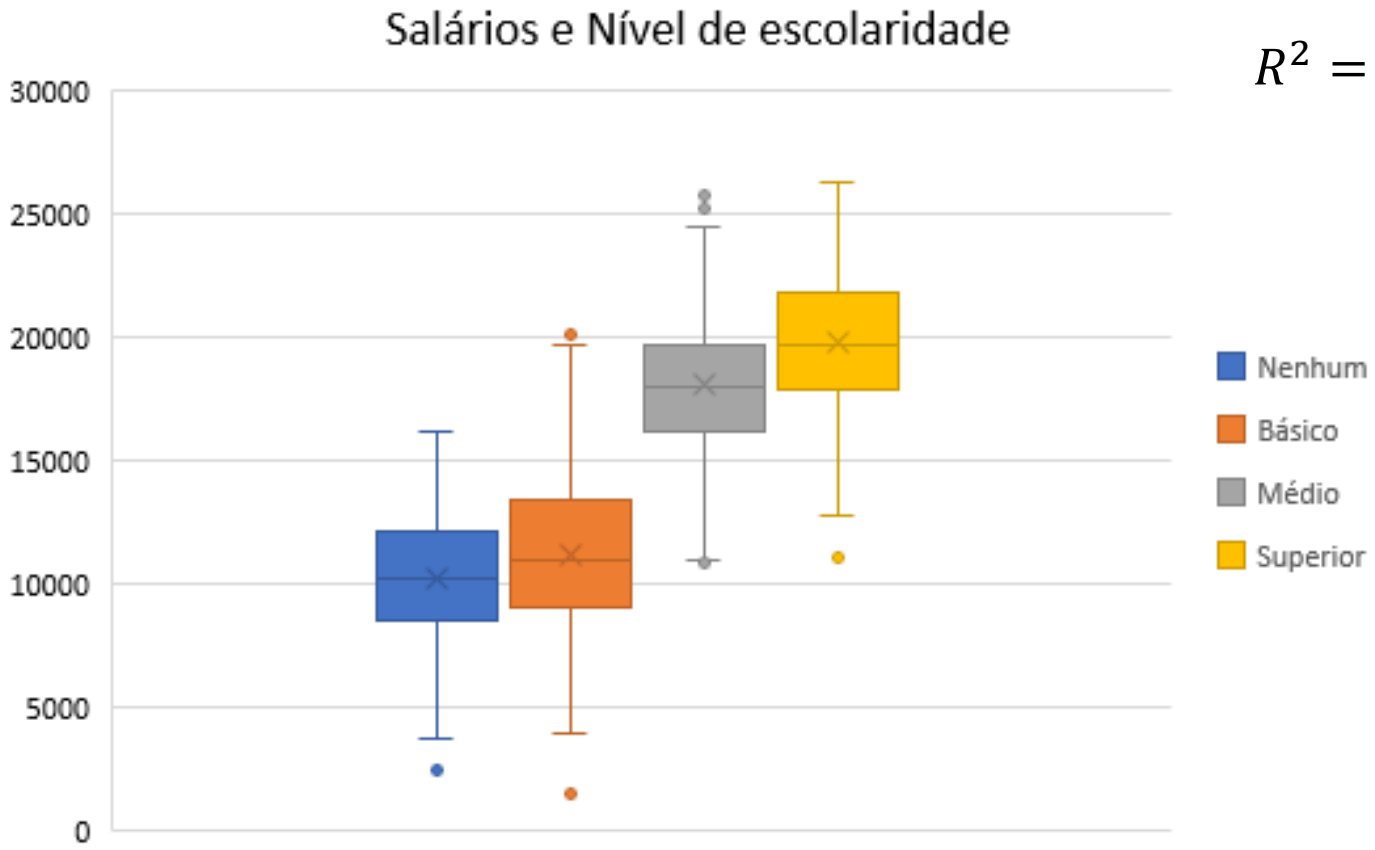
$$R^2 = \frac{var(X) - \overline{var(X)}}{var(X)} = 1 - \frac{\overline{var(X)}}{var(X)}$$

OBSERVAÇÃO: Além do coeficiente R^2 a associação pode ser descrita e explorada por meio de medidas-resumo, histogramas, box-plots ou ramo-e-folhas.

ASSOCIAÇÃO

	Nenhum	Básico	Médio	Superior
Média	10191,1	11132,5	18038,6	19767,5
DP	2803,1	3036,9	2821,2	2948,9

Variância geral	Variância média	R2
25.889.595,49	8.433.883,19	0,674



$$R^2 = 1 - \frac{8.433.883,19}{25.889.595,49} = 0,405$$