ESTATÍSTICA EXPLORATÓRIA

EST0033

Luís Gustavo do Amaral Vinha

1° semestre de 2024

Unidade II – aula 2

MEDIDAS RESUMO

$$\text{md}(X) = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, \text{se n é ímpar} \\ \frac{x_{\left(n/2\right)} + x_{\left(n/2+1\right)}}{2}, \text{se n é par} \end{cases}$$

$$AS_3 = \frac{m_3}{DP^3} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^3/n}{\left(\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2/n}\right)^3}$$

$$X^2 = \sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}$$

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

$$k_2 = \frac{m_4}{DP^4} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^4/n}{\left(\sum_{i=1}^{n}(x_i - \bar{x})^2/n\right)^2}$$

$$r = \frac{S_{XY}}{S_X S_Y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n.DP(X)DP(Y)}$$

$$\gamma = \frac{n_c - n_d}{n_c + n_d}$$

$$\overline{X} = \frac{\sum_{i=1}^{n} x_i}{n}$$

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n^3 - n}$$

$$\text{dp}(X) = S = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

$$CV = \frac{S}{\overline{X}} \cdot 100\%$$

$$\text{var}(X) = S^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$





$$\Delta = x_{(n)} - x_{(1)}$$

MEDIDAS RESUMO (OU MEDIDAS DESCRITIVAS)

- **Medidas de posição**
  - Medidas de tendência central - média, moda, mediana
  - Quantis/percentis
- **Medidas de dispersão** - amplitude, variância, desvio padrão, interval interquartil
- **Medidas de assimetria**
- **Medidas de curtose**

MEDIDAS DE POSIÇÃO – TENDÊNCIA CENTRAL

As medidas de posição (tendência central ou locação) são valores calculados como objetivo de representar os dados de uma forma ainda mais condensada do que usando uma tabela.

Quando o desejo é representar, por meio de um único valor, determinado conjunto de informações que variam, parece razoável escolher um valor central, mesmo que este valor seja uma abstração. Na prática, essas medidas estão relacionadas a dados quantitativos.

MÉDIA

Média Aritmética ou simplesmente média representa o valor "provável" de uma variável, por isso, é também chamada de valor esperado ou esperança matemática, quando calculada para a população.

Pode-se imaginar a média como o centro de gravidade de uma distribuição. Considere que um aluno realizou 3 provas obtendo as notas 1, 6 e 8. A nota que equilibra o desempenho do aluno é a média igual a 5.

$$\overline{X} = \frac{\sum_{i=1}^{n} x_i}{n}$$

MEDIANA

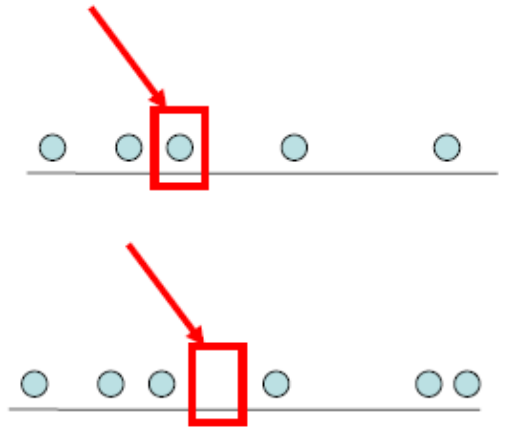
Mediana é o valor que divide um conjunto de dados ordenados ao meio. Em outras palavras, é um valor tal que tenha igual quantidade de valores menores e maiores do que ele.

Uma característica importante da mediana é que ela não é afetada por dados extremos, como acontece com a média.



MEDIANA

$$md(X) = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, \text{se n é ímpar} \\ \dfrac{x_{\left(n/2\right)} + x_{\left(n/2+1\right)}}{2}, \text{se n é par} \end{cases}$$



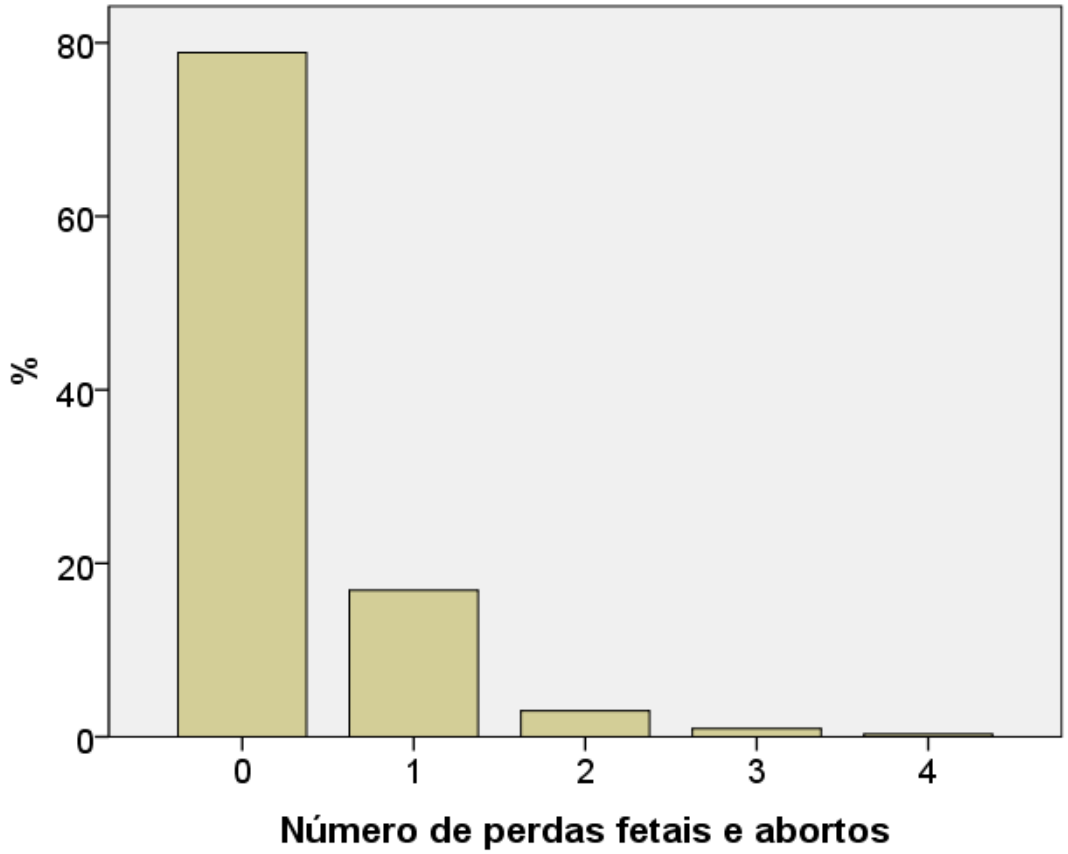
Amostra **ordenada** de n observações da variável X:

$$x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$$

MODA

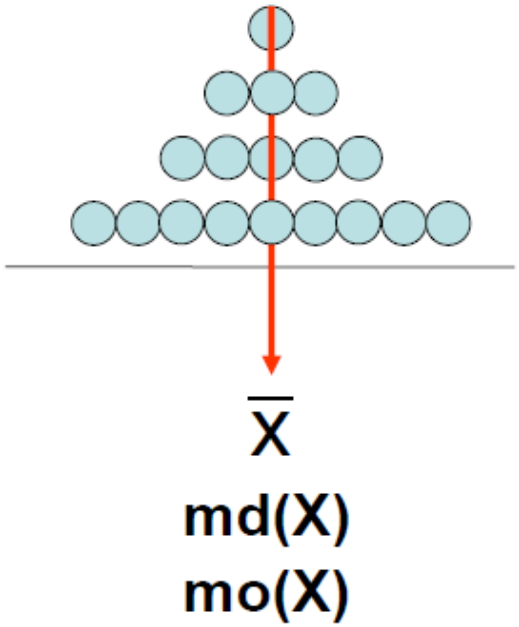
Moda é o valor que repete com maior frequência.

Número de perdas fetais ou abortos	Frequência absoluta (ni)
0	500
1	107
2	19
3	6
4	2
	634

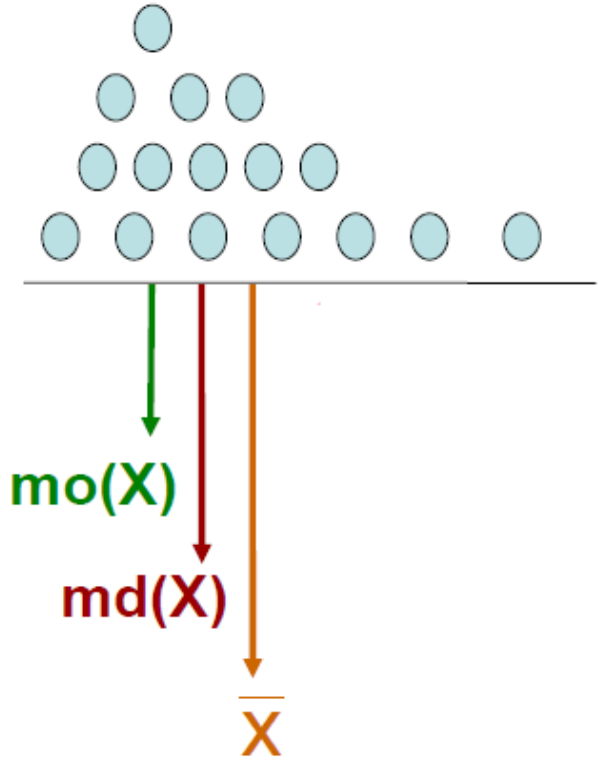


POSIÇÃO RELATIVA

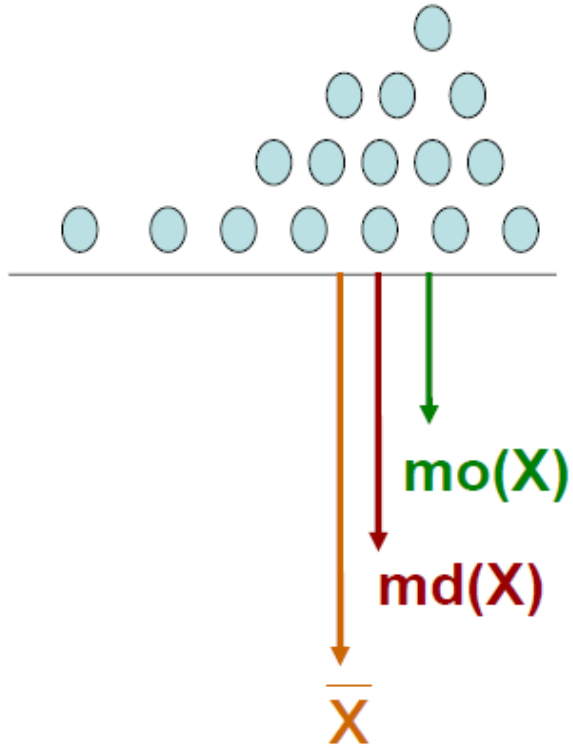
Distribuições Simétricas



Assimetria positiva



Assimetria negativa

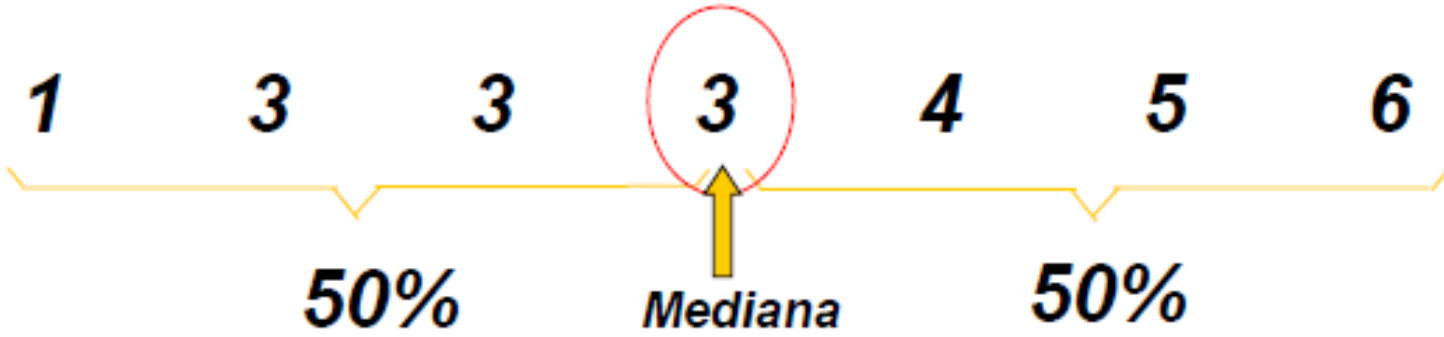


EXEMPLO: Número de computadores em 7 escritórios:

3 6 1 3 4 3 5

Média: $\overline{X} = \frac{3+6+1+3+4+3+5}{7} = 3,6$

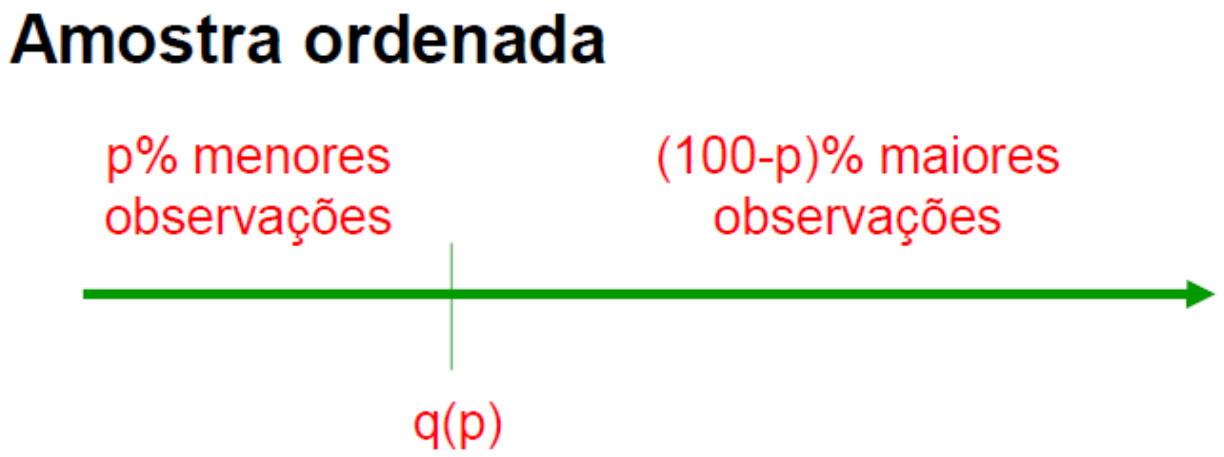
Mediana:



Moda = 3

MEDIDAS DE POSIÇÃO – QUANTIS OU PERCENTIS

Quantil ou Percentil de ordem p(0<p<1): é o valor que divide o conjunto de dados ordenado em 2 partes: uma delas com p% dos menores valores e a outra com (100-p)% dos maiores valores.



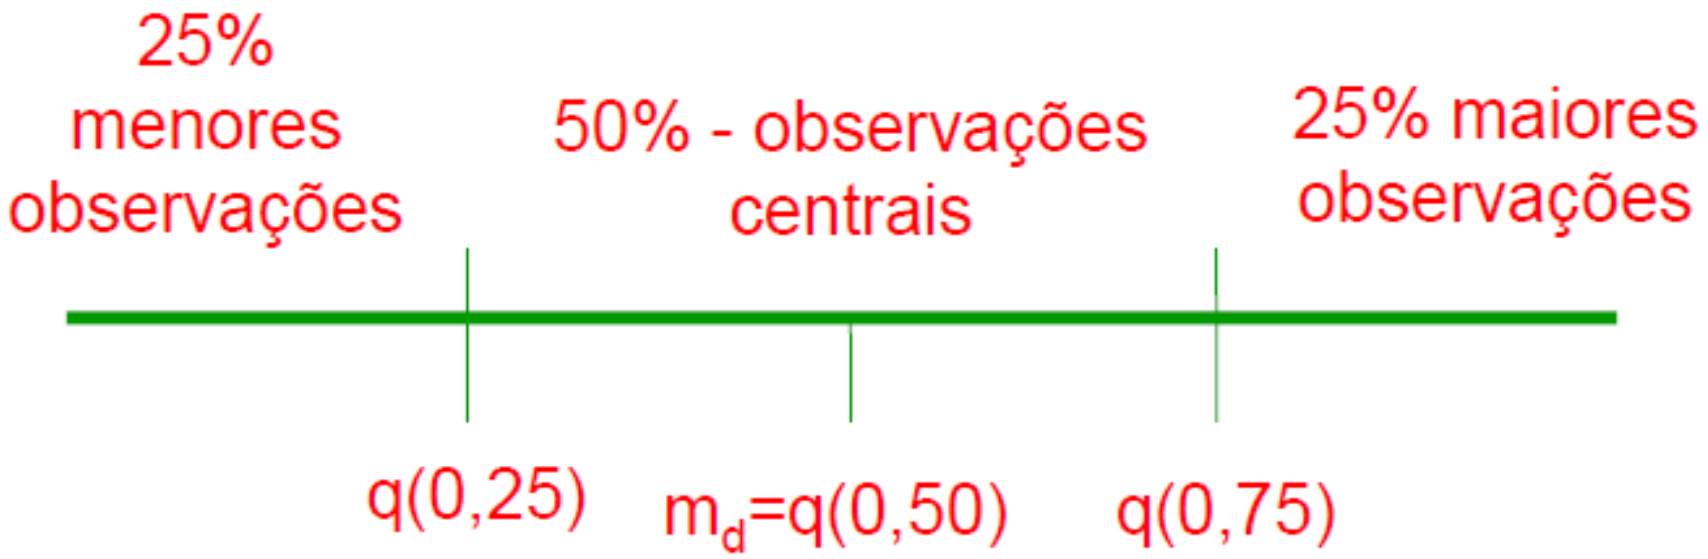
MEDIDAS DE POSIÇÃO – QUANTIS OU PERCENTIS

A empresa ABC oferece um emprego com salário de R$8.100,00 a você. Para avaliar essa oferta, você compra um jornal onde publica-se os valores dos salários de sua profissão conforme a tabela a seguir:

Percentil	Salário ($)
10%	1500
25%	2000
50%	3000
75%	4500
90%	8000

QUARTIS

Amostra ordenada



q(0,25)= Q_1: primeiro quartil

q(0,50)= Q_2: segundo quartil (mediana)

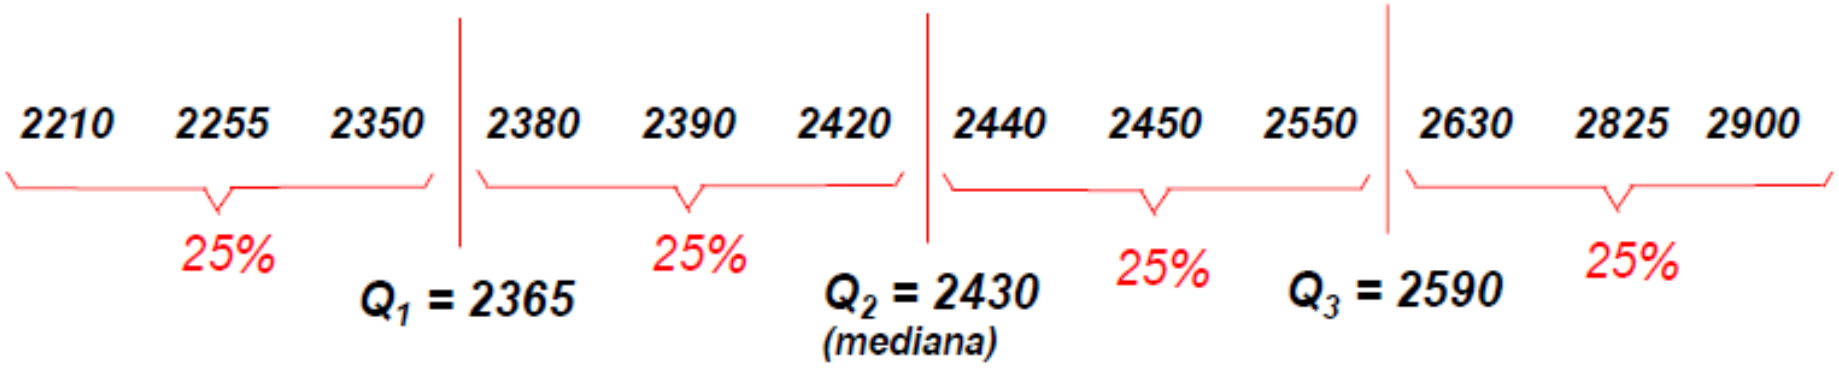
q(0,75)= Q_3: terceiro quartil

Intervalo Interquartil

$$IQ = q(0{,}75) - q(0{,}25)$$

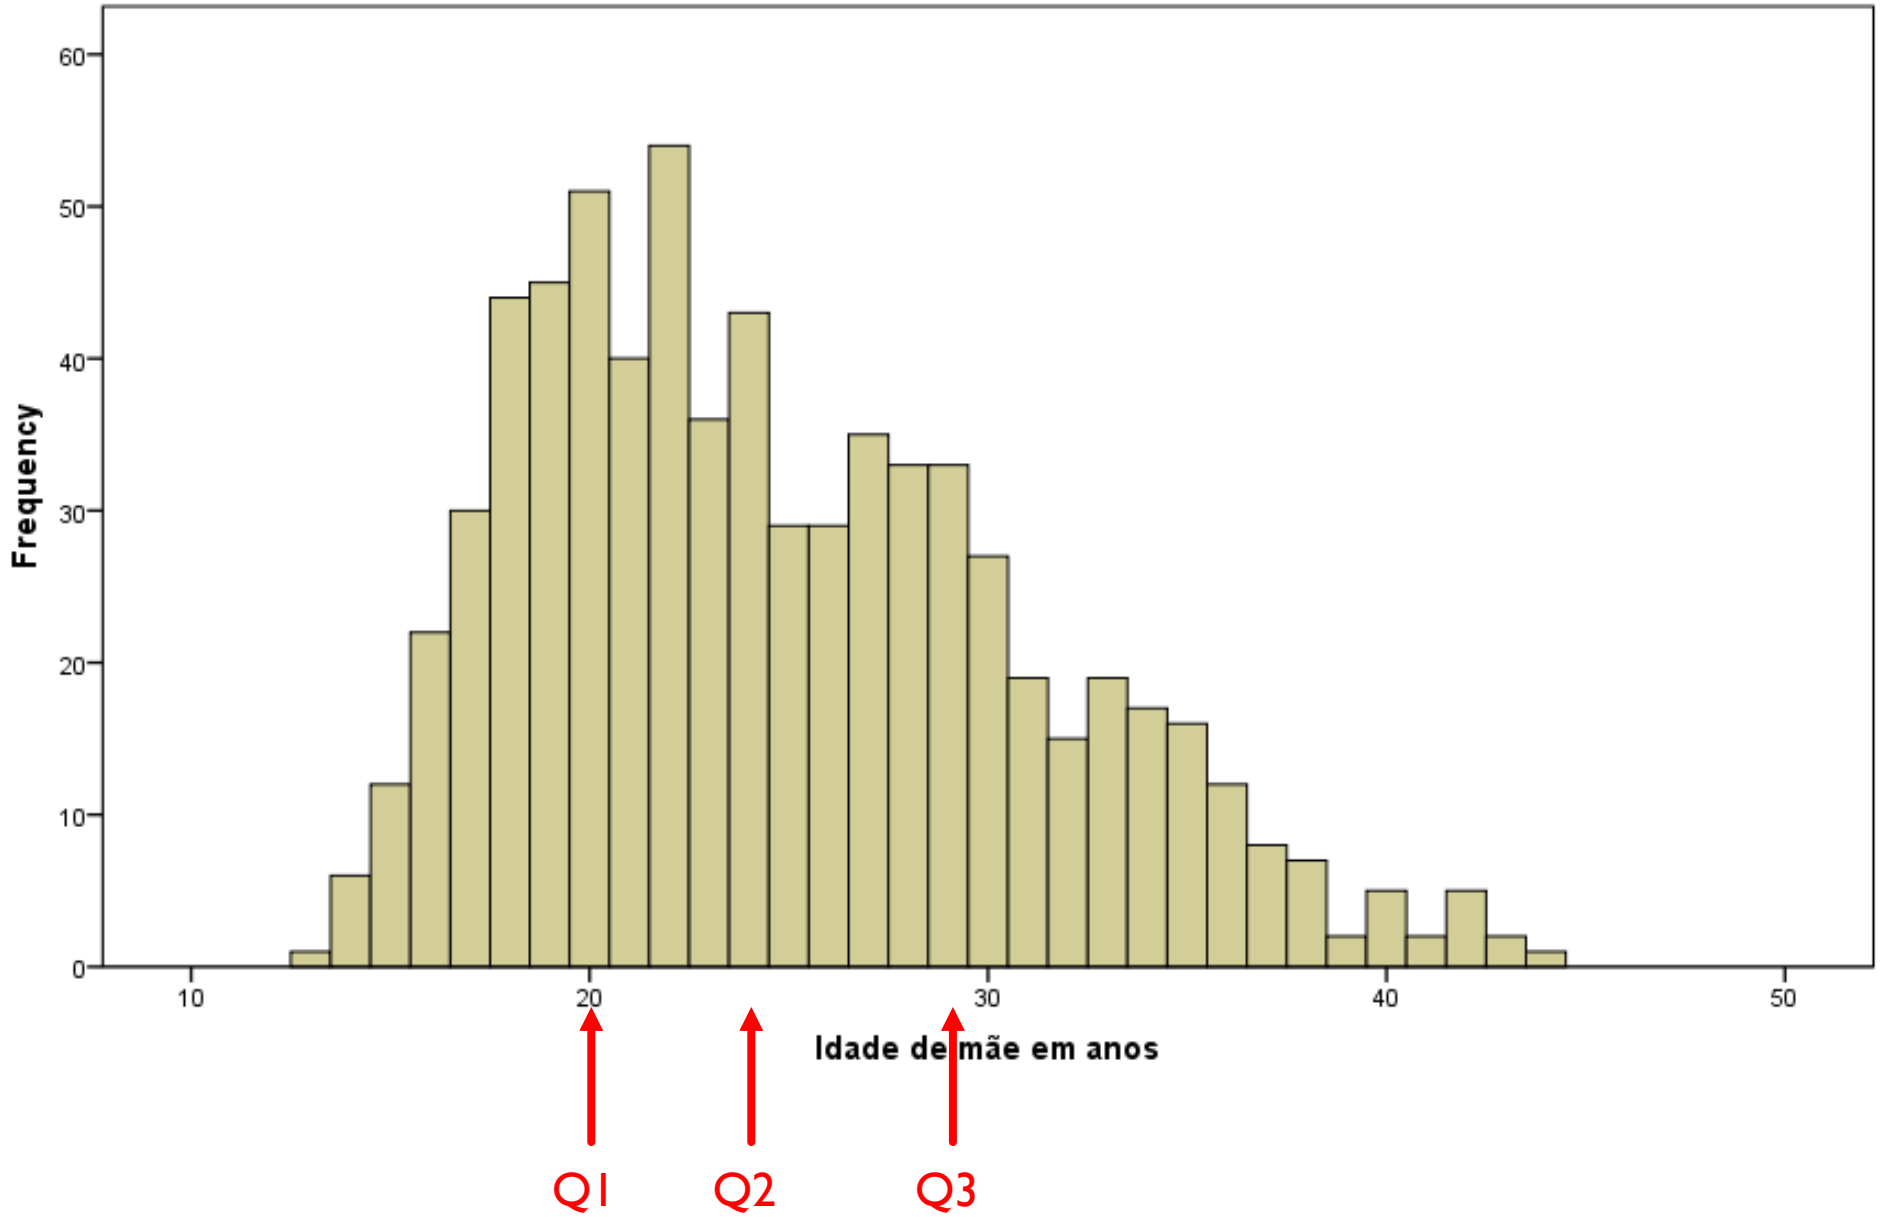
QUARTIS

Quartil: ***são valores que dividem o conjunto de dados ordenados em quatro partes iguais. Cada parte contendo 25% dos dados.***



Percentis $P_{25} = Q_1$ $P_{50} = \text{Mediana}$ $P_{75} = Q_3$

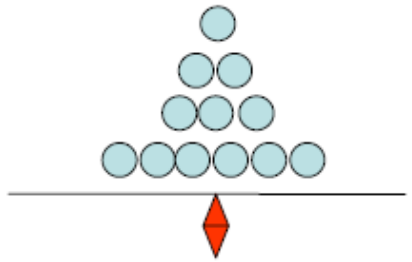
IDADE DAS MÃES

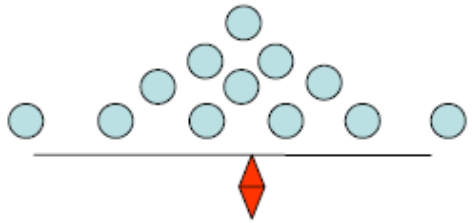


MEDIDAS DE DISPERSÃO

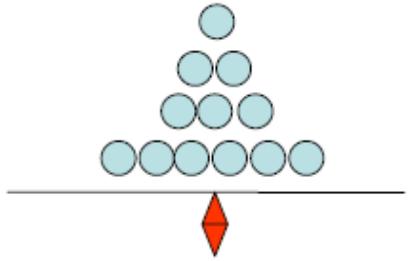
MEDIDAS DE DISPERSÃO

As medidas de dispersão apresentam a variabilidade dos valores observados. Essas medidas refletem a heterogeneidade dos indivíduos em termos da variável estudada.



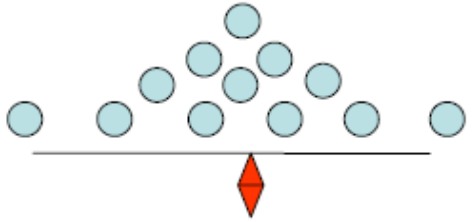


MEDIDAS DE DISPERSÃO



Baixa variabilidade

As observações estão próximas á medida de tendência central



Alta variabilidade

As observações estão mais distantes da medida de tendência central

VARIÂNCIA – DESVIO PADRÃO

A variância da amostra é a média das diferenças ao quadrado entre cada uma das observações e a média do conjunto.

Na análise descritiva, um dos problemas de usara variância como medida de dispersão é o fato de sua unidade não ser a mesma unidade em que a variável foi medida (os valores dos dados estão elevados ao quadrado). A solução é extrair a raiz quadrada positiva da variância, já que, com isso, se volta à unidade original da variável.

VARIÂNCIA – DESVIO PADRÃO

$$\mathrm{var}(X) = S^2 = \frac{\sum_{i=1}^{n} \left(x_i - \bar{x}\right)^2}{n-1}$$

VARIÂNCIA – DESVIO PADRÃO

X: idade

	19	22	23	29	34	40	44	45	46	48	55	56	67	70	78	87	89

Média amostral: 50,12 anos

x	19	22	23	29	34	40	44	45	46	48	55	56	67	70	78	87	89
(X-Média)	-31	-28	-27	-21	-16	-10	-6	-5	-4	-2	4,9	5,9	17	20	28	36,9	38,9
(X-Média)²	968	791	735	446	260	102	37	26	17	4,5	24	35	285	395	777	1360	1512

Variância amostral: 486 anos²

VARIÂNCIA – DESVIO PADRÃO

$$dp(X) = S = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n - 1}}$$

VARIÂNCIA – DESVIO PADRÃO

X: idade

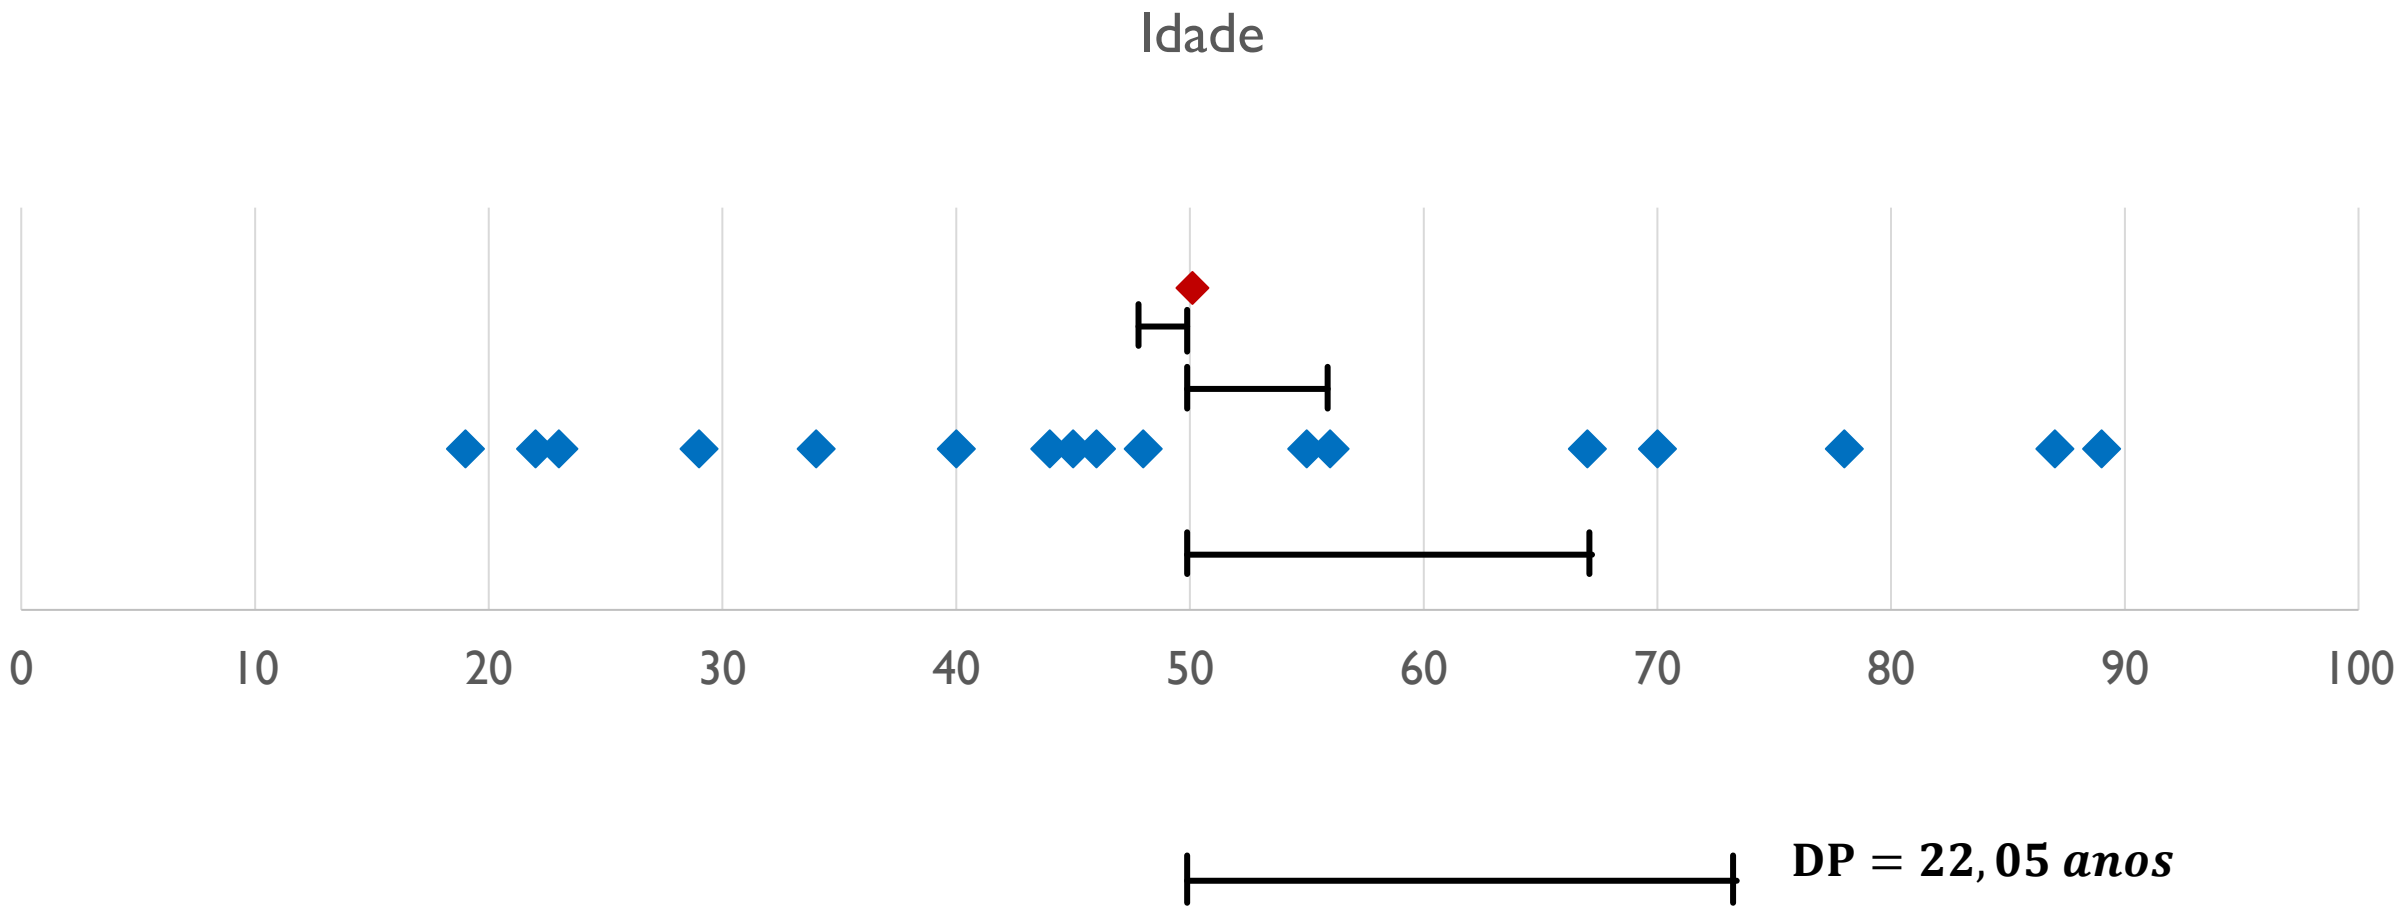
19	22	23	29	34	40	44	45	46	48	55	56	67	70	78	87	89

Média amostral: 50,12 anos

x	19	22	23	29	34	40	44	45	46	48	55	56	67	70	78	87	89
(X-Média)	-31	-28	-27	-21	-16	-10	-6	-5	-4	-2	4,9	5,9	17	20	28	36,9	38,9
(X-Média)²	968	791	735	446	260	102	37	26	17	4,5	24	35	285	395	777	1360	1512

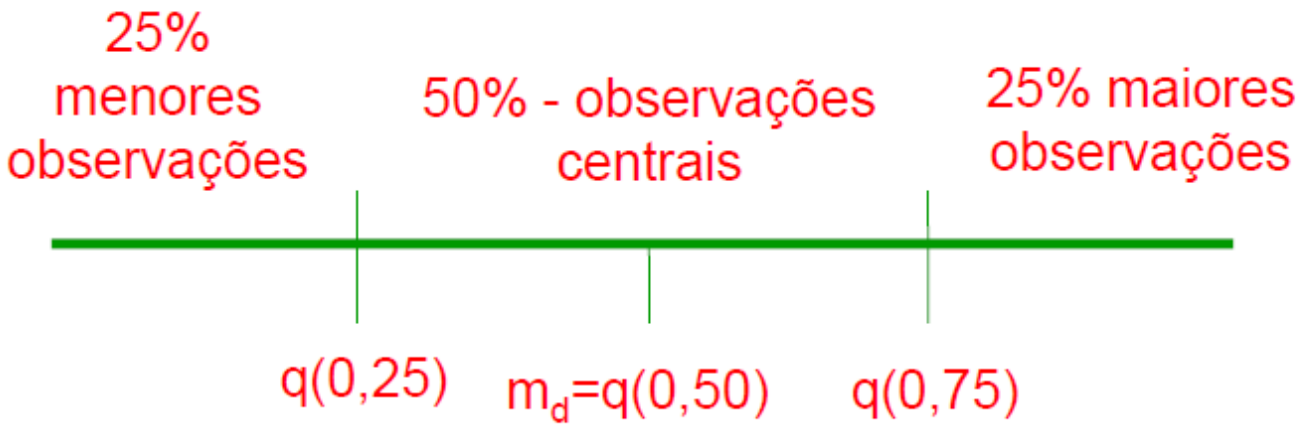
Variância amostral: 486 anos² **Desvio Padrão amostral = $\sqrt{486} = 22,05$ anos**

VARIÂNCIA – DESVIO PADRÃO



INTERVALO INTERQUARTIL

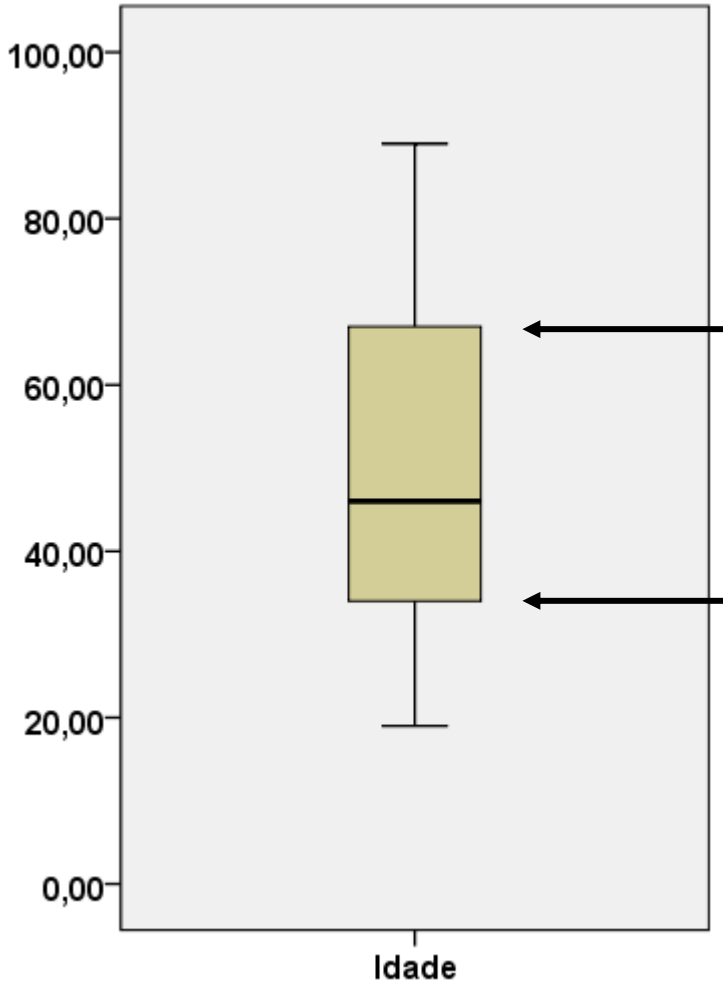
Intervalo (ou amplitude) que contém 50% dos valores centralizados.



Intervalo Interquartil

$$IQ = q(0{,}75) - q(0{,}25)$$

INTERVALO INTERQUARTIL



Q3=68,5

Q1=31,5

IIQ=Q3-Q1=68,5-31,5=37 anos

AMPLITUDE

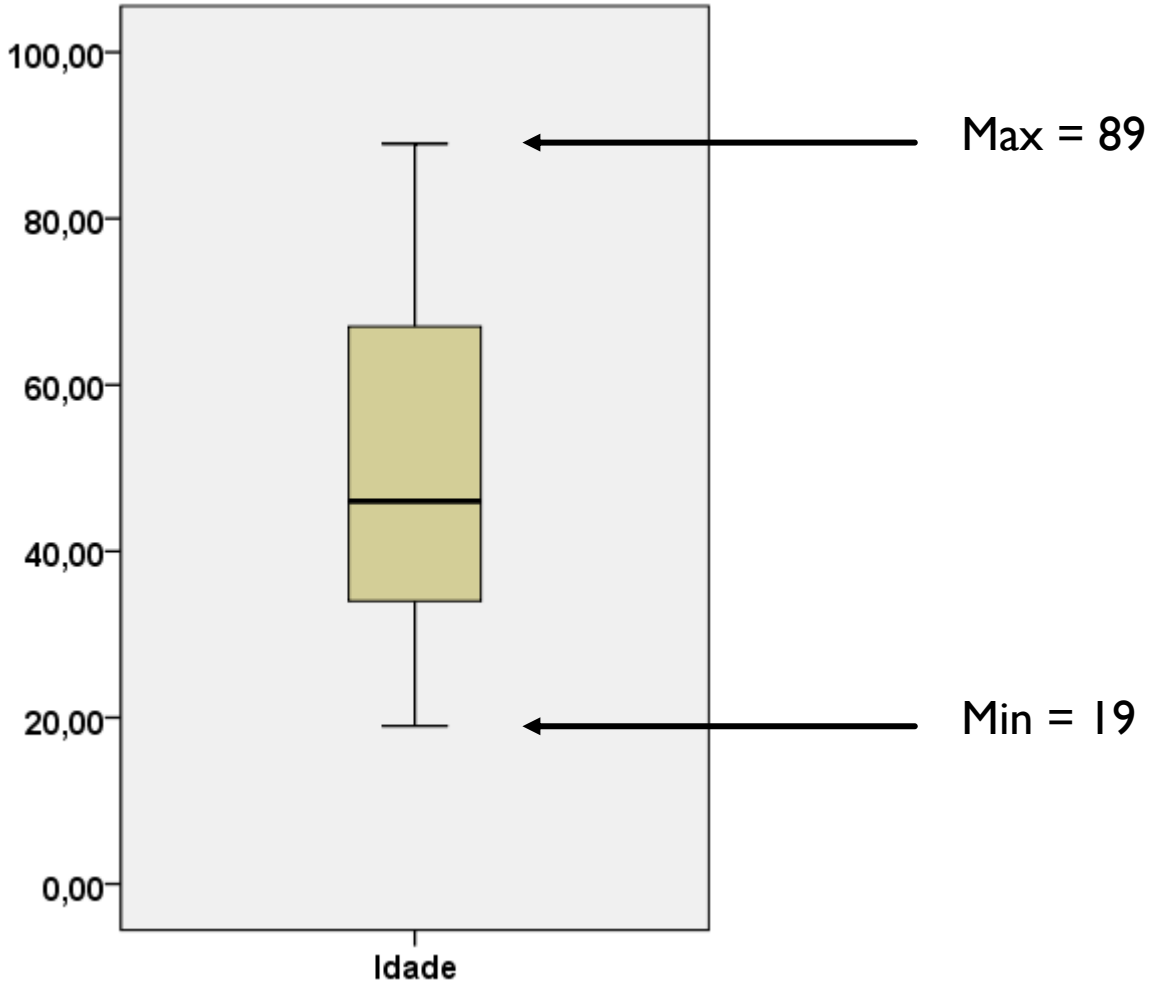
Intervalo (ou amplitude) que contém 100% dos valores. $\Delta = max - min$

X: idade

19	22	23	29	34	40	44	45	46	48	55	56	67	70	78	87	89

$$\Delta = max - min = 89 - 19 = 70$$

AMPLITUDE



Amplitude=70 anos

COEFICIENTE DE VARIAÇÃO

Coeficiente de variação (CV): é uma medida de variabilidade como uma fração em relação à média, expresso em porcentagem.

Essa medida é útil quando comparamos variabilidade de dois ou mais grupos de dados expressos em unidades de medidas diferentes ou quando a magnitude dos dados são muito díspares.

$$CV = \frac{desvio\,padrão}{média} \times 100\%$$

COEFICIENTE DE VARIAÇÃO

Coeficiente de variação (CV): é uma medida de variabilidade como uma fração em relação à média, expresso em porcentagem.

Essa medida é útil quando comparamos variabilidade de dois ou mais grupos de dados expressos em unidades de medidas diferentes ou quando a magnitude dos dados são muito díspares.

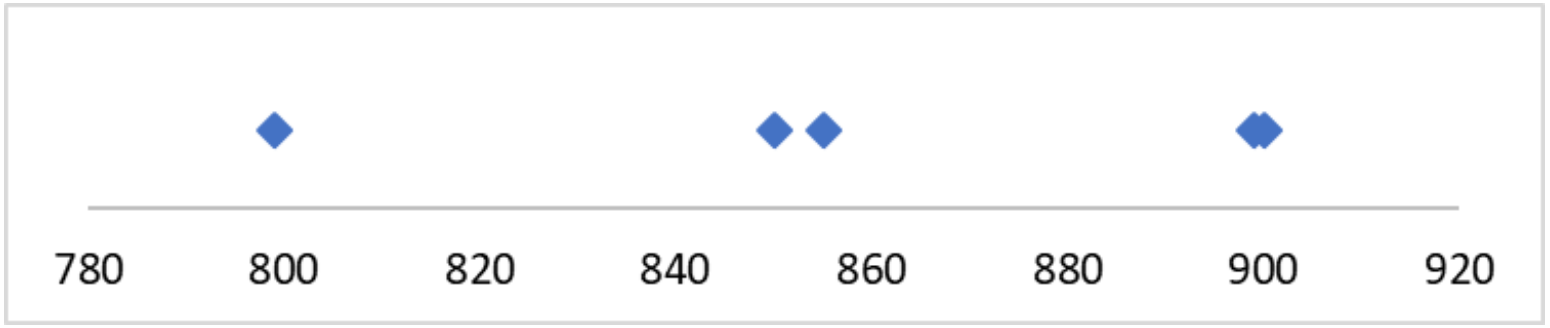
$$CV = \frac{desvio\,padrão}{média} \times 100\%$$

COEFICIENTE DE VARIAÇÃO

Exemplo: Um instituto de pesquisa de preços, coletou dados de preços de uma geladeira e de um liquidificador em cinco lojas no DF. Compare os preços dos produtos, qual deles apresenta maior variação de preços?

loja	Geladeira	Liquidificador
1	799	80
2	850	95
3	900	75
4	899	99
5	855	75

COEFICIENTE DE VARIAÇÃO



Geladeiras

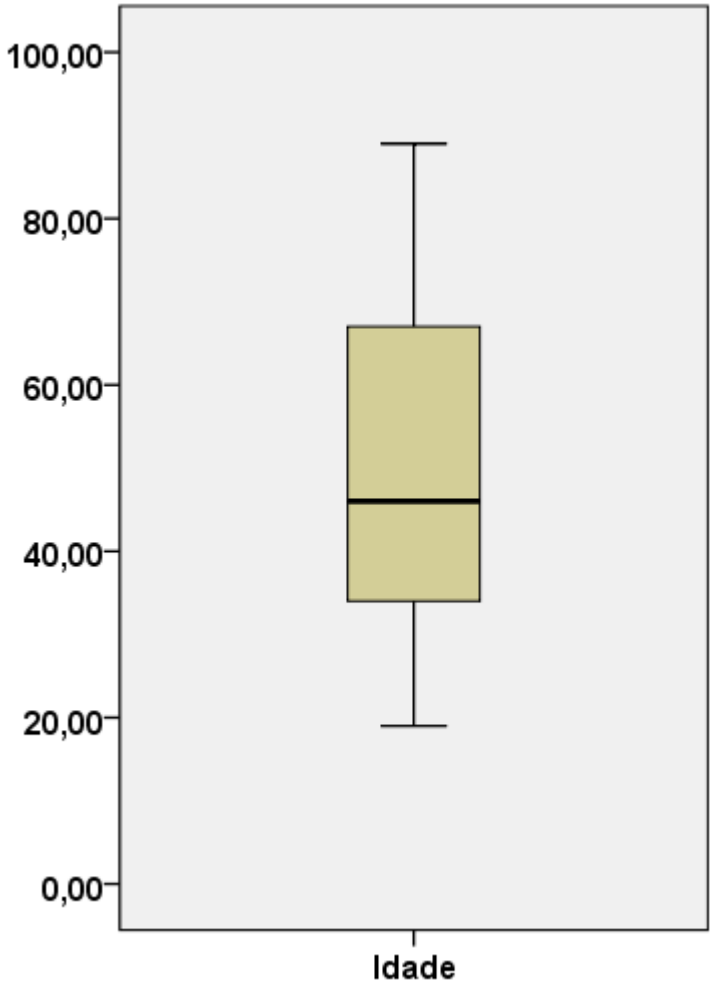


Liquidificador

COEFICIENTE DE VARIAÇÃO

	Geladeira	Liquidificador
	799	80
	850	69
	900	75
	899	99
	855	75
Média	860,6	79,6
DP	41,73	11,52
CV	4,85	14,48

BOX-PLOT



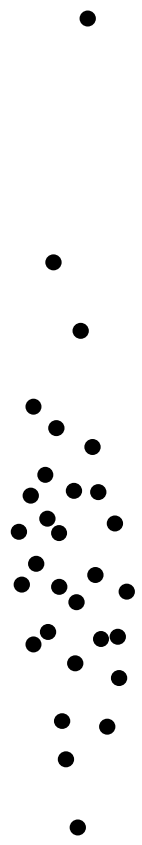
BOX PLOT

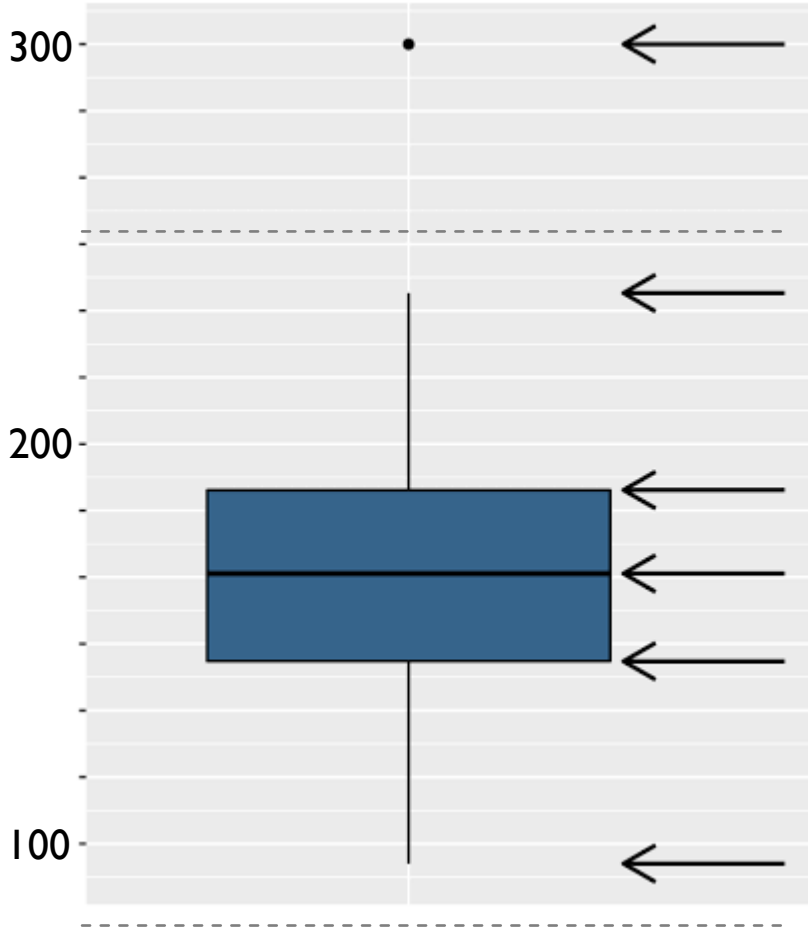
- O **box-plot** é uma figura que possibilita visualizer várias características de um conjunto de dados como:
- Tendência central (mediana)
- Posição (primeiro quartil e terceiro quartil)
- Dispersão (interval entre quartis)
- Assimetria
- Identificar os valores considerados como extremos.

OUTROS GRÁFICOS – BOX PLOT

- Caixa que contém 50% das observações centradas. Parte superior é Q3 e o inferior é Q1. Mediana Q2 está dentro da caixa.
- IQ=Q3-Q1
- LimiteSuperior=Q3+1.5IQ
- LimiteInferior=Q1-1.5IQ
- Ponto Extremo ou aberrante (“outlier”) – acima do L.S. ou abaixo do L.I.

OUTROS GRÁFICOS – BOX PLOT





Outlier (valor extremo/aberrante)

LS

Haste superior (maior valor que não é outlier)

Q3 (terceiro quartil)

Q2 (segundo quartil) - Mediana

Q1 (primeiro quartil)

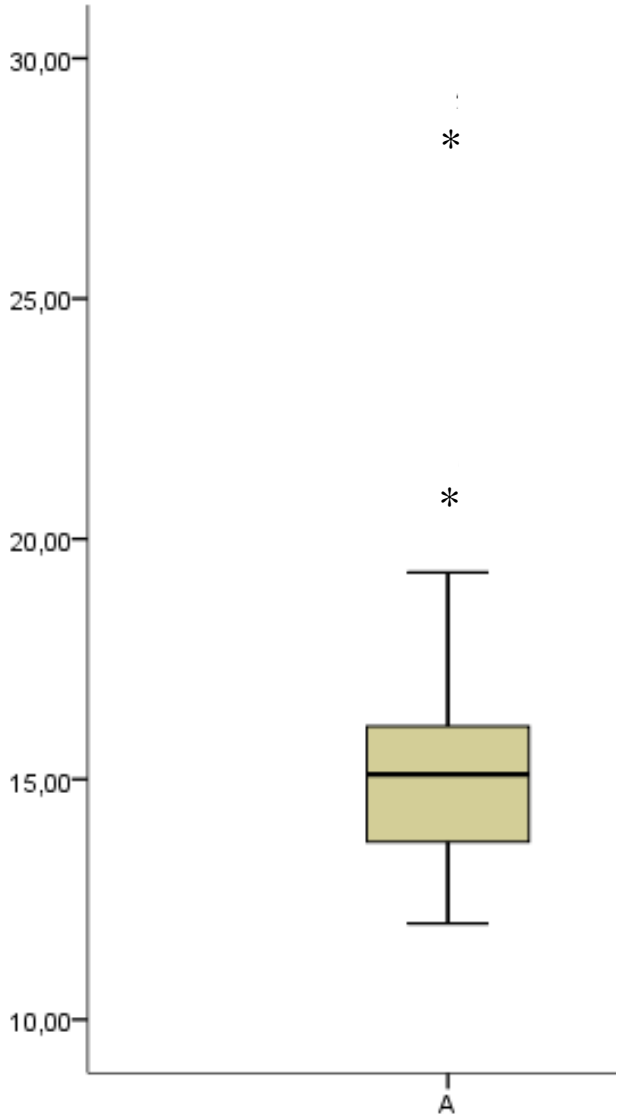
Haste inferior (menor valor que não é outlier)

LI

PREÇOS DO MEDICAMENTO

A
12
12,1
12,9
13
13,1
13,6
13,7
14,3
14,4
14,4
14,8
14,9
15,1
15,1
15,5
15,5
15,8
16
16,1
17
17,3
18,2
19,3
20,9
28,6

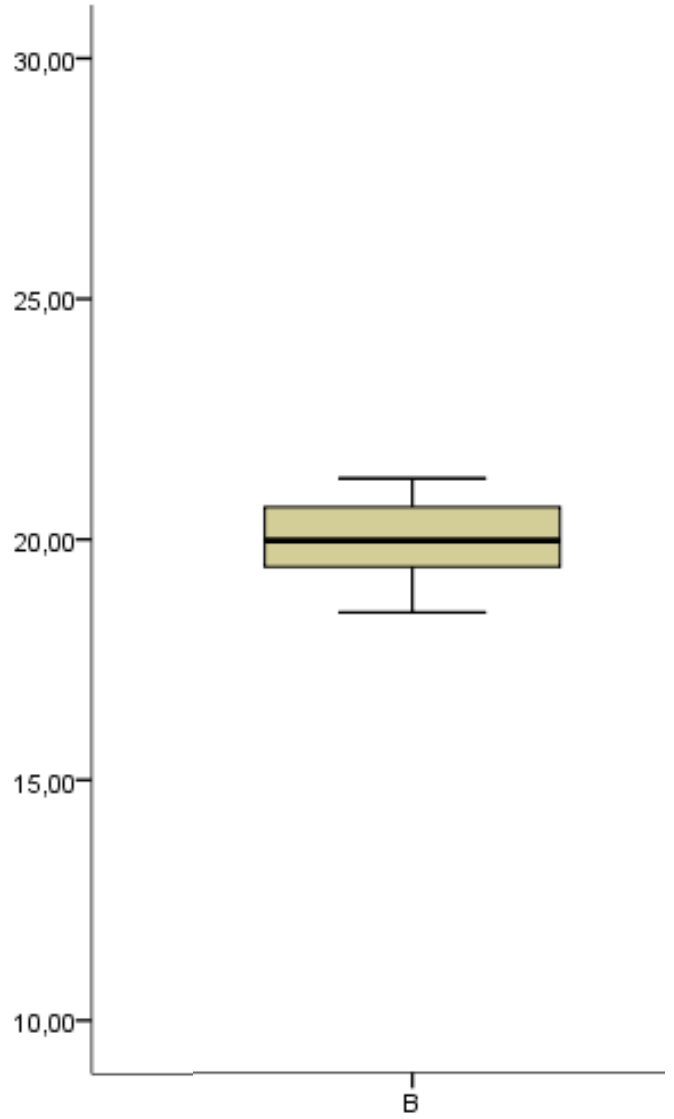
	Município
	A
Q1	13,7
Q2	15,1
Q3	16,1
LI	10,1
LS	19,7



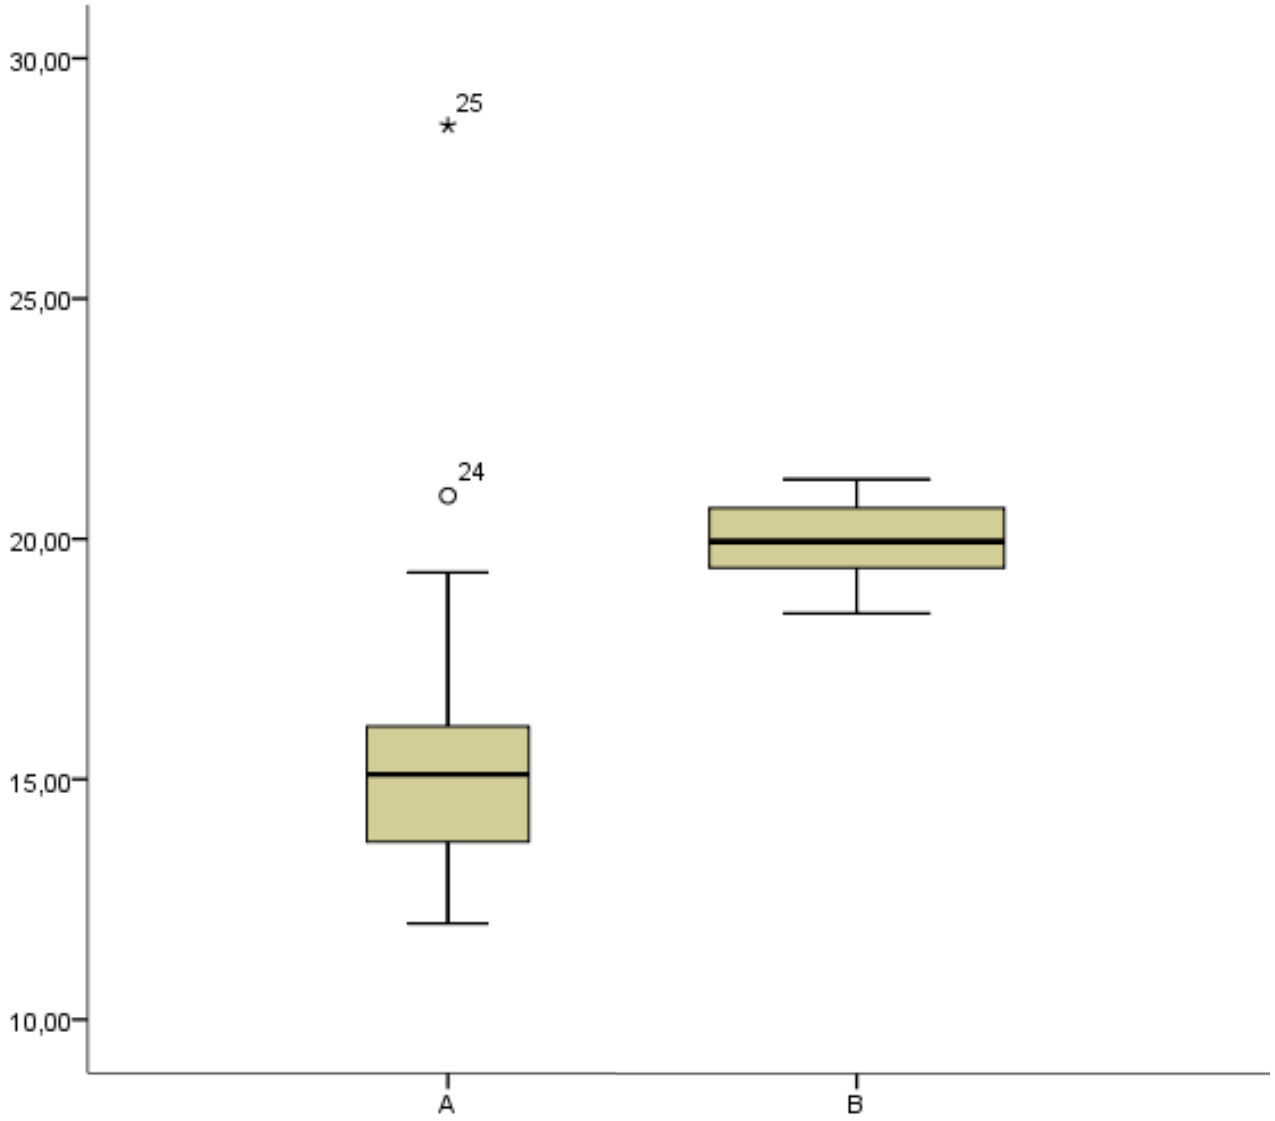
PREÇOS DO MEDICAMENTO

B
21,3
18,5
18,6
18,9
19,2
19,3
19,6
19,6
19,7
19,9
19,9
20,1
20,3
20,3
20,3
20,7
20,7
20,8
21
21,1

	Município
	B
Q1	19,5
Q2	20,0
Q3	20,7
LI	17,8
LS	22,5



PREÇOS DO MEDICAMENTO



MEDIDAS RESUMO (OU MEDIDAS DESCRITIVAS)

- **Medidas de posição**
  - Medidas de tendência central - média, moda, mediana
  - Quantis/percentis
- **Medidas de dispersão** - amplitude, variância, desvio padrão, interval interquartil
- **Medidas de assimetria**
- **Medidas de curtose**