ESTATÍSTICA EXPLORATÓRIA

EST0033

Slides adaptados do Professor

Luís Gustavo do Amaral Vinha

INTRODUÇÃO



- **Estatística** é a ciência que tem por objetivo orientar a coleta, o resumo, a apresentação, a análise e a interpretação de dados.

- **Estatística Descritiva**: é o ramo da estatística voltada para a organização, o resumo e a descrição de conjuntos de dados.

- **Inferência Estatística**: é o ramo da estatística que utiliza dados obtidos de uma amostra para fazer estimativas ou testar hipóteses sobre características de interesse de uma população.

TIPOS DE VARIÁVEIS

- **Variável:** é toda característica que, observada em uma unidade experimental, pode variar de uma unidade para outra.

  Exemplos: Proficiência em Matemática, Nível Socioeconômico, Sexo, Escolaridade da mãe, nível de infraestrutura, localização...

- **Tipos**

Qualitativas ou categóricas	Nominais
	Ordinais
Quantitativas ou numéricas	Discretas
	Contínuas

VARIÁVEIS **QUALITATIVAS**

DADOS SINASC

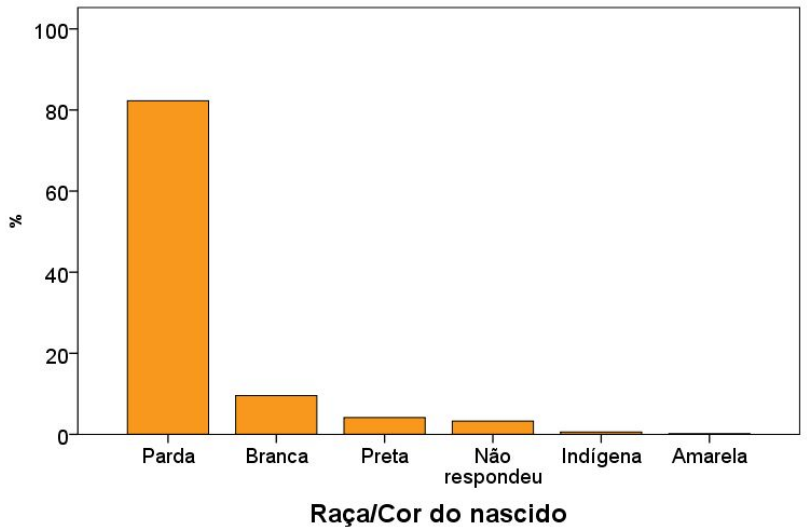
O DATASUS desenvolveu o Sistema de Informações sobre Nascidos Vivos (SINASC) visando reunir informações epidemiológicas referentes aos nascimentos informados em todo território nacional. Sua implantação ocorreu de forma lenta e gradual em todas as Unidades da Federação.

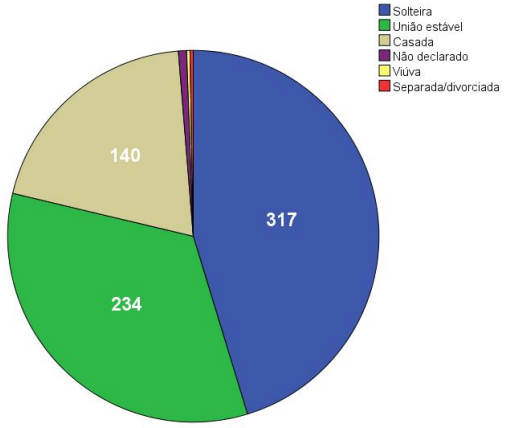
Foi extraída uma amostra aleatória simples de tamanho 700 do banco de dados de partos ocorridos no ano de 2016 do estado do Maranhão.

DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS NOMINAIS**

O resumo e apresentação das variáveis qualitativas nominais pode ser feita por meio de tabelas de frequências e gráficos de setores, barras ou colunas.

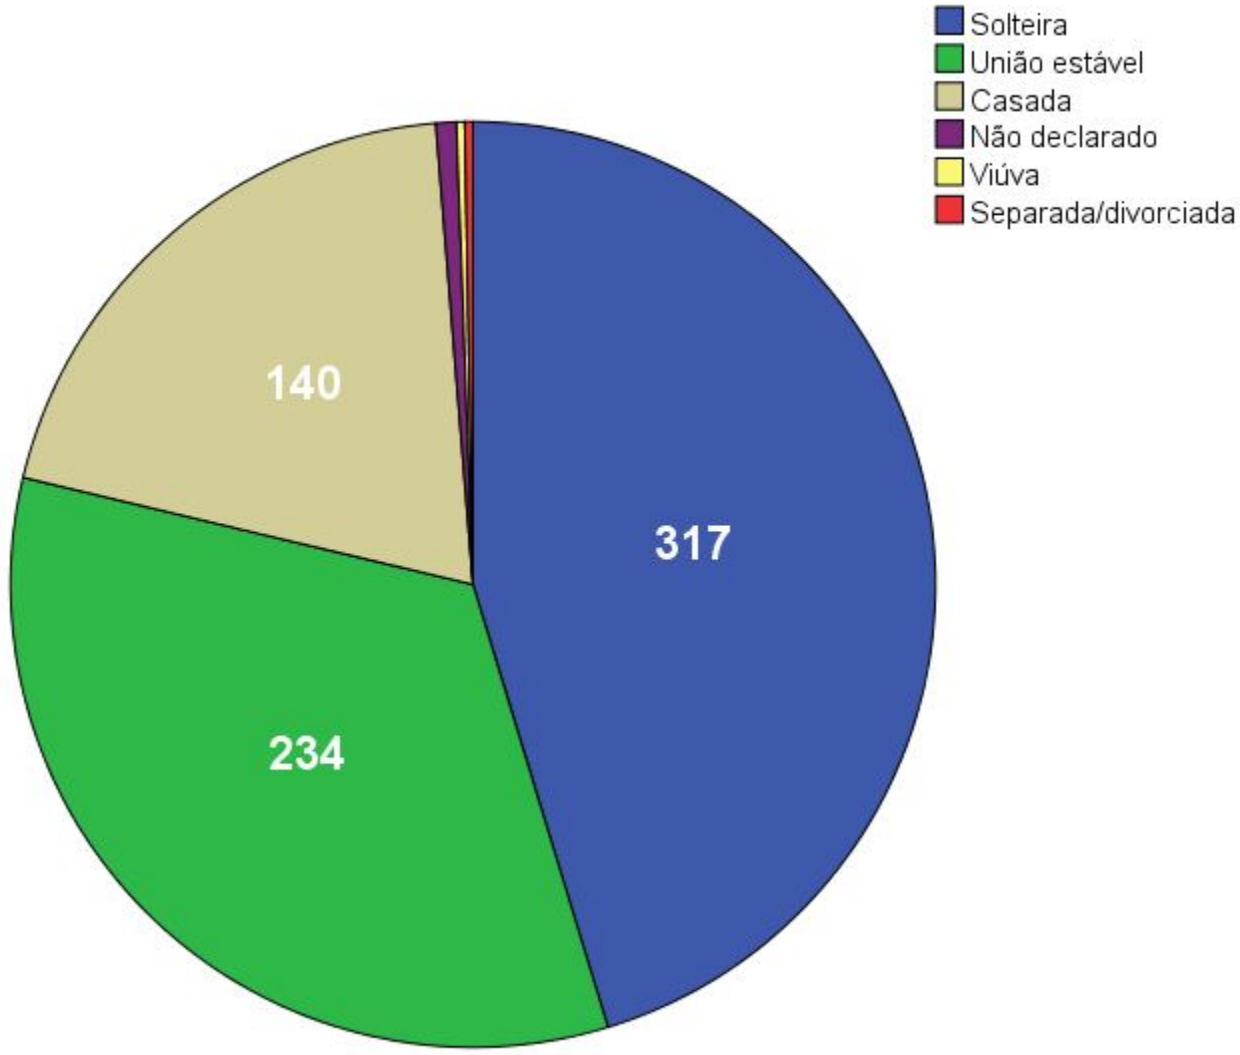
As frequências absolutas (n_i) e relativas (f_i) podem ser usadas nessa representação.





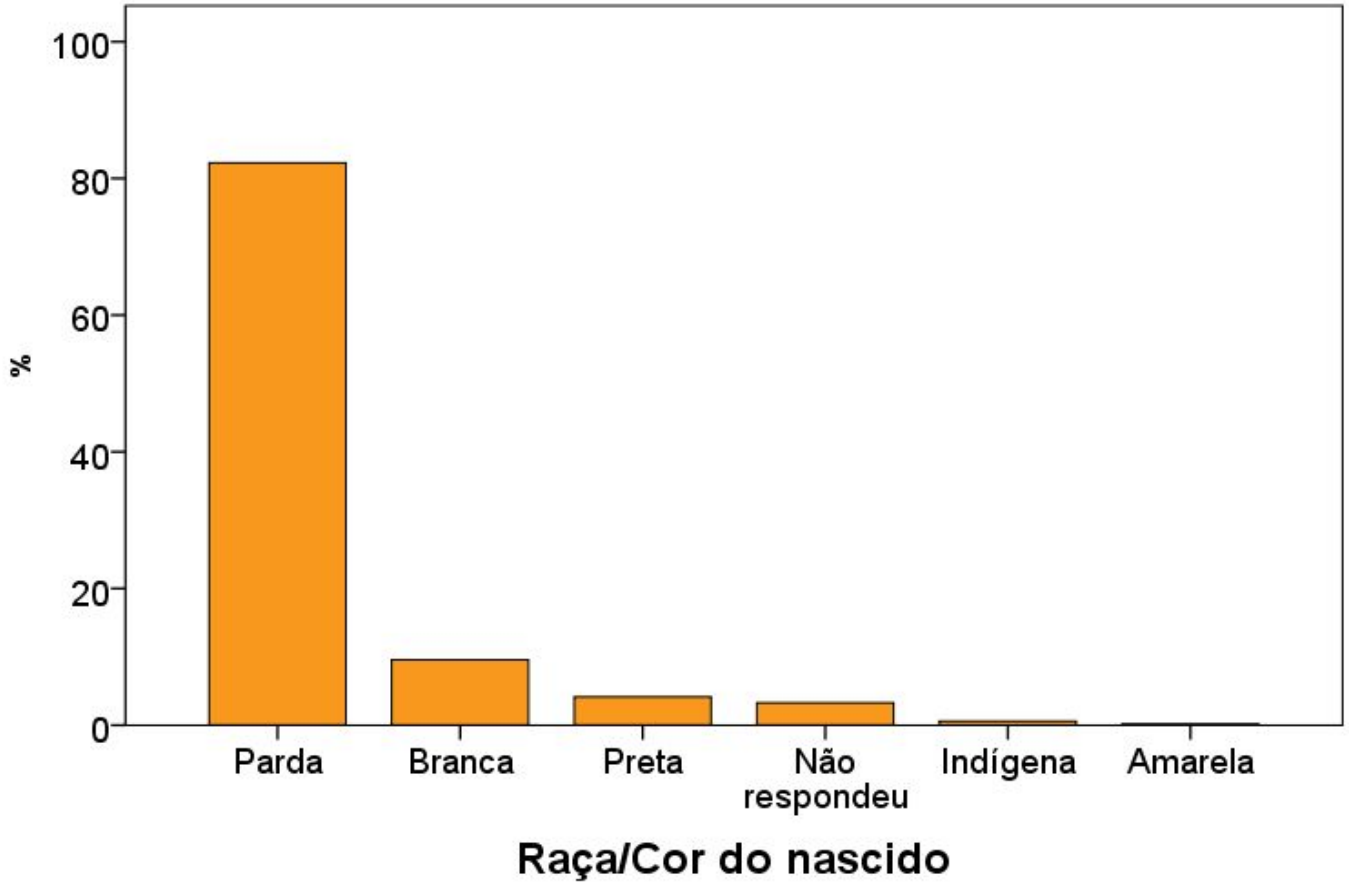
DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS NOMINAIS**

Situação conjugal	Frequência absoluta (ni)	Frequência relativa (fi) (%)
Solteira	317	45,3
União estável	234	33,4
Casada	140	20,0
Não declarado	5	0,7
Viúva	2	0,3
Separada/divorciada	2	0,3
Total	700	100,0



DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS NOMINAIS**

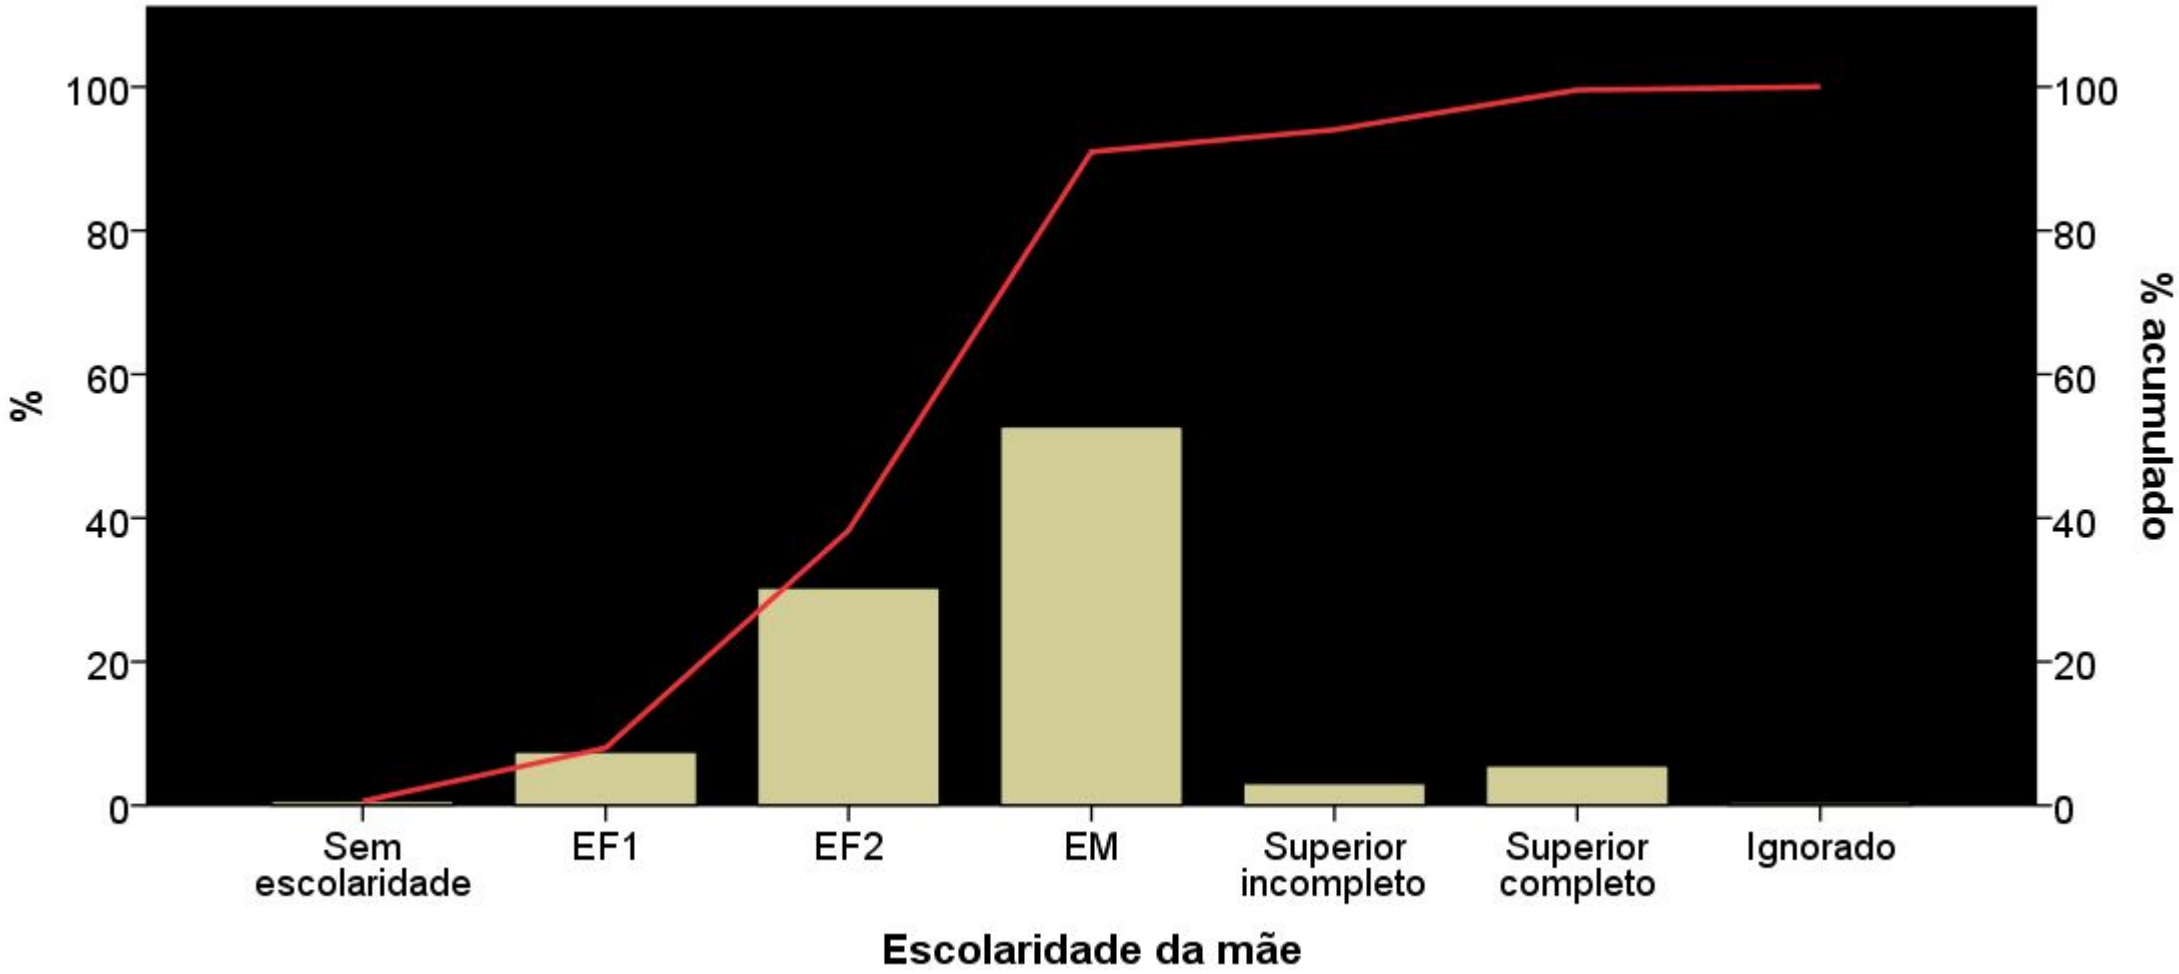
Raça/Cor do recém nascido	Frequência absoluta (ni)	Frequência relativa (fi) (%)
Parda	576	82,3
Branca	67	9,6
Preta	29	4,1
Indígena	4	0,6
Amarela	1	0,1
Não respondeu	23	3,3
Total	700	100,0



DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS ORDINAIS**

Escolaridade da mãe	Frequência absoluta (ni)	Frequência relativa (fi)	Frequência relativa acumulada (fi)
Sem escolaridade	4	0,01	0,01
Ensino fundamental 1	51	0,07	0,08
Ensino fundamental 2	208	0,30	0,38
Ensino médio	362	0,53	0,91
Superior incompleto	21	0,03	0,94
Superior completo	38	0,06	1,00
Total	684		

DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS ORDINAIS**



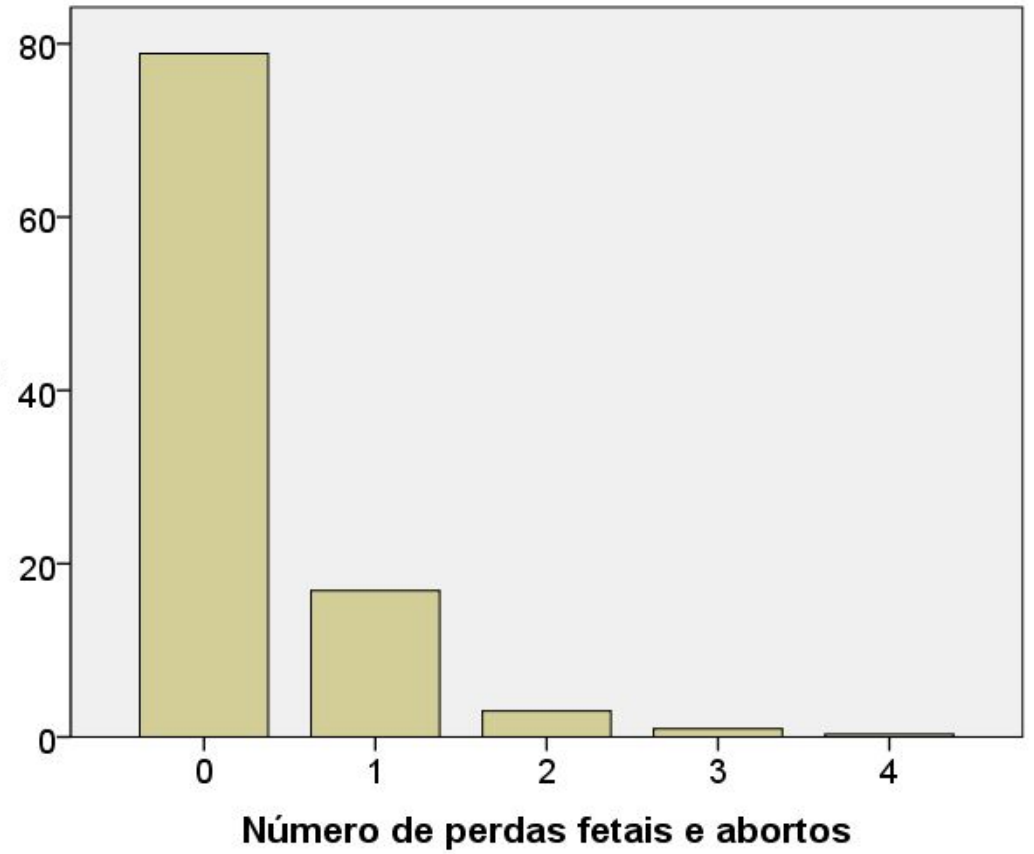
DESCRIÇÃO DE VARIÁVEIS **QUALITATIVAS**

As tabelas de distribuição de frequências e os gráficos de setores ou de barras podem ser utilizados para variáveis qualitativas nominais ou ordinais.

Além disso, podemos usar esses gráficos para variáveis quantitativas discretas que assumem poucos valores. Para variáveis numéricas que assumem muitos valores pode-se utilizar faixas de valores.

DESCRIÇÃO DE VARIÁVEIS **QUANTITATIVAS DISCRETAS**

Número de perdas fetais ou abortos	Frequência absoluta (ni)	Frequência relativa (fi)	Frequência relativa acumulada (fi)
0	500	0,79	0,79
1	107	0,17	0,96
2	19	0,03	0,99
3	6	0,01	1,00
4	2	0,00	1,00
	634		



ANÁLISE BIDIMENSIONAL

- **Objetivo:** encontrar associação ou relação entre as variáveis. Essas relações podem ser identificadas através de gráficos ou medidas numéricas.
- **Associação:** mudança de opinião sobre o comportamento de uma variável na presença ou não de informação sobre a segunda variável.

TABELA DE CONTINGÊNCIA

- Representação de 2 variáveis categóricas ou qualitativas
- **Exemplo:** Suponha que queiramos analisar o comportamento conjunto das variáveis Risco de doença coronariana (Sim/Não) e Sexo, usando a amostra de 4240 pacientes de um hospital.

	Risco de doença coronariana		
Sexo	Não	Sim	Total
Feminino	2119	301	2420
Masculino	1477	343	1820
Total	3596	644	4240

TABELA DE CONTINGÊNCIA

- Existe relação (ou associação ou dependência) entre sexo e o risco da doença?
- Olhar para as proporções para facilitar

	Risco de doença coronariana		
Sexo	Não	Sim	Total
Feminino	2119	301	2420
	0,500	**0,071**	**0,571**
Masculino	1477	343	1820
	0,348	**0,081**	**0,429**
Total	3596	644	4240
	0,848	**0,152**	**1,000**

Distribuição marginal de sexo

Distribuição marginal do risco da doença coronariana

TABELA DE CONTINGÊNCIA

- Olhando a tabela das proporções pelo total, ainda não conseguimos enxergar os resultados pois o total de homens e mulheres é diferente
- Para retirar o efeito dos totais marginais, calcular proporções por coluna.

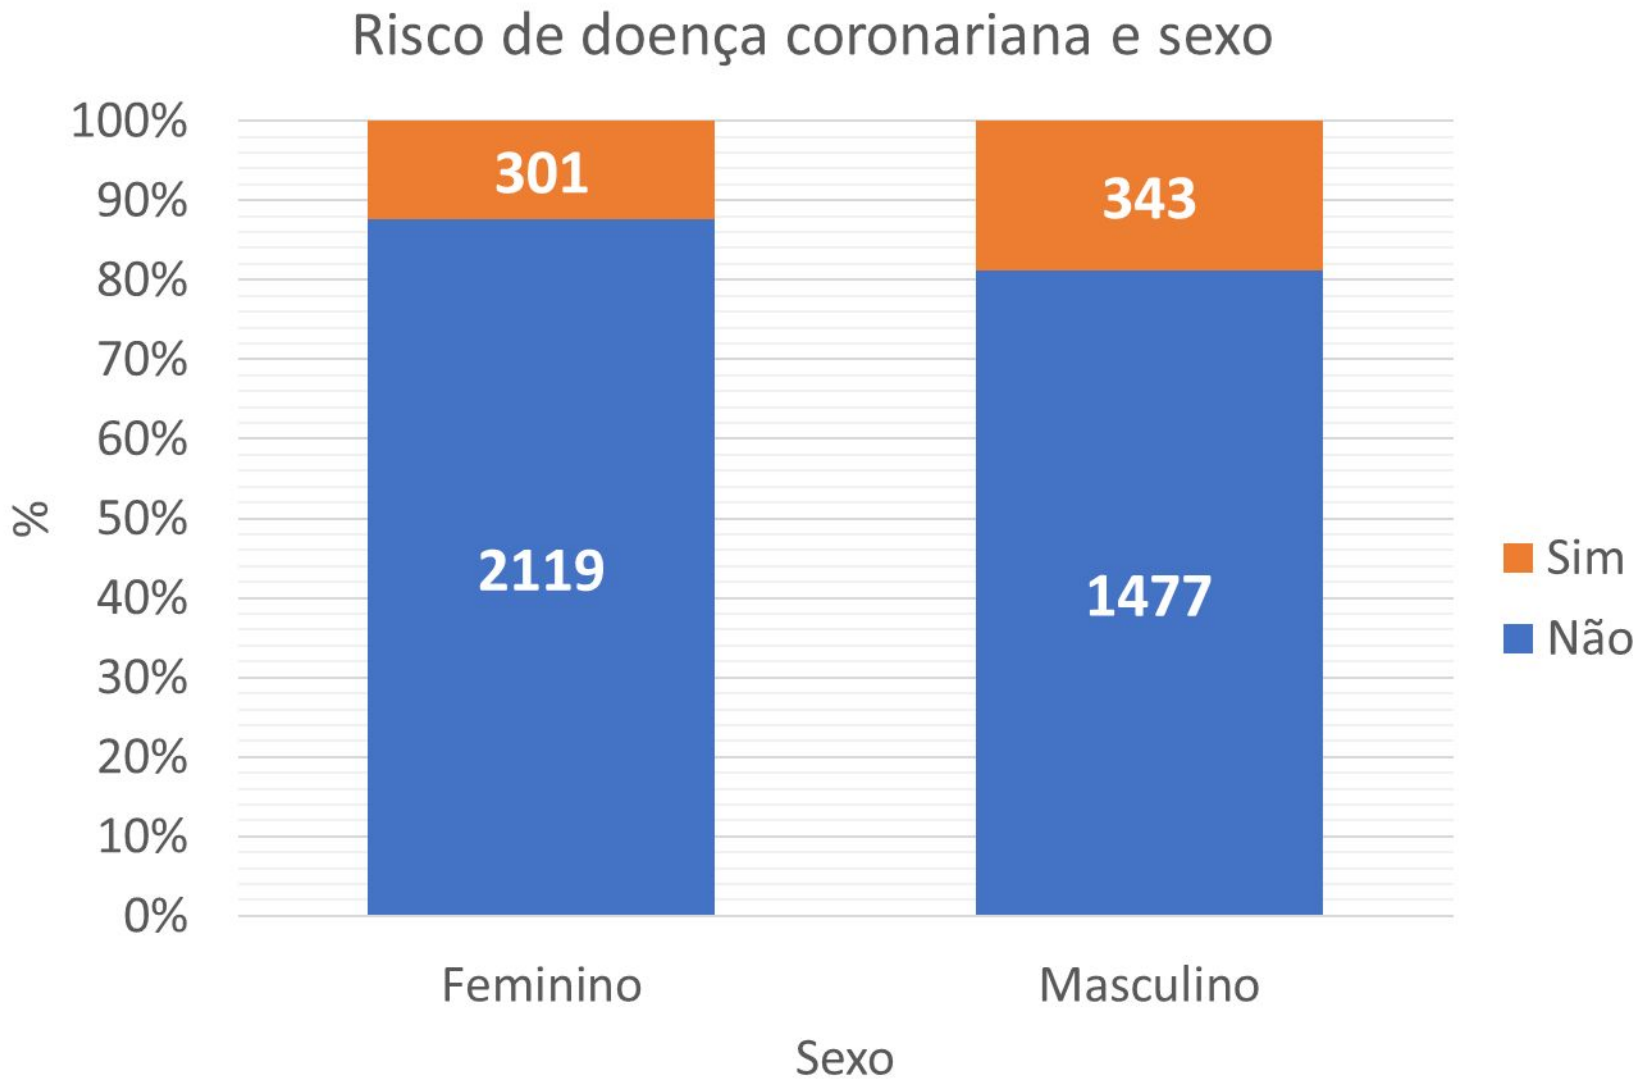
	Risco de doença coronariana		
Sexo	Não	Sim	Total
Feminino	2119	301	2420
	0,589	0,467	0,571
Masculino	1477	343	1820
	0,411	0,533	0,429
Total	3596	644	4240
	1,000	1,000	1,000

TABELA DE CONTINGÊNCIA

- Ou por linha.

	Risco de doença coronariana		
Sexo	Não	Sim	Total
Feminino	2119	301	2420
	0,876	0,124	1,000
Masculino	1477	343	1820
	0,812	0,188	1,000
Total	3596	644	4240
	0,848	0,152	1,000

ANÁLISE BIDIMENSIONAL



ANÁLISE BIDIMENSIONAL - EXEMPLO

Conduziu-se uma pesquisa para avaliar se a percepção que os consumidores tinham de um produto alimentício dependia do gênero.

Dados

Consumidor	Gênero	Avaliação
1	M	Positiva
2	F	Positiva
3	F	Indiferente
4	F	Positiva
5	M	Negativa
6	F	Negativa
...	...	...
285	M	Indiferente

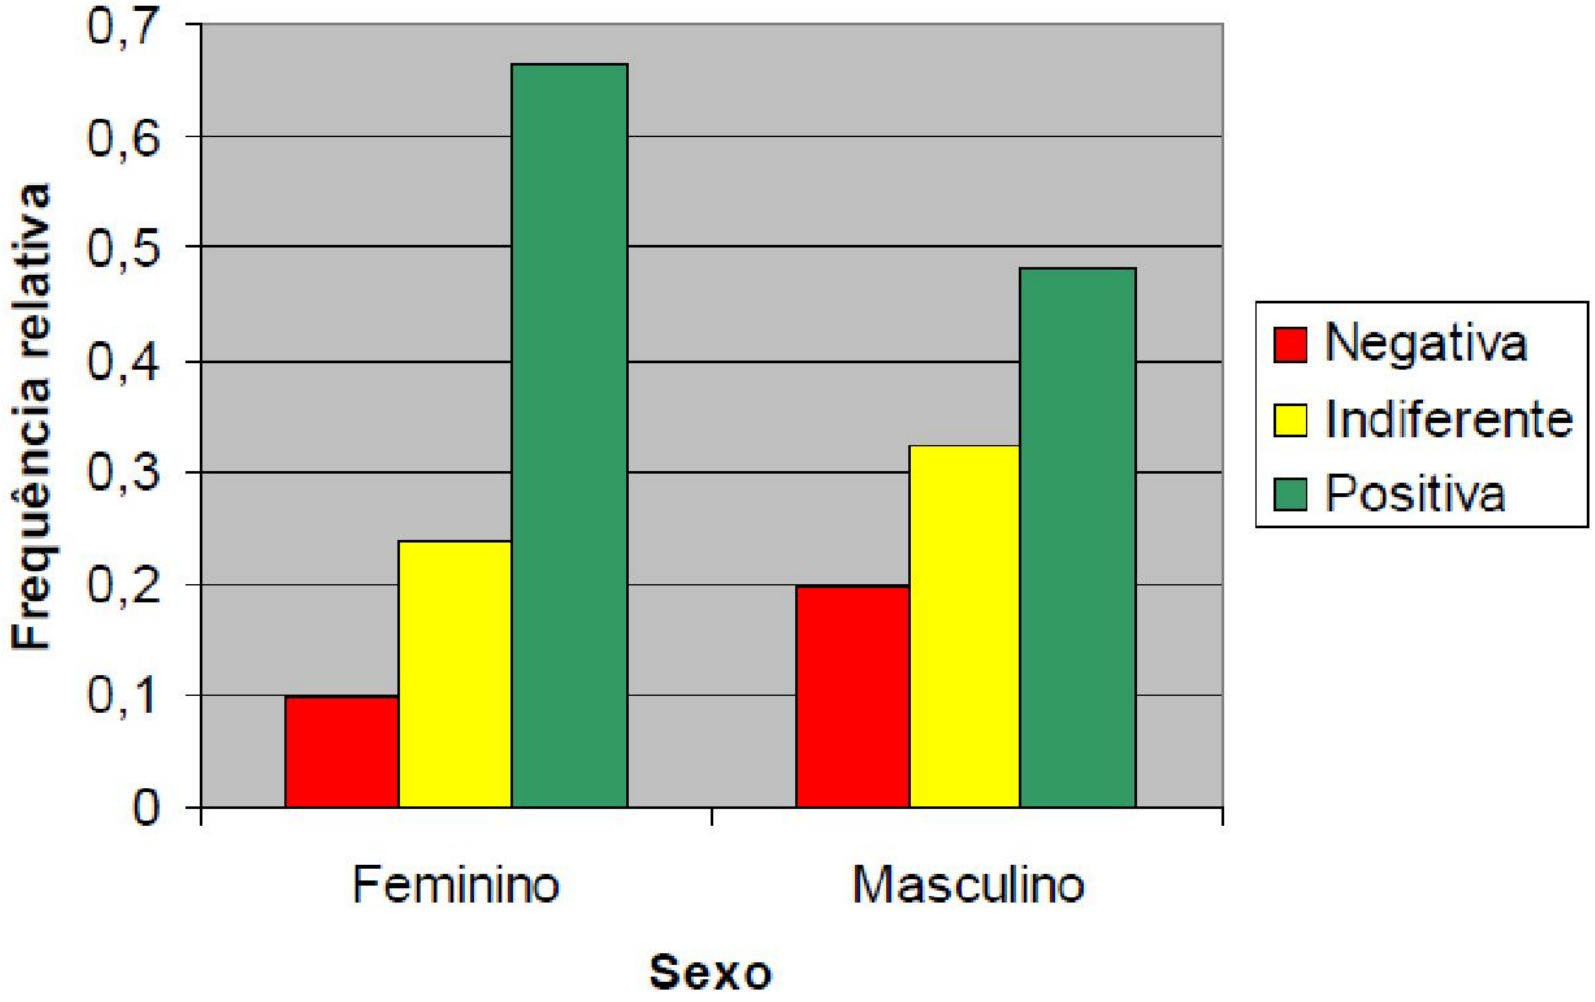
ANÁLISE BIDIMENSIONAL

Count

		Avaliação			Total
		Positiva	Indiferente	Negativa	
Sexo	Masculino	54	36	22	112
	Feminino	115	41	17	173
Total		169	77	39	285

			Avaliação			Total
			Positiva	Indiferente	Negativa	
Sexo	Masculino		54	36	22	112
		% linha	48,2%	32,1%	19,6%	100%
	Feminino		115	41	17	173
		% linha	66,5%	23,7%	9,8%	100%
	Total		169	77	39	285
		% linha	59,3%	27,0%	13,7%	100%

ANÁLISE BIDIMENSIONAL



DESCRIÇÃO DE VARIÁVEIS **QUANTITATIVAS**

As tabelas de distribuição de frequências e os gráficos de setores ou de barras podem ser utilizados variáveis quantitativas discretas que assumem poucos valores.

Para variáveis numéricas que assumem muitos valores pode-se utilizar faixas de valores e outras representações.

Histograma!

HISTOGRAMA

Uma amostra de 30 indivíduos foi coletada e as idades foram registradas:

43	32	62	54	49
48	61	50	42	62
39	59	35	76	48
51	49	23	55	40
46	63	62	36	43
46	44	52	46	57

Observe que nesse caso não é apropriado montar a tabela de frequência contando a repetição de cada resultado uma vez que a possibilidade de repetição é muito baixa. Quando os dados têm muitas possibilidades de resultados, faz-se a contagem dos resultados de acordo com um intervalo pré-estabelecido, denominado de classe.

HISTOGRAMA

A distribuição de frequências então poderá ser obtida com a divisão dos dados em faixas. Para isso é necessário (se não tivéssemos os pacotes estatísticos):

- Definir a amplitude total e a amplitudes das classes (amplitudes iguais ou diferentes)
- Contar quantas observações temos em cada classe – frequência absoluta (ni)
- Dividir pelo número total de observações – frequência relativa (fi)
- Montar um gráfico de barras (contíguas)

HISTOGRAMA

Nesse caso, a determinação do tamanho das classes poderia ser

- MÁXIMO = 76 E MÍNIMO = 23
- AMPLITUDE DEVARIAÇÃO = MAX -MIN = 76 -23 = 53
- NÚMERO DE CLASSES = aproximadamente a raiz quadrada do tamanho da amostra ($\sqrt{n}$)
- TAMANHO DAS CLASSES :

$$\frac{AMPLITUDE}{N.\ DE\ CLASSES} = \frac{53}{\sqrt{30}} \approx 10$$

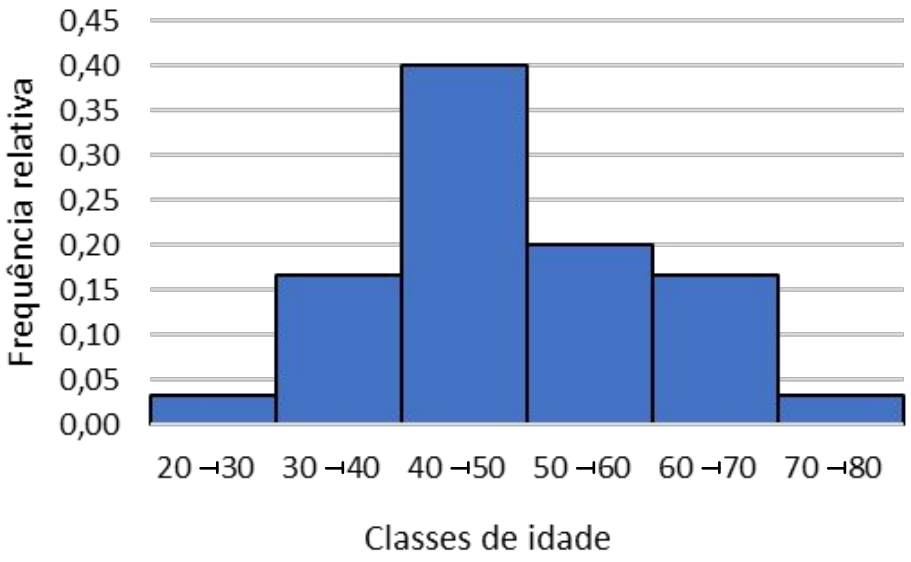
HISTOGRAMA

43	~~32~~	62	54	49
48	61	50	42	62
~~39~~	59	~~35~~	76	48
51	49	23	55	~~40~~
46	63	62	~~36~~	43
46	44	52	46	57

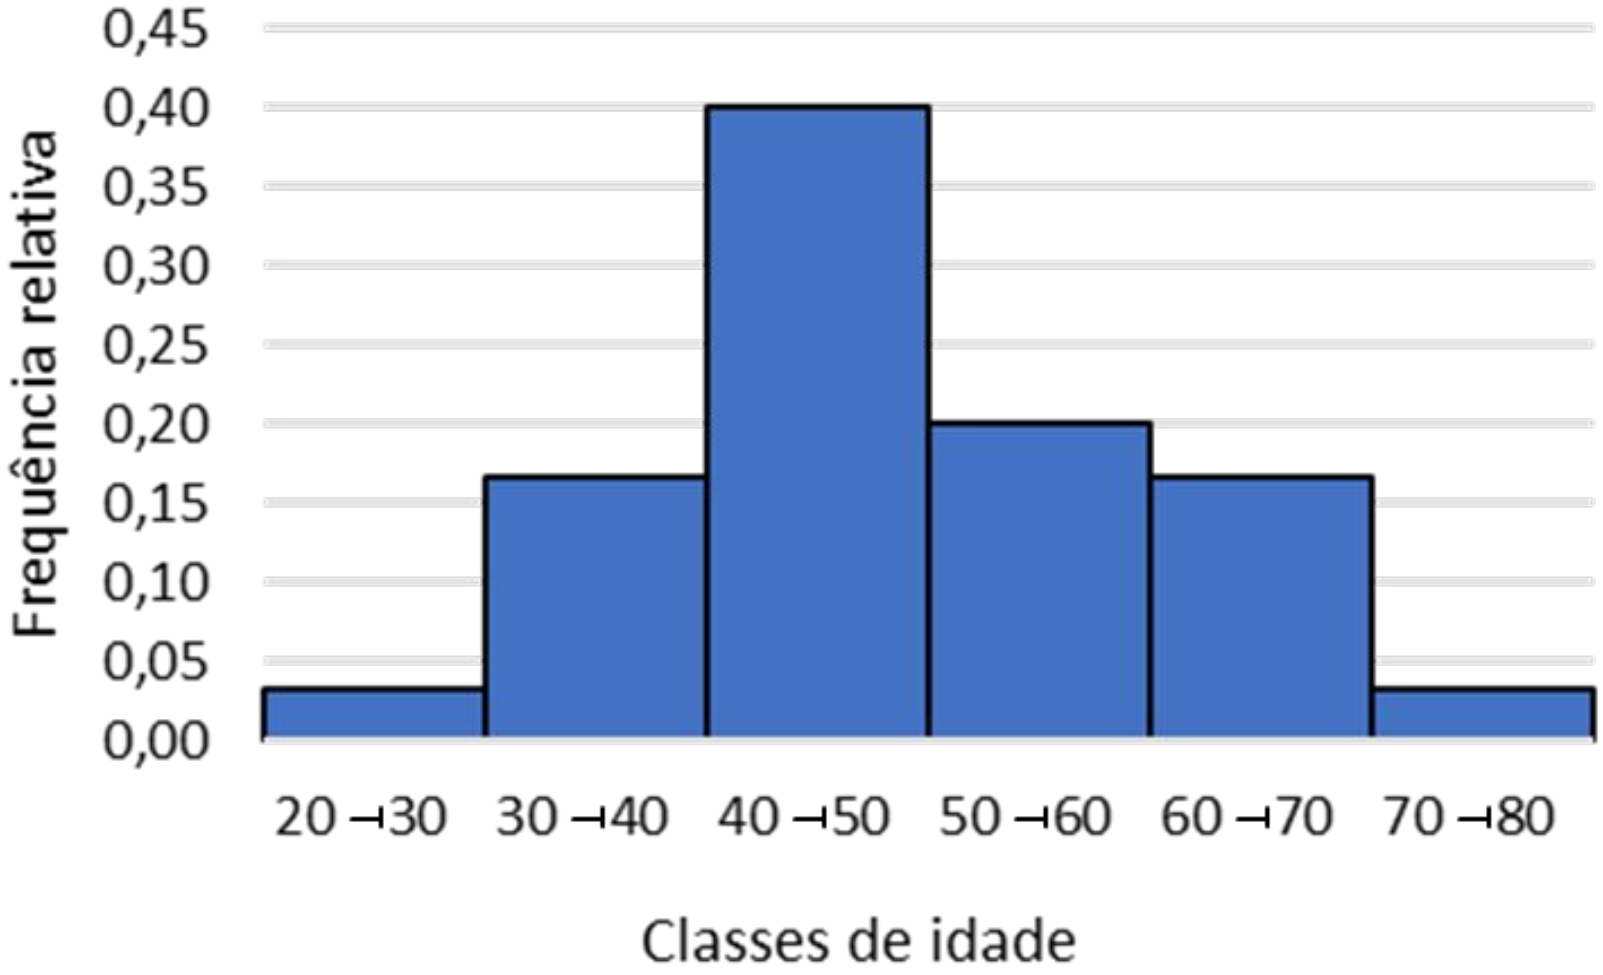
Pertence a classe que vai de 30 (exclusive) a 40 (inclusive)

Contagem para cada intervalo

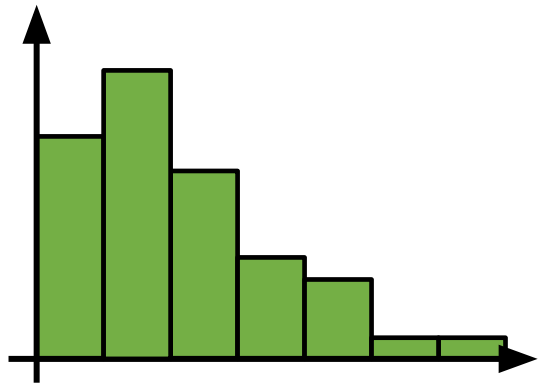
Classes de idade	ni	fi
20 ⊣ 30	1	0,033
30 ⊣ 40	5	0,167
40 ⊣ 50	12	0,400
50 ⊣ 60	6	0,200
60 ⊣ 70	5	0,167
70 ⊣ 80	1	0,033
Total	30	1

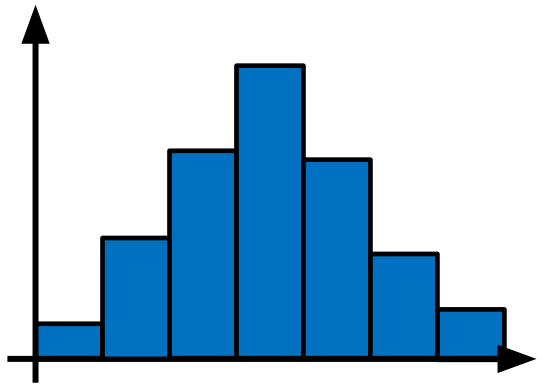


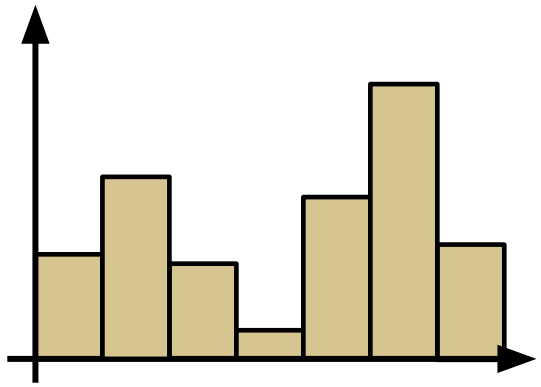
HISTOGRAMA

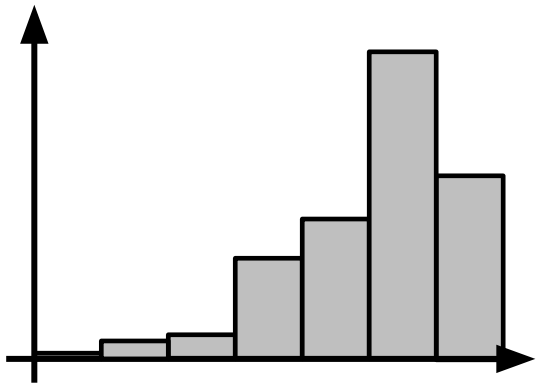

0,45
0,40
0,35
0,30
0,25
0,20
0,15
0,10
0,05
0,00
Frequência relativa
20 ⊣30
30 ⊣40
40 ⊣50
50 ⊣60
60 ⊣70
70 ⊣80
Classes de idade

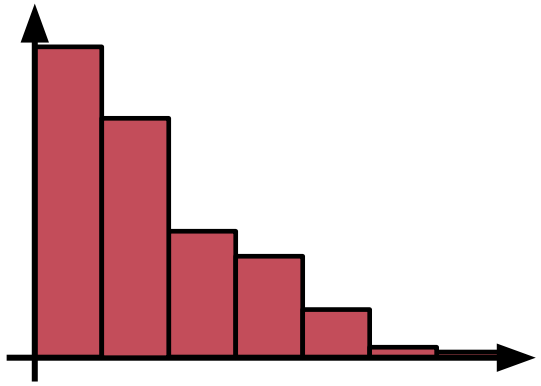
HISTOGRAMA

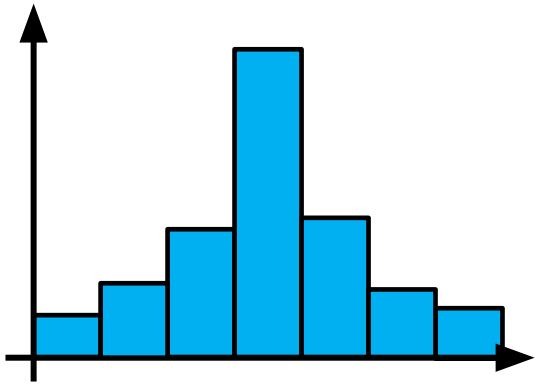


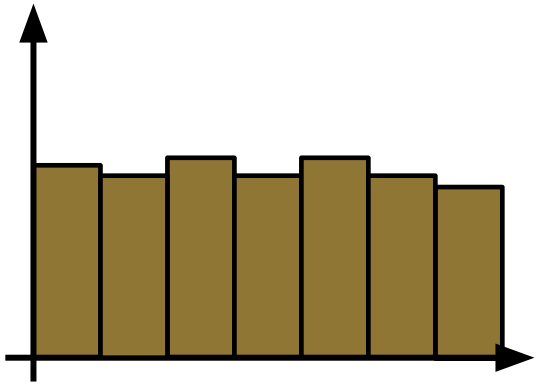


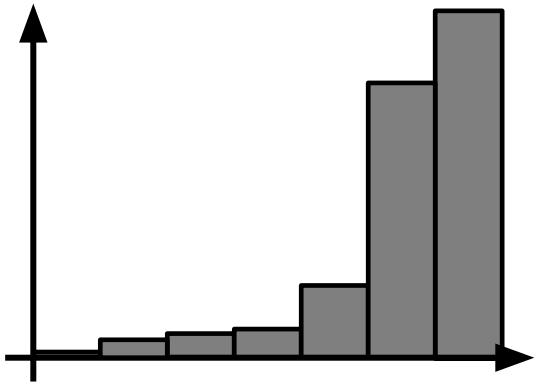












HISTOGRAMA – DENSIDADE DE FREQUÊNCIA

Em algumas situações a divisão de faixas de mesmo tamanho no histograma pode não gerar a melhor representação da distribuição.

Nesses casos o uso de classes com tamanhos desiguais no agrupamento dos dados em tabelas de frequências é mais adequado mas deve-se tomar alguns cuidados especiais quanto à análise e construção do histograma.

Exemplo:

Distribuição de frequências da

variável salário de um setor da economia.

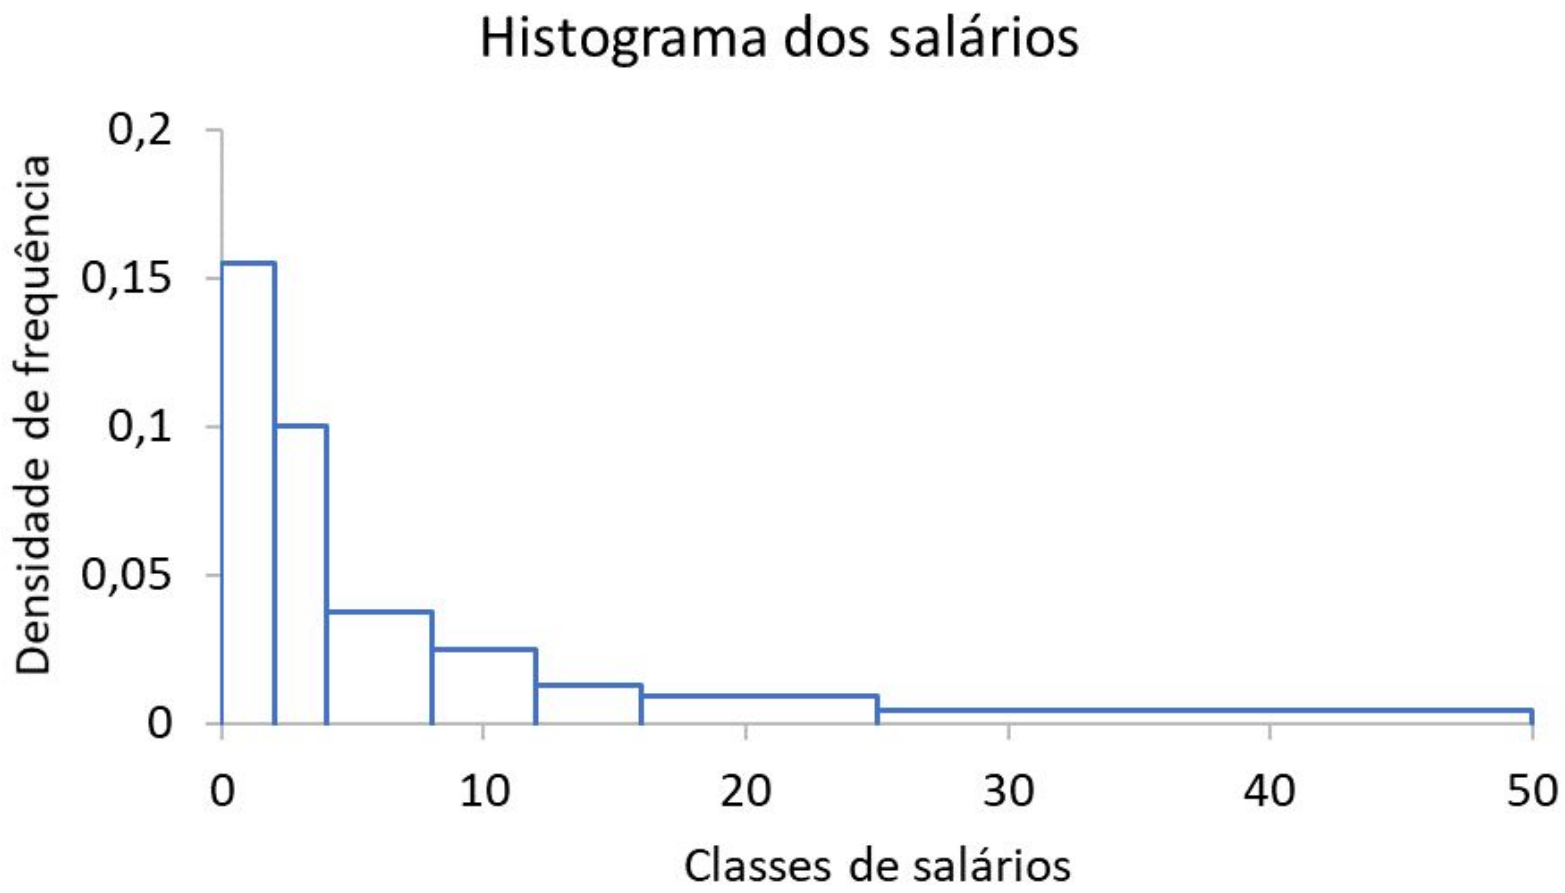
Salário (em 1.000 reais)	Frequência relativa
0 a 2	0,31
2 a 4	0,2
4 a 8	0,15
8 a 12	0,1
12 a 16	0,05
16 a 25	0,08
25 a 50	0,11

HISTOGRAMA – DENSIDADE DE FREQUÊNCIA

Salário (em 1.000 reais)	Frequência relativa (f_i)	Amplitude do intervalo (Δ_i)	Densidade de frequência
0 a 2	0,31	2	0,1550
2 a 4	0,20	2	0,1000
4 a 8	0,15	4	0,0375
8 a 12	0,10	4	0,0250
12 a 16	0,05	4	0,0125
16 a 25	0,08	9	0,0089
25 a 50	0,11	25	0,0044

Densidade = frequência relativa / amplitude da classe $\delta_i = \frac{f_i}{\Delta_i}$

HISTOGRAMA – DENSIDADE DE FREQUÊNCIA



HISTOGRAMA – DENSIDADE DE FREQUÊNCIA

Essa ideia de densidade está relacionada com as distribuições de probabilidades teóricas. Para que uma função f(x) seja uma função densidade de probabilidade a área sob a curva deve ser igual a 1. Por isso, para calcular a área sob o histograma feito utilizando-se a densidade como altura tem-se:

Área = 1

Mas, por que construir um histograma com classes de tamanhos diferentes? Para que em algumas classes não ocorram saltos no histograma, presença de classes vazias. A assimetria da variável influencia na construção do histograma, por exemplo, salários.

OUTROS GRÁFICOS – RAMO-E-FOLHAS

Este gráfico pode ser utilizado como uma alternativa ao histograma, principalmente quando o número de observações é pequeno.

Para a sua construção devemos divider os valores em 2 partes:

- **Ramo**, um ou mais dígitos;
- **Folhas,** dígitos restantes.

18	50	60	90				
19	20	30	60	60	70	90	90
20	10	30	30	30	70	70	80
21	0	10	30				

OUTROS GRÁFICOS – RAMO-E-FOLHAS

- Considere o exemplo que o gerente de uma indústria farmacêutica deseja estudar o preço de venda de um medicamento em 2 municípios: A e B.
- Para estudara distribuição de preços, foram tomados os preços praticados por uma amostra de 25 lojas do município A e de 20 lojas do município B.

OUTROS GRÁFICOS – RAMO-E-FOLHAS

Dados

Município			
A		B	
14,80	12,90	21,30	20,30
18,20	20,90	20,70	19,60
13,60	19,30	20,70	19,20
15,50	14,40	19,90	18,50
12,00	15,10	20,30	18,60
13,70	13,10	21,10	20,30
16,00	15,50	19,60	20,10
17,30	14,30	19,30	19,90
14,40	15,10	20,80	21,00
16,10	15,80	19,70	18,90
26,80	13,00		
12,10	14,90		
	17,00		

Município A

12	00 10 90
13	60 70 10 00
14	80 40 40 30 90
15	50 10 50 10 80
16	00 10
17	30 00
18	20
19	30
20	90
21	
22	
23	
24	
25	
26	80

Município B

12	
13	
14	
15	
16	
17	
18	50 60 90
19	90 60 30 70 60 20 90
20	70 70 30 80 30 30 10
21	30 10 00
22	
23	
24	
25	
26	

Idade de mãe em anos Stem-and-Leaf Plot

```
 Frequency    Stem &  Leaf

     1,00        1 .  3
    18,00        1 .  444444555555555555
    52,00        1 .  66666666666666666666677777777777777777777777777777
    89,00        1 .  88888888888888888888888888888888888888899999999999999999999999999999999999999999999
    91,00        2 .
0000000000000000000000000000000000000000000011111111111111111111111111111111111111111
    90,00        2 .  22222222222222222222222222222222222222222222222233333333333333333333333333333333333333
    72,00        2 .  44444444444444444444444444444444444444444455555555555555555555555555555555
    64,00        2 .  66666666666666666666666666666677777777777777777777777777777777
    66,00        2 .  88888888888888888888888888888888999999999999999999999999999999999
    46,00        3 .  00000000000000000000000001111111111111111111
    34,00        3 .  22222222222222233333333333333333333
    33,00        3 .  44444444444444445555555555555555
    20,00        3 .  66666666666677777777
     9,00        3 .  888888899
     7,00        4 .  0000011
     5,00        4 .  22222
     3,00 Extremes    (>=43)

 Stem width:        10
 Each leaf:       1 case(s)
```

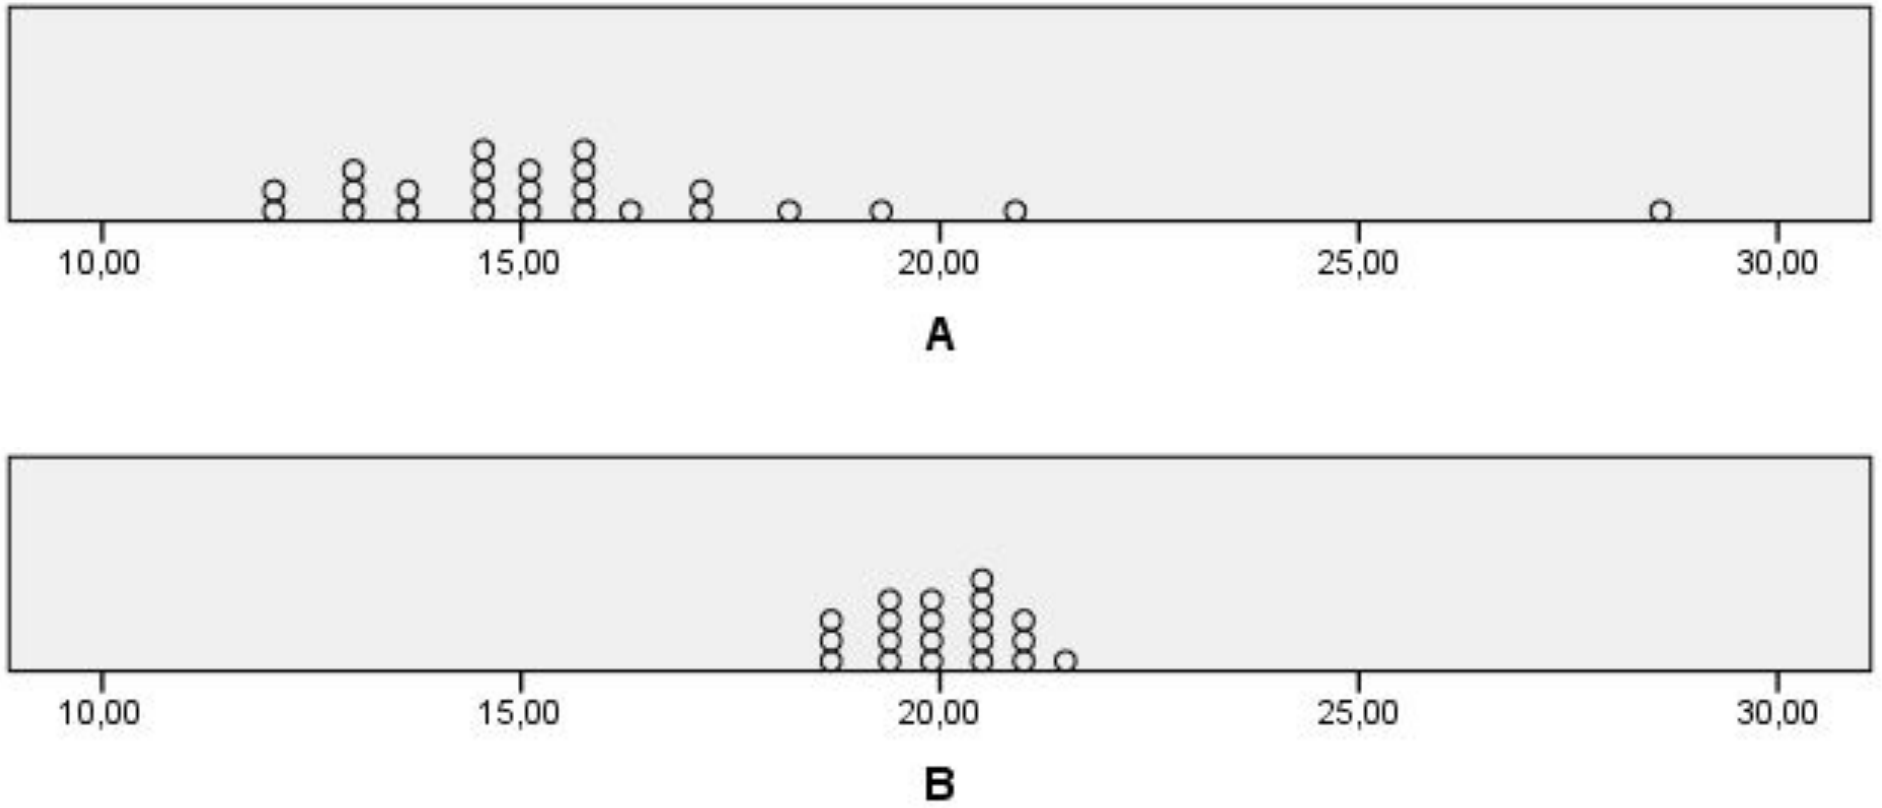
OUTROS GRÁFICOS – GRÁFICO DE PONTOS

- Utilizado quando o número de observações é reduzido.
- Exemplo: taxa de crescimento demográfico de 6 cidades:

-1 -0,1 0,1 0,8 2,1 4,2



OUTROS GRÁFICOS – GRÁFICO DE PONTOS

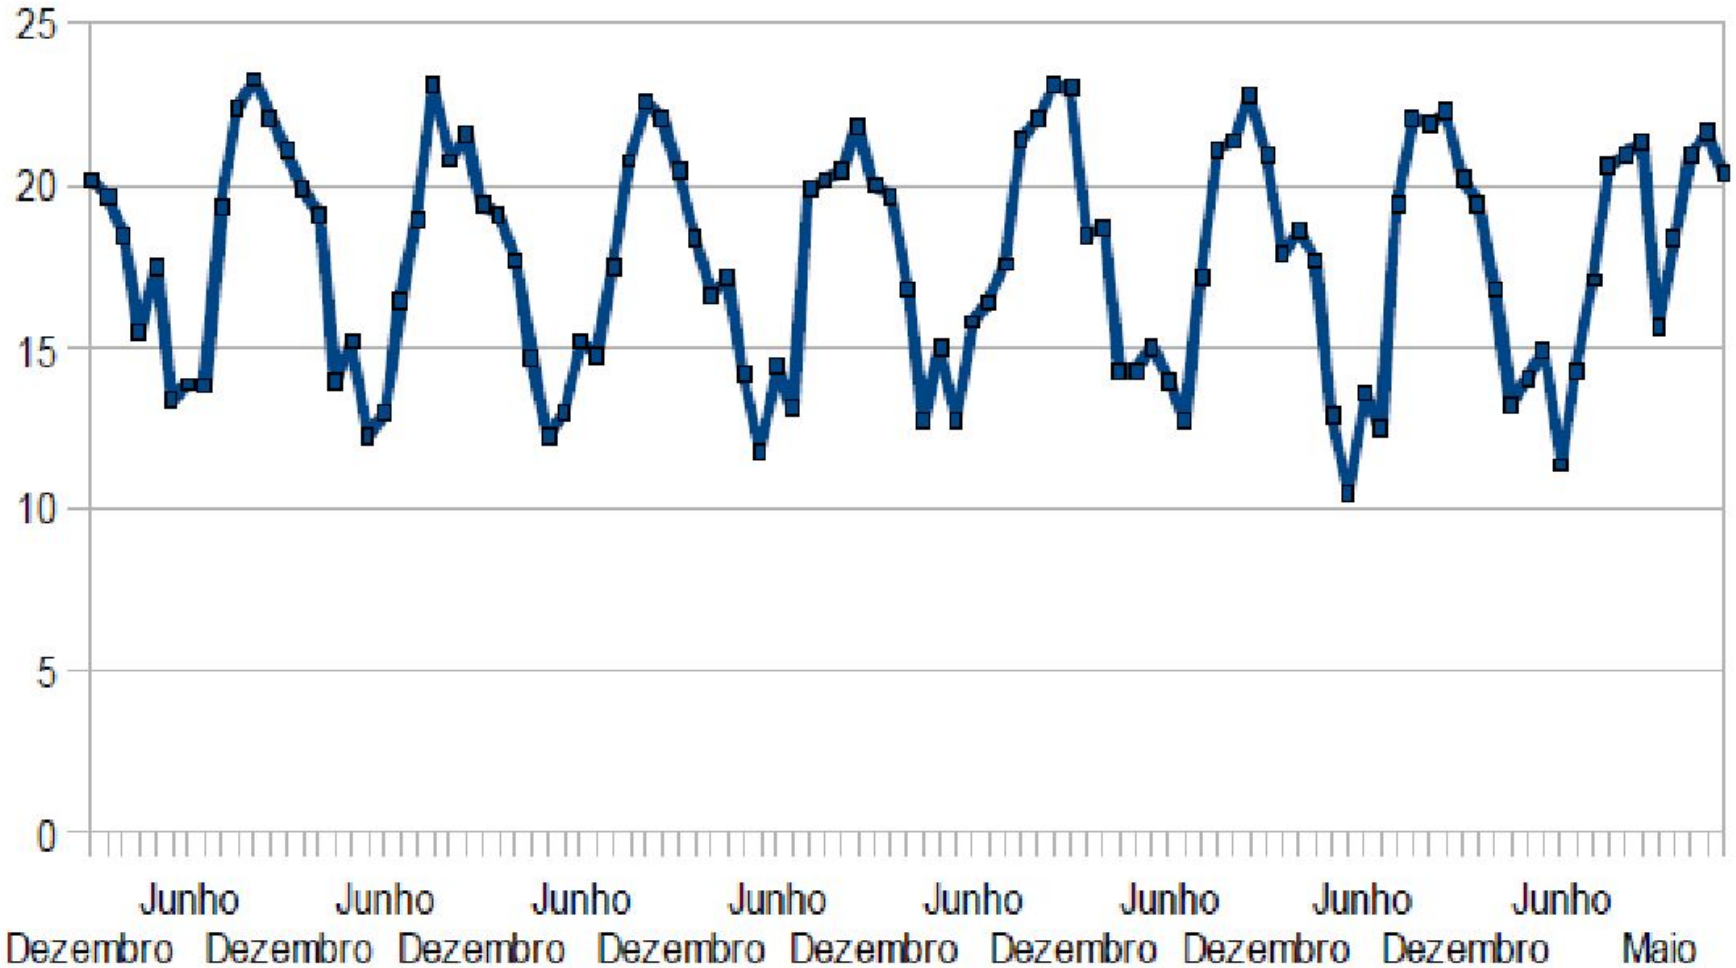


OUTROS GRÁFICOS – GRÁFICO DE LINHA

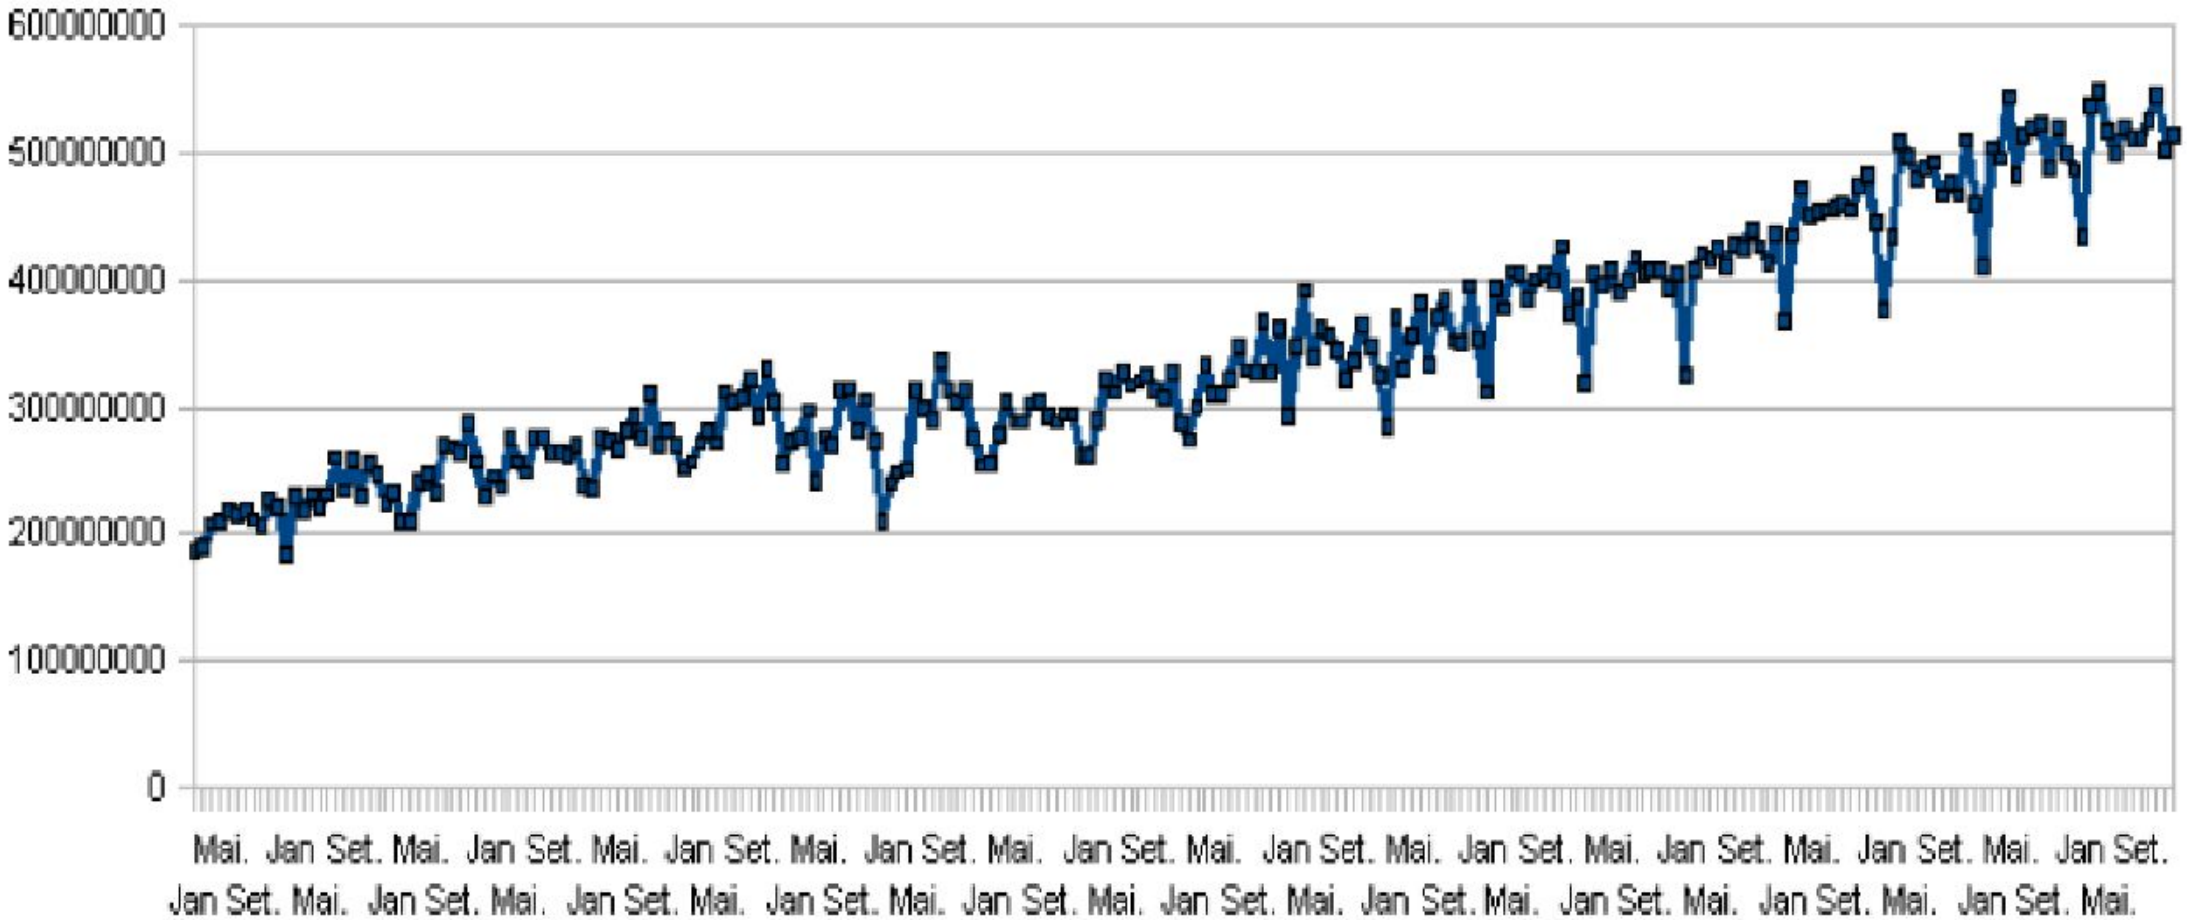
Gráfico de tendência ou de série temporal. É utilizado quando estudamos o comportamento de uma variável ao longo do tempo. Exemplos:

- Vendas mensais de cerveja;
- Temperatura média diária em Bento Gonçalves;
- Consumo de energia, em uma indústria, por hora
- Preço diário de uma ação;
- Preço mensal do barril de petróleo.

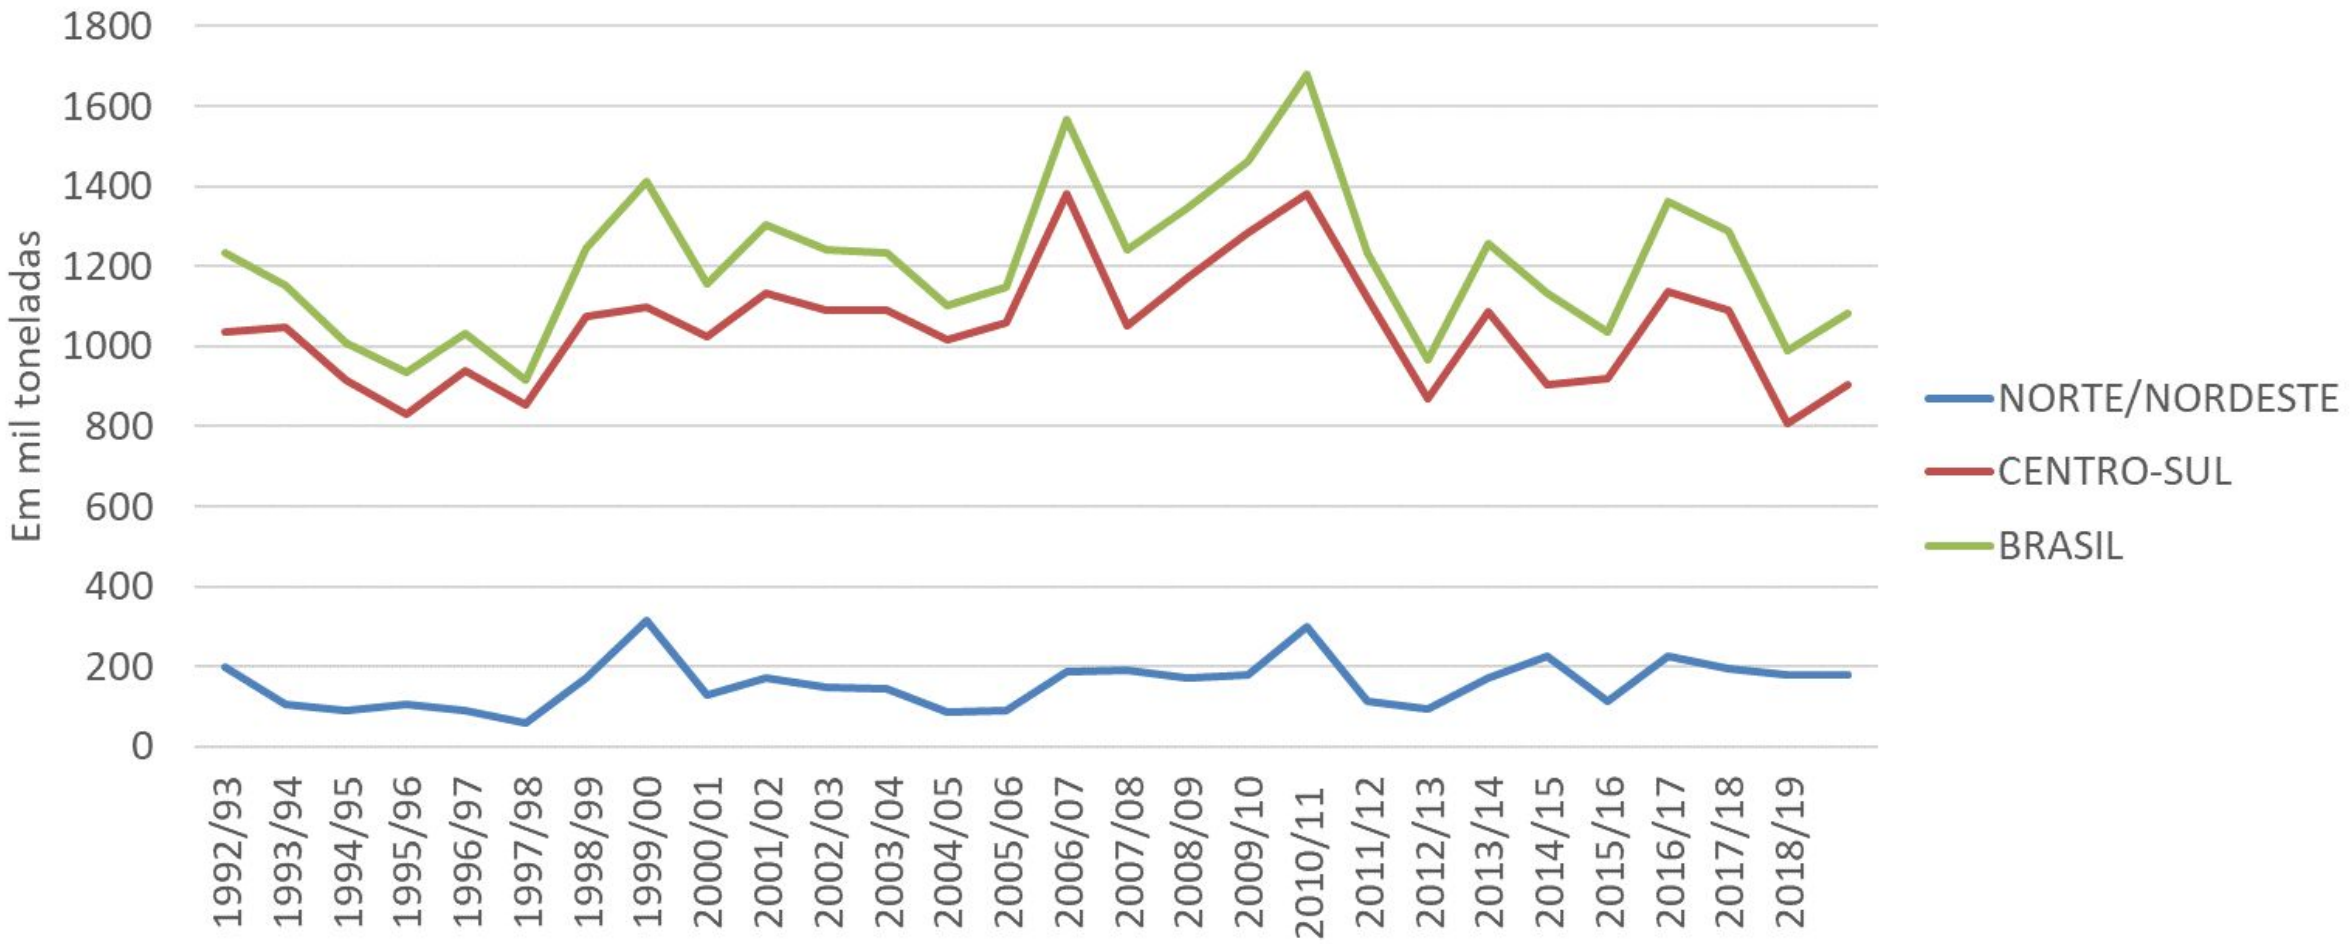
Temperatura média mensal em Bento Gonçalves (2001 a 2009)



Consumo de energia – Indústria em Santa Catarina
(1984 a 2003)



Produção anual de Feijão (1ª safra) período 1992 a 2018





- **Estatística** é a ciência que tem por objetivo orientar a coleta, o resumo, a apresentação, a análise e a interpretação de dados.

- **Estatística Descritiva**: é o ramo da estatística voltada para a organização, o resumo e a descrição de conjuntos de dados.

- **Inferência Estatística**: é o ramo da estatística que utiliza dados obtidos de uma amostra para fazer estimativas ou testar hipóteses sobre características de interesse de uma população.