Tidy

O jeito certo de organizar seus dados

James Sampaio, PhD

Tidy

O jeito certo de organizar seus dados

- Tidy
- Carregando dados
- Reorganizando os dados
- Salvando os dados

Tidy Data

O que são dados Tidy?

- Dados fáceis de modelar, visualizar e agregar (ou seja, funciona bem com tidyverse e modelagem)
- Um passo no caminho para limpeza dos dados

Tidy Data

Armazenamento	Conteúdo
Linhas	Observações
Colunas	Variáveis
Data frame	Todo o conjunt

Muitas funções do R esperam dados em formato Tidy

Quais são as três variáveis deste banco de dados?

	Grávida	Não grávida
Masculino	0	5
Feminino	1	4

Quais são as três variáveis deste banco de dados?

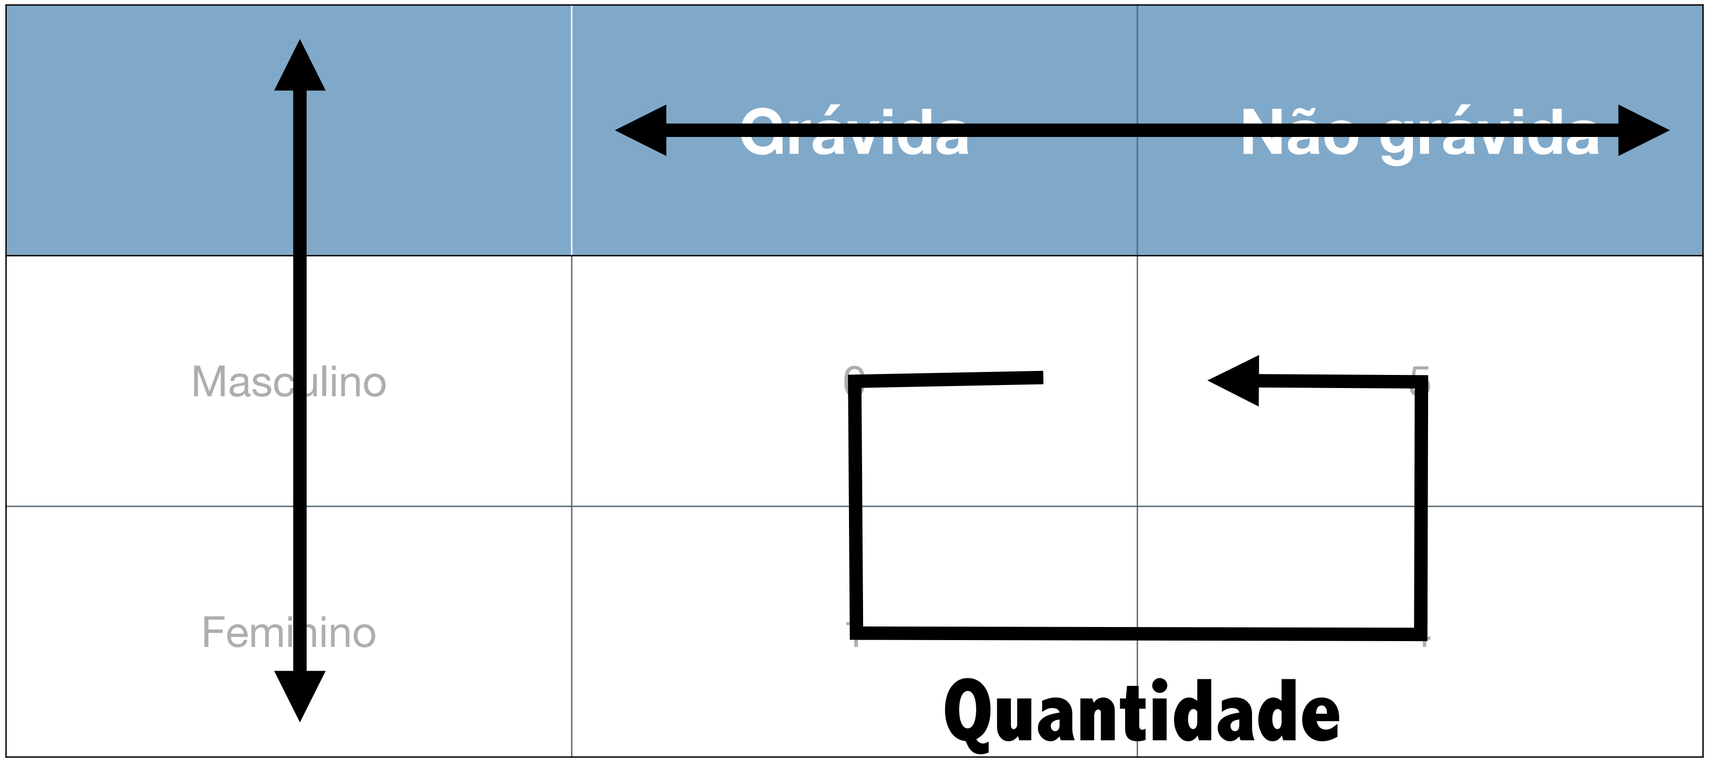
Sexo	Grávida	Não grávida
Masculino	0	5
Feminino	1	4



Quais são as três variáveis deste banco de dados?

	Gravidez	
	Grávida	Não grávida
Masculino	0	5
Feminino	1	4

Quais são as três variáveis deste banco de dados?



Quais são as três variáveis deste banco de dados?

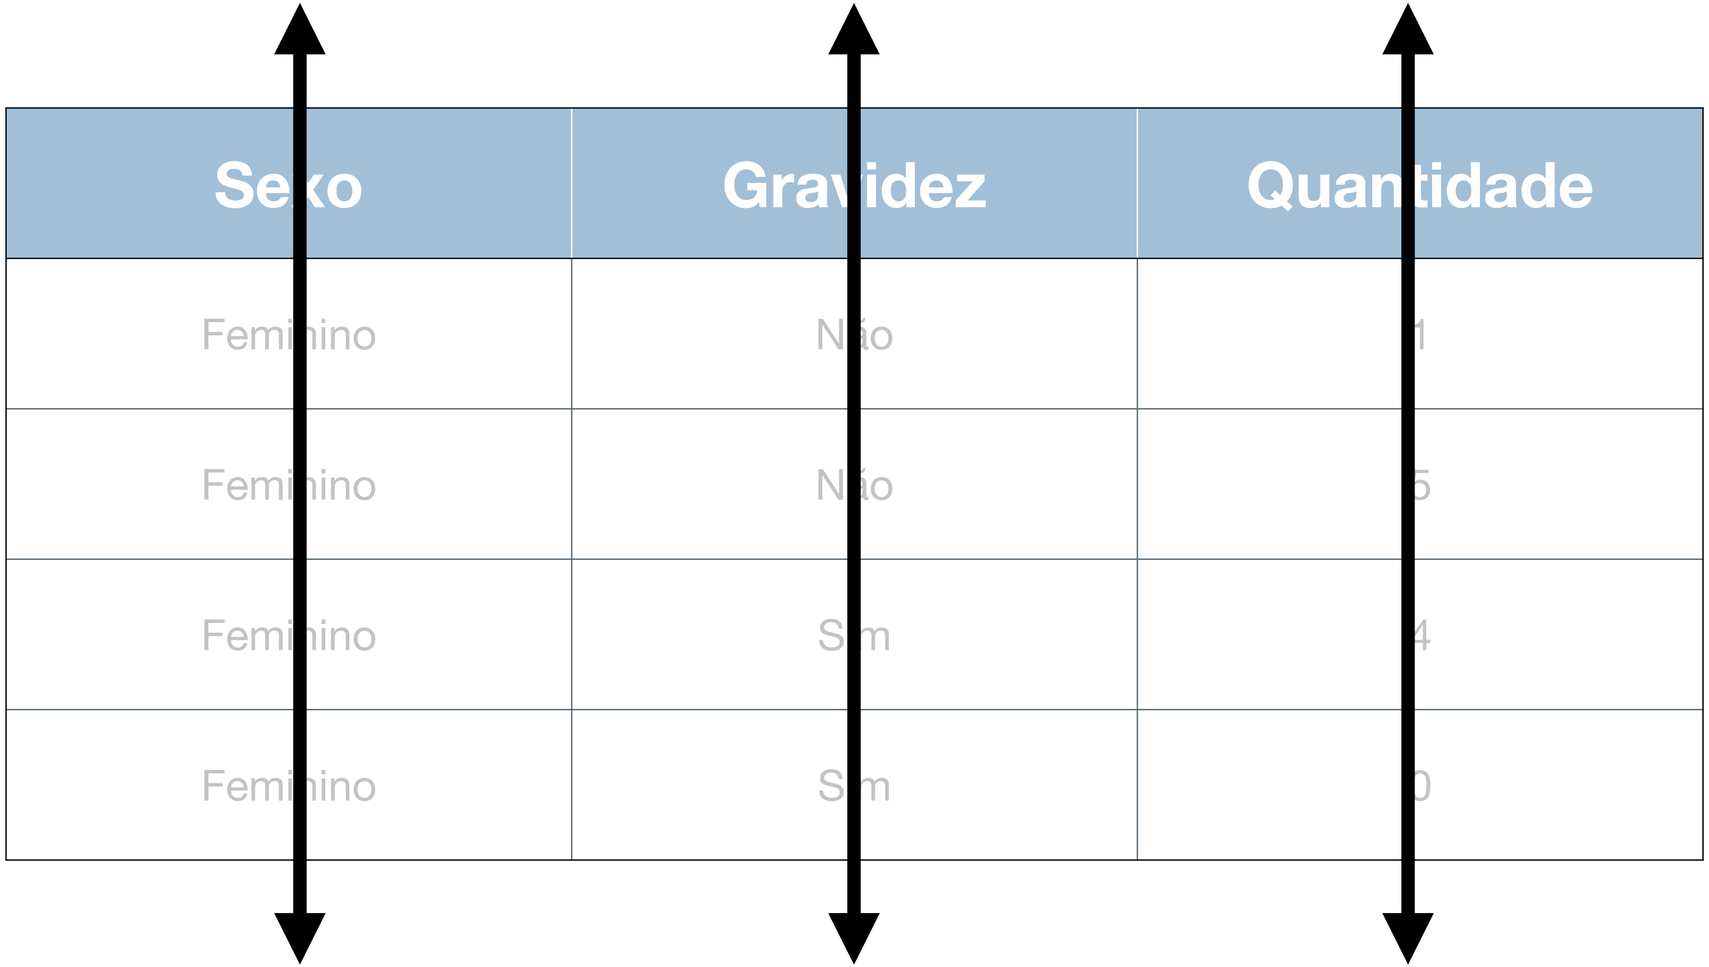
	Grávida	Não grávida
Masculino	0	5
Feminino	1	4

Não Tidy

Quais são as três variáveis deste banco de dados?

Sexo	Gravidez	Quantidade
Feminino	Não	1
Masculino	Não	5
Feminino	Sim	4
Masculino	Sim	0

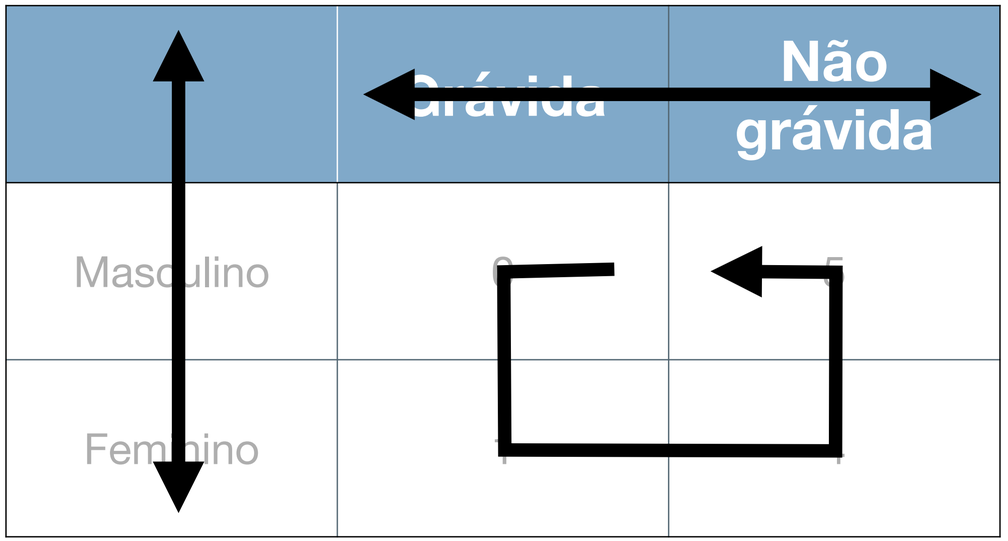
Quais são as três variáveis deste banco de dados?



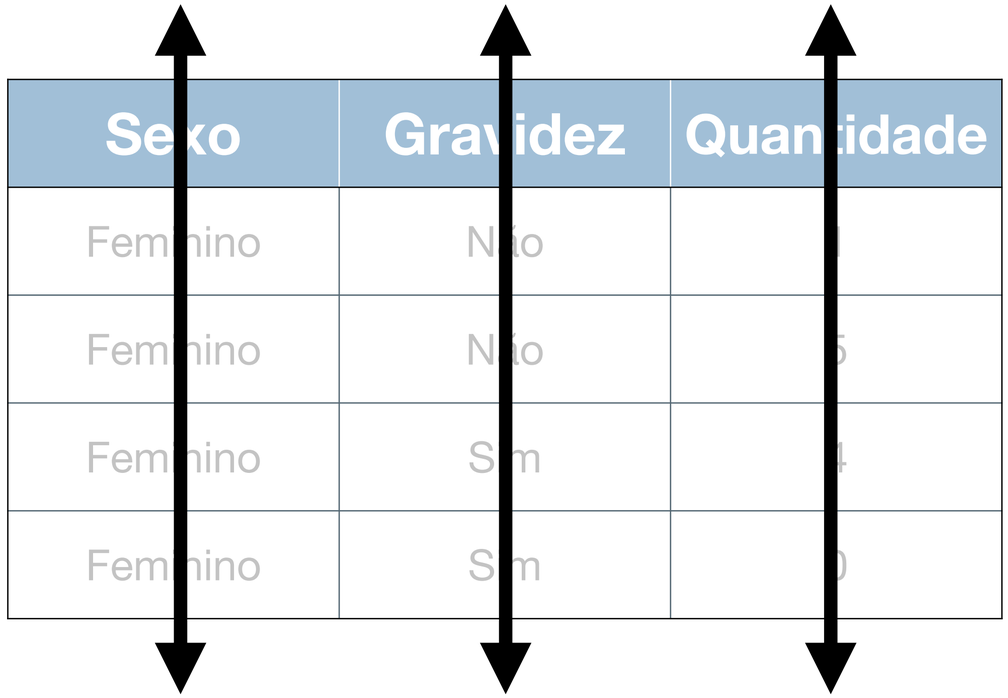
Sexo	Gravidez	Quantidade
Feminino	Não	1
Feminino	Não	5
Feminino	Sim	4
Feminino	Sim	0

Tidy

O que você prefere?



	Grávida	Não grávida
Masculino	0	5
Feminino	4	4



Sexo	Gravidez	Quantidade
Feminino	Não	3
Feminino	Não	5
Feminino	Sim	4
Feminino	Sim	0

```
df[[1]]
names(df)
c(df[2,2],df[3,2],df[2,3],df[3,3])
```

```
df$Sexo
df$Gravidez
df$Quantidade
```

Sexo	Gravidez	Quantidade
Feminino	Não	1
Masculino	Não	5
Feminino	Sim	4
Masculino	Sim	0



Tidy **ggplot**

Sexo	Gravidez
Feminino	Não
Masculino	Não
Feminino	Sim
Feminino	Sim
Masculino	Não
Masculino	Não
Masculino	Não
Masculino	Não
Feminino	Sim
Feminino	Sim

Causas comuns de bagunça

- Cabeçalhos de coluna são valores, não nomes de variáveis
- Células são nomes de variáveis, não valores
- Dados divididos em vários arquivos

Carregando os dados

Distribuição de renda dentro de grupos religiosos dos EUA

- Coletado pelo Pew Research Center
- Examina a relação entre renda e religião nos EUA
- Quais religiões têm os adeptos mais ricos?

Carregando os dados

Baseada no tipo de caractere separador

Função leitura

```
raw <- read.csv( "pew.csv", check.names = F )
```

Carregando os dados

Arquivo a ser lido

```
raw <- read.csv( "pew.csv", check.names = F )
```

Carregando os dados

Arquivo a ser lido

```
raw <- read.csv( "pew.csv", check.names = F )
```

Garanta que o arquivo esteja no diretório de trabalho

Carregando os dados

Ignora caracteres especiais dos cabeçalhos

As variáveis deste arquivo começam com $ e o R iria alterar o título dessas variáveis

```
raw <- read.csv( "pew.csv", check.names = F )
```

Carregando os dados

Usualmente, desnecessário

Ignora caracteres especiais dos cabeçalhos

As variáveis deste arquivo começam com $ e o R iria alterar o título dessas variáveis

```
raw <- read.csv( "pew.csv", check.names = F )
```

Arquivo .csv original: separado por vírgulas

```
"religion","<$10k","$10-20k","$20-30k","$30-40k","$40-50k","$50-75k","$75-100k","$100-150k",">150k","Don't know/refused"
"Agnostic",27,34,60,81,76,137,122,109,84,96
"Atheist",12,27,37,52,35,70,73,59,74,76
"Buddhist",27,21,30,34,33,58,62,39,53,54
"Catholic",418,617,732,670,638,1116,949,792,633,1489
"Don’t know/refused",15,14,15,11,10,35,21,17,18,116
"Evangelical Prot",575,869,1064,982,881,1486,949,723,414,1529
"Hindu",1,9,7,9,11,34,47,48,54,37
"Historically Black Prot",228,244,236,238,197,223,131,81,78,339
"Jehovah's Witness",20,27,24,24,21,30,15,11,6,37
"Jewish",19,19,25,25,30,95,69,87,151,162
"Mainline Prot",289,495,619,655,651,1107,939,753,634,1328
"Mormon",29,40,48,51,56,112,85,49,42,69
"Muslim",6,7,9,10,9,23,16,8,6,22
"Orthodox",13,17,23,32,32,47,38,42,46,73
"Other Christian",9,7,11,13,13,14,18,14,12,18
"Other Faiths",20,33,40,46,49,63,46,40,41,71
"Other World Religions",5,2,3,4,2,7,3,4,4,8
"Unaffiliated",217,299,374,365,341,528,407,321,258,597
```

Dados no R, após leitura via `read.csv`

```
> head(raw)
                  religion <$10k $10-20k $20-30k $30-40k $40-50k $50-75k $75-100k $100-150k >150k Don't know/refused
1                 Agnostic    27      34      60      81      76     137      122       109    84                  96
2                  Atheist    12      27      37      52      35      70       73        59    74                  76
3                 Buddhist    27      21      30      34      33      58       62        39    53                  54
4                 Catholic   418     617     732     670     638    1116      949       792   633                1489
5 Don’t know/refused    15      14      15      11      10      35       21        17    18                 116
6   Evangelical Prot   575     869    1064     982     881    1486      949       723   414                1529
```

Carregando os dados

```
read.csv()  #separado por vírgula
read.csv( sep = ";" ) #ponto e vírgula
read.delim()  #separado por tab
read.delim( sep = "|" )  #separado por |
read.fwf()  #largura fixada
```

SUA VEZ

Quais são as variáveis deste banco de dados?

```
> head(raw)
             religion <$10k $10-20k $20-30k $30-40k $40-50k $50-75k $75-100k $100-150k >150k Don't know/refused
1           Agnostic    27      34      60      81      76     137      122       109    84                  96
2            Atheist    12      27      37      52      35      70       73        59    74                  76
3           Buddhist    27      21      30      34      33      58       62        39    53                  54
4           Catholic   418     617     732     670     638    1116      949       792   633                1489
5 Don’t know/refused    15      14      15      11      10      35       21        17    18                 116
6   Evangelical Prot   575     869    1064     982     881    1486      949       723   414                1529
```

SUA VEZ

Quais são as variáveis deste banco de dados?

```
> head(raw)
                  religion <$10k $10-20k $20-30k $30-40k $40-50k $50-75k $75-100k $100-150k >150k Don't know/refused
1                 Agnostic    27      34      60      81      76     137      122       109    84                  96
2                  Atheist    12      27      37      52      35      70       73        59    74                  76
3                 Buddhist    27      21      30      34      33      58       62        39    53                  54
4                 Catholic   418     617     732     670     638    1116      949       792   633                1489
5 Don’t know/refused    15      14      15      11      10      35       21        17    18                 116
6   Evangelical Prot   575     869    1064     982     881    1486      949       723   414                1529
```



religion

SUA VEZ

Quais são as variáveis deste banco de dados?




```
> head(raw)
             religion <$10k $10-20k $20-30k $30-40k $40-50k $50-75k $75-100k $100-150k >150k Don't know/refused
1            Agnostic    27      34      60      81      76     137      122       109    84                96
2             Atheist    12      27      37      52      35      70       73        59    74                76
3            Buddhist    27      21      30      34      33      58       62        39    53                54
4            Catholic   418     617     732     670     638    1116      949       792   633              1489
5 Don’t know/refused    15      14      15      11      10      35       21        17    18               116
6   Evangelical Prot   575     869    1064     982     881    1486      949       723   414              1529
```

SUA VEZ

Quais são as variáveis deste banco de dados?

```
> head(raw)
             religion <$10k $10-20k $20-30k $30-40k $40-50k $50-75k $75-100k $100-150k >150k Don't know/refused
1            Agnostic    27      34      60      81      76     137      122       109    84                  96
2             Atheist    12      27      37      52      35      70       73        59    74                  76
3            Buddhist    27      21      30      34      33      58       62        39    53                  54
4            Catholic   418     617     732     670     638    1116      949       792   633                1489
5 Don’t know/refused    15      14      15      11      10      35       21        17    18                 116
6   Evangelical Prot   575     869    1064     982     881    1486      949       723   414                1529
```

count

Reorganizando os dados

Valores no cabeçalho das colunas



pivot_longer

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don’t know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don’t know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

Conjunto de dados

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don’t know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don’t know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

Variáveis a transformar

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don’t know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don’t know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

Novas variáveis

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don’t know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don’t know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

income

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

count

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

pivot_longer

```
tidy <- pivot_longer( raw, !religion,
                      names_to = "income",
                      values_to = "count" )
```

```
> head(tidy)
# A tibble: 6 × 3
  religion  income   count
  <chr>     <chr>    <int>
1 Agnostic  <$10k       27
2 Agnostic  $10-20k     34
3 Agnostic  $20-30k     60
4 Agnostic  $30-40k     81
5 Agnostic  $40-50k     76
6 Agnostic  $50-75k    137
```

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

```
> head(raw)
```

	religion	<$10k	$10-20k	$20-30k	$30-40k	$40-50k	$50-75k	$75-100k	$100-150k	>150k	Don't know/refused
1	Agnostic	27	34	60	81	76	137	122	109	84	96
2	Atheist	12	27	37	52	35	70	73	59	74	76
3	Buddhist	27	21	30	34	33	58	62	39	53	54
4	Catholic	418	617	732	670	638	1116	949	792	633	1489
5	Don't know/refused	15	14	15	11	10	35	21	17	18	116
6	Evangelical Prot	575	869	1064	982	881	1486	949	723	414	1529

```
> head(tidy)
# A tibble: 6 × 3
```

	religion	income	count
	<chr>	<chr>	<int>
1	Agnostic	<$10k	27
2	Agnostic	$10-20k	34
3	Agnostic	$20-30k	60
4	Agnostic	$30-40k	81
5	Agnostic	$40-50k	76
6	Agnostic	$50-75k	137

Todos os valores do conjunto de dados original são preservados

Dados por linha

```
tidy <- uncount( tidy, count )
```

```
> glimpse(tidy)
Rows: 35,556
Columns: 2
$ religion <chr> "Agnostic", "Agnostic", "Agnostic", "Agnostic", "Agnostic", "Agnostic", "Agnostic", "Agno…
$ income   <chr> "<$10k", "<$10k", "<$10k", "<$10k", "<$10k", "<$10k", "<$10k", "<$10k", "<$10k", "<$10k",…
```

Dados por linha

```
tidy <- uncount( tidy, count )
```

```
> head(tidy, 10)
# A tibble: 10 × 2
   religion income
   <chr>    <chr>
 1 Agnostic <$10k
 2 Agnostic <$10k
 3 Agnostic <$10k
 4 Agnostic <$10k
 5 Agnostic <$10k
 6 Agnostic <$10k
 7 Agnostic <$10k
 8 Agnostic <$10k
 9 Agnostic <$10k
10 Agnostic <$10k
```

```
> tail(tidy, 10)
# A tibble: 10 × 2
   religion     income
   <chr>        <chr>
 1 Unaffiliated Don't know/refused
 2 Unaffiliated Don't know/refused
 3 Unaffiliated Don't know/refused
 4 Unaffiliated Don't know/refused
 5 Unaffiliated Don't know/refused
 6 Unaffiliated Don't know/refused
 7 Unaffiliated Don't know/refused
 8 Unaffiliated Don't know/refused
 9 Unaffiliated Don't know/refused
10 Unaffiliated Don't know/refused
```

Nome de variáveis nas células



Dados sobre temperatura

- Temperatura diária em Cuernavaca, México no ano 2010
- Dias do mês: `1` a `31`
- Temperatura mínima: `tmin`
- Temperatura máxima: `tmax`



Dados crus

```
raw <- read.delim( "weather.txt", check.names = F )
```

```
> head(raw)
  year month element 1   2   3 4   5 6 7 8 9  10  11 12 13 14 15  16 17 18 19 20 21 22  23 24 25 26 27 28 29  30 31
1 2010     1    tmax .   .   . .   . . . . .   .   . .  .  .  .   .  .  .  .  .  .  .   .  .  .  .  .  .  . 278  .
2 2010     1    tmin .   .   . .   . . . . .   .   . .  .  .  .   .  .  .  .  .  .  .   .  .  .  .  .  .  . 145  .
3 2010     2    tmax . 273 241 .   . . . . .   . 297  .  .  .  .   .  .  .  .  .  .  . 299  .  .  .  .  .  .   .  .
4 2010     2    tmin . 144 144 .   . . . . .   . 134  .  .  .  .   .  .  .  .  .  .  . 107  .  .  .  .  .  .   .  .
5 2010     3    tmax .   .   . . 321 . . . . 345   .  .  .  .  .  . 311  .  .  .  .  .  .   .  .  .  .  .  .  .   .  .
6 2010     3    tmin .   .   . . 142 . . . . 168   .  .  .  .  .  . 176  .  .  .  .  .  .   .  .  .  .  .  .  .   .  .
```

Dados crus

Converte os pontos para NA

```
raw <- read.delim( "weather.txt", check.names = F, na.strings = "." )
```

```
> head(raw)
  year month element  1   2   3  4   5  6  7  8  9  10  11 12 13 14 15  16 17 18 19 20 21 22  23 24 25 26 27 28 29  30 31
1 2010     1    tmax NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 278 NA
2 2010     1    tmin NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 145 NA
3 2010     2    tmax NA 273 241 NA  NA NA NA NA NA  NA 297 NA NA NA NA  NA NA NA NA NA NA NA 299 NA NA NA NA NA NA  NA NA
4 2010     2    tmin NA 144 144 NA  NA NA NA NA NA  NA 134 NA NA NA NA  NA NA NA NA NA NA NA 107 NA NA NA NA NA NA  NA NA
5 2010     3    tmax NA  NA  NA NA 321 NA NA NA NA 345  NA NA NA NA NA 311 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
6 2010     3    tmin NA  NA  NA NA 142 NA NA NA NA 168  NA NA NA NA NA 176 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
```

SUA VEZ

Reorganize o banco de dados alocando a variável `day` como coluna

```
raw2 <- pivot_longer( raw, !c(year, month, element),
                      names_to = "day", values_to = "value",
                      values_drop_na = T )
```

```
> head(raw)
  year month element  1   2   3  4   5  6  7  8  9  10  11 12 13 14 15  16 17 18 19 20 21 22  23 24 25 26 27 28 29  30 31
1 2010     1    tmax NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 278 NA
2 2010     1    tmin NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 145 NA
3 2010     2    tmax NA 273 241 NA  NA NA NA NA NA  NA 297 NA NA NA NA  NA NA NA NA NA NA NA 299 NA NA NA NA NA NA  NA NA
4 2010     2    tmin NA 144 144 NA  NA NA NA NA NA  NA 134 NA NA NA NA  NA NA NA NA NA NA NA 107 NA NA NA NA NA NA  NA NA
5 2010     3    tmax NA  NA  NA NA 321 NA NA NA NA 345  NA NA NA NA NA 311 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
6 2010     3    tmin NA  NA  NA NA 142 NA NA NA NA 168  NA NA NA NA NA 176 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
```

SUA VEZ

Reorganize o banco de dados alocando a variável `day` como coluna

```
raw2 <- pivot_longer( raw, !c(year, month, element),
                      names_to = "day", values_to = "value",
                      values_drop_na = T )
```

Remove os dados faltantes

```
> head(raw)
  year month element  1   2   3  4   5  6  7  8  9  10  11 12 13 14 15  16 17 18 19 20 21 22  23 24 25 26 27 28 29  30 31
1 2010     1    tmax NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 278 NA
2 2010     1    tmin NA  NA  NA NA  NA NA NA NA NA  NA  NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA NA NA NA NA NA 145 NA
3 2010     2    tmax NA 273 241 NA  NA NA NA NA NA  NA 297 NA NA NA NA  NA NA NA NA NA NA NA 299 NA NA NA NA NA NA  NA NA
4 2010     2    tmin NA 144 144 NA  NA NA NA NA NA  NA 134 NA NA NA NA  NA NA NA NA NA NA NA 107 NA NA NA NA NA NA  NA NA
5 2010     3    tmax NA  NA  NA NA 321 NA NA NA NA 345  NA NA NA NA NA 311 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
6 2010     3    tmin NA  NA  NA NA 142 NA NA NA NA 168  NA NA NA NA NA 176 NA NA NA NA NA NA  NA NA NA NA NA NA NA  NA NA
```

SUA VEZ

Reorganize o banco de dados alocando a variável `day` como coluna

```
raw2 <- pivot_longer( raw, !c(year, month, element),
                      names_to = "day", values_to = "value",
                      values_drop_na = T )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

SUA VEZ

Reorganize o banco de dados alocando a variável `day` como coluna

```
raw2 <- pivot_longer( raw, !c(year, month, element),
                      names_to = "day", values_to = "value",
                      values_drop_na = T )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

Está tudo certo?
Ou ainda há algo estranho?

SUA VEZ

Reorganize o banco de dados alocando a variável `day` como coluna

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

Não são observações!

São variáveis!!!!

`tmax`

`tmin`

pivot_wider

```
tidy <- pivot_wider( raw2,
                     names_from = "element",
                     values_from = "value" )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

pivot_wider

Dados a serem tratados

```
tidy <- pivot_wider( raw2,
                     names_from = "element",
                     values_from = "value" )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

pivot_wider

Coluna de onde vem as novas variáveis

```
tidy <- pivot_wider( raw2,
                     names_from = "element",
                     values_from = "value" )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```

pivot_wider

Coluna de onde vem as novas variáveis

```
tidy <- pivot_wider( raw2,
                     names_from = "element",
                     values_from = "value" )
```

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```



```
> head(tidy)
# A tibble: 6 × 5
   year month day     tmax  tmin
  <int> <int> <chr> <int> <int>
1  2010     1 30      -     -
2  2010     2 2       -     -
3  2010     2 3       -     -
4  2010     2 11      -     -
5  2010     2 23      -     -
6  2010     3 5       -     -
```

pivot_wider

```
tidy <- pivot_wider( raw2,
                     names_from = "element",
                     values_from = "value" )
```

Coluna de onde vem os valores das novas variáveis

```
> head(raw2)
# A tibble: 6 × 5
   year month element day   value
  <int> <int> <chr>   <chr> <int>
1  2010     1 tmax    30      278
2  2010     1 tmin    30      145
3  2010     2 tmax    2       273
4  2010     2 tmax    3       241
5  2010     2 tmax    11      297
6  2010     2 tmax    23      299
```



```
> head(tidy)
# A tibble: 6 × 5
   year month day    tmax  tmin
  <int> <int> <chr> <int> <int>
1  2010     1 30      278   145
2  2010     2 2       273   144
3  2010     2 3       241   144
4  2010     2 11      297   134
5  2010     2 23      299   107
6  2010     3 5       321   142
```

pipes

```
raw %>%
  pivot_longer( !c(year, month, element),
                names_to = "day",
                values_to = "value",
                values_drop_na = T ) %>%
  pivot_wider( names_from = "element",
               values_from = "value" )
```

Permite uma sequência de execuções de comandos

```
# A tibble: 33 × 5
    year month day    tmax  tmin
   <int> <int> <chr> <int> <int>
 1  2010     1 30      278   145
 2  2010     2 2       273   144
 3  2010     2 3       241   144
 4  2010     2 11      297   134
 5  2010     2 23      299   107
 6  2010     3 5       321   142
 7  2010     3 10      345   168
 8  2010     3 16      311   176
 9  2010     4 27      363   167
10  2010     5 27      332   182
# … with 23 more rows
# ℹ Use `print(n = ...)` to see
more rows
```

pipes

```
raw %>%
  pivot_longer( !c(year, month, element),
                names_to = "day",
                values_to = "value",
                values_drop_na = T ) %>%
  pivot_wider( names_from = "element",
               values_from = "value" ) %>%
  head()
```

```
# A tibble: 6 × 5
   year month day    tmax  tmin
  <int> <int> <chr> <int> <int>
1  2010     1 30      278   145
2  2010     2 2       273   144
3  2010     2 3       241   144
4  2010     2 11      297   134
5  2010     2 23      299   107
6  2010     3 5       321   142
```

pipes

```
raw %>%
  pivot_longer( !c(year, month, element),
                names_to = "day",
                values_to = "value",
                values_drop_na = T ) %>%
  pivot_wider( names_from = "element",
               values_from = "value" ) %>%
  head()
```

raw2

tidy

head

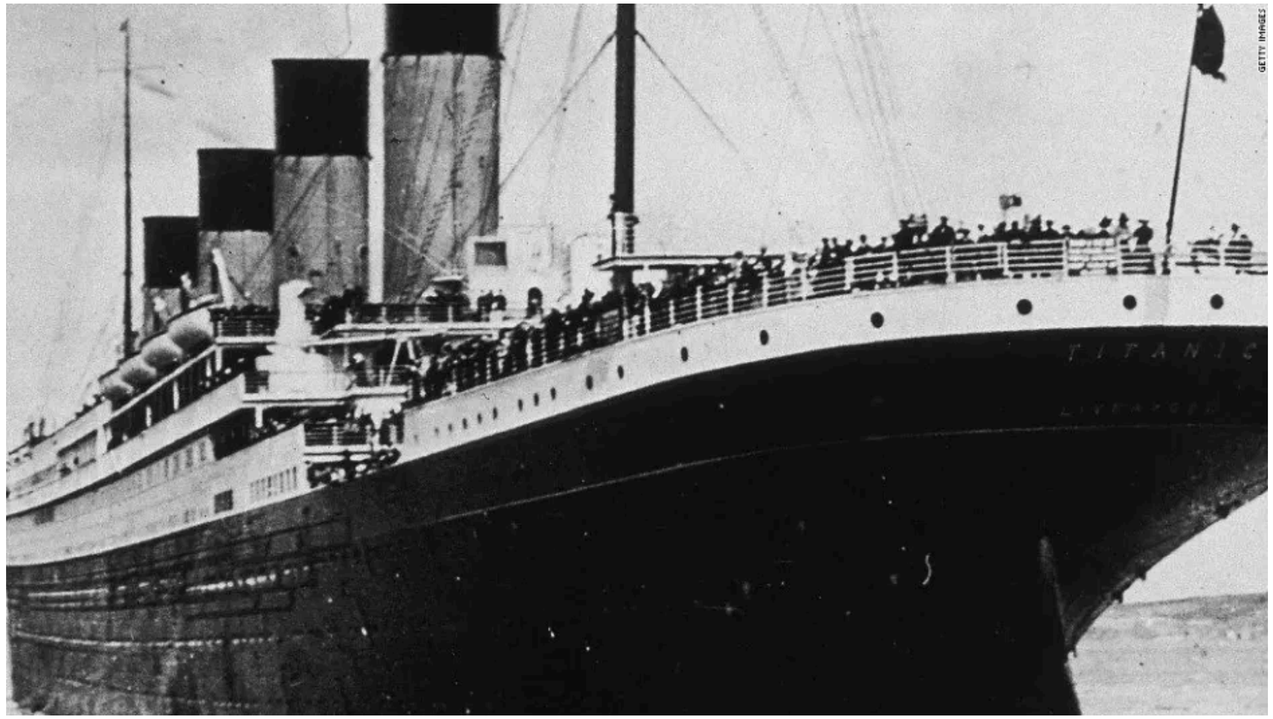
pipes

```
tidy <- raw %>%
  pivot_longer( !c(year, month, element),
                names_to = "day",
                values_to = "value",
                values_drop_na = T ) %>%
  pivot_wider( names_from = "element",
               values_from = "value" )
```

```
> head(tidy)
# A tibble: 6 × 5
   year month day    tmax  tmin
  <int> <int> <chr> <int> <int>
1  2010     1 30      278   145
2  2010     2 2       273   144
3  2010     2 3       241   144
4  2010     2 11      297   134
5  2010     2 23      299   107
6  2010     3 5       321   142
```

titanic

Características e destino de passageiros no acidente com o barco Titanic



titanic

Características e destino de passageiros no acidente com o barco Titanic

```
titanic2 <- read.csv( "titanic2.csv", stringsAsFactors = FALSE )
```

```
> head(titanic2)
  class   age     fate male female
1   1st adult perished  118      4
2   1st adult survived   57    140
3   1st child perished    0      0
4   1st child survived    5      1
5   2nd adult perished  154     13
6   2nd adult survived   14     80
```

SUA VEZ

`male` e `female` não são variáveis. Organize os dados de maneira adequada.

```
tidy <- titanic2 %>%
  pivot_longer( !c("class", "age", "fate"),
                names_to = "gender",
                values_to = "value" )
```

```
> head(titanic2)
  class   age     fate male female
1   1st adult perished  118      4
2   1st adult survived   57    140
3   1st child perished    0      0
4   1st child survived    5      1
5   2nd adult perished  154     13
6   2nd adult survived   14     80
```

SUA VEZ

`male` e `female` não são variáveis. Organize os dados de maneira adequada.

```
tidy <- titanic2 %>%
  pivot_longer( c("male", "female"),
                names_to = "gender",
                values_to = "value" )
```

```
> head(titanic2)
  class   age     fate male female
1   1st adult perished  118      4
2   1st adult survived   57    140
3   1st child perished    0      0
4   1st child survived    5      1
5   2nd adult perished  154     13
6   2nd adult survived   14     80
```

SUA VEZ

`male` e `female` não são variáveis. Organize os dados de maneira adequada.

```
tidy <- titanic2 %>%
  pivot_longer( c("male", "female"),
                names_to = "gender",
                values_to = "value" )
```

```
> head(tidy)
# A tibble: 6 × 5
  class age   fate     gender value
  <chr> <chr> <chr>    <chr>  <int>
1 1st   adult perished male     118
2 1st   adult perished female     4
3 1st   adult survived male      57
4 1st   adult survived female   140
5 1st   child perished male       0
6 1st   child perished female     0
```

SUA VEZ

A variável `fate` possui dois resultados, mas precisaremos transformá-los em variáveis numéricas para calcular a taxa de sobreviventes. Faça isso!!

```
tidy <- tidy %>%
  pivot_wider( names_from = "fate",
               values_from = "value" )
```

```
> head(tidy)
# A tibble: 6 × 5
  class age   fate      gender value
  <chr> <chr> <chr>     <chr>  <int>
1 1st   adult perished  male     118
2 1st   adult perished  female     4
3 1st   adult survived  male      57
4 1st   adult survived  female   140
5 1st   child perished  male       0
6 1st   child perished  female     0
```

SUA VEZ

A variável `fate` possui dois resultados, mas precisaremos transformá-los em variáveis numéricas para calcular a taxa de sobreviventes. Faça isso!!

```
tidy <- tidy %>%
  pivot_wider( names_from = "fate",
               values_from = "value" )
```

```
> head(tidy)
# A tibble: 6 × 5
  class age   gender perished survived
  <chr> <chr> <chr>     <int>    <int>
1 1st   adult male        118       57
2 1st   adult female        4      140
3 1st   child male          0        5
4 1st   child female        0        1
5 2nd   adult male        154       14
6 2nd   adult female       13       80
```

SUA VEZ

Calcule a taxa de sobreviventes para cada grupo de idade, classe e gênero

```
tidy$rate <- round( tidy$survived / (tidy$survived + tidy$perished), 2 )
```

```
> head(tidy)
# A tibble: 6 × 6
  class age   gender perished survived  rate
  <chr> <chr> <chr>     <int>    <int> <dbl>
1 1st   adult male        118       57  0.33
2 1st   adult female        4      140  0.97
3 1st   child male          0        5  1
4 1st   child female        0        1  1
5 2nd   adult male        154       14  0.08
6 2nd   adult female       13       80  0.86
```

SUA VEZ

Calcule a taxa de sobreviventes para cada grupo de idade, classe e gênero

```
titanic2 %>%
  pivot_longer( c("male", "female"),
                names_to = "gender",
                values_to = "value") %>%
  pivot_wider( names_from = "fate",
               values_from = "value") %>%
  mutate( rate = round ( survived / (survived + perished), 2 ) )
```

Cria uma nova coluna ao data frame de referência

Pacote `dplyr` **do** `tidyverse`

SUA VEZ

Calcule a taxa de sobreviventes para cada grupo de idade, classe e gênero

```
# A tibble: 16 × 6
   class age   gender perished survived     rate
   <chr> <chr> <chr>     <int>    <int>    <dbl>
 1 1st   adult male        118       57   0.33
 2 1st   adult female        4      140   0.97
 3 1st   child male          0        5   1
 4 1st   child female        0        1   1
 5 2nd   adult male        154       14   0.08
 6 2nd   adult female       13       80   0.86
 7 2nd   child male          0       11   1
 8 2nd   child female        0       13   1
 9 3rd   adult male        387       75   0.16
10 3rd   adult female       89       76   0.46
11 3rd   child male         35       13   0.27
12 3rd   child female       17       14   0.45
13 Crew  adult male        670      192   0.22
14 Crew  adult female        3       20   0.87
15 Crew  child male          0        0 NaN
16 Crew  child female        0        0 NaN
```

SUA VEZ

Calcule a taxa de sobreviventes para cada grupo de idade, classe e gênero

```
tidy <- titanic2 %>%
  pivot_longer( !c("class", "age", "fate"),
                names_to = "gender",
                values_to = "value") %>%
  pivot_wider( names_from = "fate",
               values_from = "value") %>%
  mutate( rate = round ( survived / (survived + perished), 2 ) )
```

Dados divididos em vários arquivos



rbind

row biding

df1

Cor	Valor
Branco	1
Branco	2

+

df2

Cor	Valor
Azul	3
Azul	4
Azul	5



Cor	Valor
Branco	1
Branco	2
Azul	3
Azul	4
Azul	5

```
rbind( df1, df2 )
```

cbind

column biding

df1

Cor	Valor
Branco	1
Branco	2
Branco	3

+

df2

Código	Qtd
a	7
b	13
c	5



Cor	Valor	Código	Qtd
Branco	1	a	7
Branco	2	b	13
Branco	3	c	5

```
cbind( df1, df2 )
```

Salvando os dados

Salvando dados

Salvando dados .csv

```
write.csv( tidy, file = "tidy.csv", row.names = FALSE )
# para armazenamento de longo prazo
```

Lendo dados .csv

```
read.csv( "tidy.csv" )
```

Salvando dados

Salvando dados .RDS

```
saveRDS( tidy, "tidy.rds" )
# Cache de curto prazo para cálculos extensos
# preserva fatores e outras definições
```

Lendo dados .RDS

```
readRDS( "tidy.rds" )
```

Os arquivos sempre serão salvos no diretório de trabalho

.csv	.RDS
`read.csv()`	`readRDS()`
`write.csv(row.names = FALSE)`	`saveRDS()`
Apenas data frames	Qualquer objeto R
Qualquer programa lê	Apenas o R lê
Armazenamento de longo prazo	Cache de curto prazo para cálculos extensos

Salvando dados

Você pode comprimir o arquivo para economizar espaço

```
write.csv(tidy, file = bzfile("tidy.csv.bz2"), row.names = FALSE)
```

A leitura também fica mais fácil

```
read.csv("tidy.csv.bz2")
```

Arquivos salvos com saveRDS() são comprimidos de forma automática