Lista de Exercícios da Monitoria - stringr

Computação em Estatística 2: R

11 de setembro de 2026

1. Limpeza e padronização de nomes

Você ajudou a organizar um evento de extensão e agora precisa emitir os certificados de participação. A inscrição foi feita por um formulário online, e cada pessoa digitou o próprio nome como quis: alguns em caixa alta, outros tudo em minúsculo, vários com espaços sobrando no início, no fim ou entre os sobrenomes. O nome sai impresso no certificado exatamente como está no cadastro — então, antes de gerar qualquer coisa, esse vetor precisa ser arrumado.

a) Crie o vetor `nomes_limpos`, sem espaços no início e no fim e sem espaços duplicados no meio dos nomes.

b) Padronize `nomes_limpos` de modo que cada palavra comece com letra maiúscula.

c) A caixa de texto para o nome do participante no certificado do evento imprime no máximo 15 caracteres. Quantos caracteres tem cada nome padronizado, e quais deles estouram esse limite?

d) Olhe agora os nomes de Igor e de Camila. A padronização do item (b) resolveu esses dois casos? Corrija as partículas (`de`, `do`, `da`) para que voltem a ficar em minúsculas, como manda a norma para nomes próprios.

2. Construindo strings, e não apenas extraindo

Os nomes já estão limpos. Agora a secretaria precisa emitir os certificados de verdade, e cada um leva um código de autenticação único, que o participante digita no site do evento para confirmar que o documento é legítimo. O formato combinado é `SIGLA-NNN`: as três primeiras letras do curso em maiúsculas, um hífen, e o número de inscrição com três dígitos.

a) A coluna `id` vai de 1 a 35. Transforme-a em texto com **três dígitos**, completando com zeros à esquerda: `"001"`, `"002"`, …, `"035"`.

b) Monte a sigla de cada curso: as três primeiras letras, em maiúsculas. Atenção: a coluna `curso` também veio bagunçada. Se você não arrumar antes, `" nutrição"` vai gerar uma sigla errada.

c) Combine os dois resultados anteriores na variável `codigo`, no formato `"NUT-001"`, `"EST-007"`, e assim por diante.

d) Gere o texto de cada certificado, no formato: `"Certificamos que Ana Beatriz, do curso de Nutrição, participou do evento. Código de autenticação: NUT-001."`

e) A coordenação pediu todos os códigos emitidos em um **único** campo de texto, separados por `"; "`. Produza essa string.

3. Detectando padrões: âncoras e filtros

Os certificados estão prontos. Agora a coordenação quer saber quantos participantes são alunos da universidade, porque para esses o evento vale horas complementares — e eles precisam receber um formulário extra. O jeito de identificar é o e-mail: alunos usam o domínio institucional `@aluno.unb.br`; os demais se inscreveram com e-mail pessoal.

a) Conte quantos participantes têm e-mail institucional, isto é, cujo endereço **termina** em `"@aluno.unb.br"`.

b) A secretaria conferiu a lista na mão e afirma que existe **um aluno a mais** do que o seu código encontrou. Descubra quem ficou de fora e por quê — o padrão está correto, o problema é outro. Depois corrija e reconte.

c) Várias pessoas digitaram o domínio em maiúsculas. Conte quantos participantes usam Gmail, independentemente da caixa. Compare com a contagem sem esse cuidado: quantos você perderia?

d) Em vez do vetor lógico, devolva diretamente o **subconjunto** dos e-mails institucionais — é essa lista que vai receber o formulário de horas complementares.

e) Devolva agora os e-mails que **não** são institucionais, usando um único argumento da mesma função (sem `!`).

4. Extrair por padrão ou extrair por posição?

A coordenação quer um relatório simples: quantos participantes vieram de cada provedor de e-mail, e em que mês cada um se inscreveu. Parece trivial, mas nada na planilha está no formato que você precisa — o provedor está grudado no nome de usuário, e a data foi digitada de três maneiras diferentes.

a) Descubra em que posição está o `"@"` de cada e-mail. Ele está sempre no mesmo lugar?

b) Usando essas posições, separe cada endereço em duas partes: o nome de usuário (antes do `"@"`) e o domínio (depois dele).

c) Faça a mesma separação usando **um padrão**, sem calcular posição nenhuma.

d) Quantos domínios diferentes existem na planilha? Confira a lista que você obteve — o número que o R devolve na primeira tentativa não é o número real de provedores. Explique a diferença e corrija.

5. Contagem de palavras feita com cuidado

Terminado o evento, a coordenação aplicou um formulário de avaliação com uma pergunta aberta. Agora quer um resumo para o relatório final: o que as pessoas mais mencionaram. E quer também corrigir o vocabulário nas citações, porque o evento foi uma série de oficinas, não um curso.

```r
respostas <- c(
  "O curso foi otimo, aprendi muito sobre analise de dados e quero fazer outro curso assim.",
  "Gostei do percurso das oficinas. O curso de estatistica foi o melhor!",
  "Achei o curso curto. Faltou tempo para praticar analise de dados.",
  "Otima organizacao. O percurso entre as salas era confuso, mas o curso valeu a pena.",
  "Quero parabenizar a equipe. Curso excelente; volto no proximo ano!"
)
```

a) Quantas vezes a palavra `"curso"` aparece nas respostas, ignorando maiúsculas e minúsculas?

b) Refaça a contagem considerando apenas `"curso"` como **palavra inteira**. O número caiu: identifique as duas ocorrências que estavam sendo contadas indevidamente.

c) A coordenação quer trocar `"curso"` por `"oficina"` nas citações. Faça a substituição e leia o resultado da segunda resposta em voz alta. Conserte.

d) Extraia todas as palavras que começam com vogal.

e) Quantas frases existem no conjunto de respostas? Compare o resultado usando como separador apenas o ponto e usando o conjunto `.`, `!` e `?`.